

Università degli Studi di Modena e Reggio-Emilia
Dipartimento di Comunicazione ed Economia

Corso di Laurea Magistrale in
Management e Comunicazione d'Impresa
LM77

Tesi di Ricerca di Laurea Magistrale

**ANALISI DATA-DRIVEN PER
L'ADOZIONE DI VEICOLI ELETTRICI**
Analisi statistiche e predittive sugli acquirenti di auto elettriche

Laureando:
Gamberini Federico
mat. 178147

Relatore:
Prof. Cavicchioli Roberto

Sessione straordinaria: 7 Marzo 2025

Anno Accademico
2023 - 2024

Tesi di Ricerca di Laurea Magistrale

ANALISI DATA-DRIVEN PER L'ADOZIONE DI VEICOLI ELETTRICI

Analisi statistiche e predittive sugli acquirenti di auto elettriche

INDICE

NOMENCLATURA.....	ix
CAPITOLO 1: INTRODUZIONE.....	1
1.1 Motivazione della tesi.....	1
1.2 Obiettivi e ipotesi della ricerca	2
1.2.1 <i>Ipotesi 1 (H1) - Influenza del reddito sull'acquisto di veicoli BEV.....</i>	2
1.2.2 <i>Ipotesi 2 (H2) - Influenza del veicolo posseduto in precedenza sull'acquisto di veicoli BEV</i>	2
1.2.3 <i>Ipotesi 3 (H3) - Influenza delle lunghe distanze percorse sull'acquisto di veicoli BEV.....</i>	3
1.2.3 <i>Ipotesi 3 (H3) - Influenza delle lunghe distanze percorse sull'acquisto di veicoli BEV.....</i>	4
1.3 Struttura della tesi.....	4
CAPITOLO 2: LA MOBILITÀ DEL FUTURO.....	5
2.1 Cambio di mobilità, cambio di paradigma.....	5
2.1.1 <i>L'auto elettrica.....</i>	6
2.1.2 <i>L'auto a idrogeno.....</i>	7
2.2 L'Andamento del mercato dei veicoli elettrici in Italia.....	9
2.2.1 <i>Una fotografia del cambiamento in Italia.....</i>	9
2.2.2 <i>Il rallentamento del mondo dell'elettrico.....</i>	10
CAPITOLO 3: Il dataset: la raccolta e la preparazione dei dati.....	12
3.1 Fonte del dataset e le sue caratteristiche.....	12
3.2 Pulizia e correzione dei dati mancanti.....	14
3.2.1 <i>Variabile Carmain.....</i>	14
3.2.2 <i>Variabili Previous.....</i>	15
3.2.3 <i>Variabile Household Income.....</i>	15
3.2.4 <i>Variabile Highest Level of Education.....</i>	17
3.2.5 <i>Variabile Age.....</i>	18
3.2.6 <i>Rimanenti Variabili.....</i>	18
3.3. Preparazione dei differenti dataset finali per le analisi.....	19

CAPITOLO 4: Analisi preliminari.....	21
4.1 Il dataset e le sue caratteristiche: come si distribuiscono le variabili.....	21
4.1.1 Variabili socio-demografiche.....	22
4.1.2 Variabili abitative.....	24
4.1.3 Variabile sensibilità ambientale.....	27
4.1.4 Variabili classe veicolare.....	28
4.1.5 Variabili di mobilità e percorrenza.....	30
4.2 Come si distribuiscono le variabili in relazione alla variabile dipendente.....	34
4.3 Analisi della multicollinearità: analisi VIF.....	38
4.4 Librerie Python per le analisi preliminari.....	42
 CAPITOLO 5: Analisi di regressione logistica.....	 43
5.1 Definizione della regressione logistica.....	43
5.2 Risultati e interpretazione.....	44
5.2.1 Applicazione e spiegazione generale del modello.....	44
5.2.2 Risultati delle variabili legate alle ipotesi di ricerca.....	47
5.2.3 Risultati delle altre variabili.....	51
5.3 Librerie Python per l'analisi di regressione logistica.....	52
 CAPITOLO 6: Analisi esplorative.....	 53
6.1 Preparazione.....	53
6.2 Riduzione delle variabili, FAMD, MCA e PCA.....	55
6.2.1 FAMD - Factor Analysis of Mixed Data.....	55
6.2.2 MCA - Multi Correspondence Analysis.....	57
6.2.3 PCA - Principal Component Analysis.....	66
6.2.4 Conclusioni.....	69
6.3 Cluster Analysis.....	70
6.3.1 Algoritmo Kmeans.....	71
6.3.2 Algoritmo Kmode.....	74
6.3.3 Risultati.....	78
6.4 Librerie R e Python per le analisi esplorative.....	81
 CAPITOLO 7: Apprendimento automatico.....	 82
7.1 Cenni sui sistemi di apprendimento automatico.....	82
7.2 Machine Learning.....	84
7.2.1 Preparazione.....	84
7.2.2 Scelta dei modelli.....	86
7.2.3 Ensemble Learning.....	88
7.2.4 Support Vector Machine.....	107

7.2.5 <i>Linear model</i>	111
7.2.6 <i>Neural Network</i>	115
7.3 I migliori modelli e le migliori features negli algoritmi di ML.....	118
7.3.1 <i>Il migliore modello</i>	118
7.3.2 <i>Le feature migliori</i>	121
7.3.3 <i>Il migliore modello con le migliori feature</i>	126
7.4 Deep Learning: analisi del modello di rete neurale artificiale (ANN).....	129
7.4.1 <i>Introduzione alle Reti Neurali Artificiali</i>	129
7.4.2 <i>Analisi dei modelli ANN: Modello Base</i>	131
7.4.3 <i>Analisi dei modelli ANN: Modelli Avanzati</i>	133
7.5 Conclusioni.....	140
7.6 Librerie Python per l'Analisi predittive dell'apprendimento automatico.....	141
 CAPITOLO 8: Conclusioni finali	 143
8.1 <i>Introduzione alle conclusioni</i>	143
8.2 <i>Conclusioni sulle Analisi Statistiche</i>	144
8.3 <i>Conclusioni sull'Apprendimento Automatico</i>	145
8.4 <i>I limiti della ricerca</i>	149
8.5 <i>Related Works</i>	150
8.6 <i>Considerazioni finali</i>	152
 BIBLIOGRAFIA	 153

NOMECLATURA

ICE (*Internal Combustion Engine*): Veicoli con motore a combustione interna, alimentati da carburanti come benzina o diesel.

HEV (*Hybrid Electric Vehicle*): Veicoli ibridi che combinano un motore a combustione interna con un motore elettrico, utilizzando entrambi per migliorare l'efficienza del carburante.

MHEV (*Mild Hybrid Electric Vehicle*): Veicoli ibridi leggeri che utilizzano un sistema elettrico a bassa tensione per supportare il motore a combustione interna, senza la possibilità di guidare esclusivamente in modalità elettrica.

PHEV (*Plug-in Hybrid Electric Vehicle*): Veicoli ibridi plug-in che combinano un motore a combustione interna e una batteria ricaricabile, permettendo una maggiore autonomia in modalità completamente elettrica rispetto agli HEV.

FCEV (*Fuel Cell Electric Vehicle*): Veicoli elettrici a celle a combustibile, che utilizzano l'idrogeno per generare elettricità e alimentare il motore elettrico. A volte si può trovare scritto nelle forme di HFCV (abbreviazione per *Hydrogen Full Cell Vehicle*) o FCV (*Fuel Cell Vehicle*)

BEV (*Battery Electric Vehicle*): Veicoli completamente elettrici che funzionano esclusivamente con batterie ricaricabili, senza motore a combustione interna.

LPG (*Liquefied Petroleum Gas*): Veicoli alimentati a gas di petrolio liquefatto, una miscela di propano e butano. In Italia è conosciuto come GPL (Gas di petrolio liquefatti).

CNG (*Compressed Natural Gas*): Veicoli alimentati a gas naturale compresso, che riducono le emissioni rispetto ai carburanti tradizionali come la benzina o il diesel. In Italia sono comunemente conosciuti come veicoli a metano, o a GNC (Gas Naturale Compresso).

LNG (*Liquefied Natural Gas*): Veicoli alimentati a gas naturale liquefatto, utilizzato principalmente per mezzi pesanti e per ridurre le emissioni di CO². In Italia è conosciuto con il nome di GNL (Gas Naturale liquefatto).

CAPITOLO 1

INTRODUZIONE

Questa tesi magistrale nasce dall'interesse di approfondire le caratteristiche degli acquirenti di automobili elettriche, in quanto siamo in un contesto di cambiamento della mobilità degli ultimi anni. Esiste una crescente esigenza, da parte di governi nazionali, locali e sovranazionali, di avviare una transizione dalla mobilità classica e inquinante a una mobilità nuova e sostenibile.

Questa transizione richiede un cambiamento in termini di strumenti, mezzi, abitudini, comportamenti, atteggiamenti e ideali da parte dei consumatori. L'obiettivo di tale lavoro è analizzare, attraverso un dataset, le variabili di tipo sociodemografico per comprendere chi sono gli acquirenti di automobili elettriche e in che modo si differenziano.

1.1 MOTIVAZIONE DELLA TESI

L'acquisto di automobili elettriche rappresenta una scelta che riflette nuovi ideali legati alla sostenibilità ambientale, ma che può essere influenzata da una varietà di fattori socio-demografici e culturali. Questa tesi magistrale nasce dall'interesse di comprendere chi sono gli acquirenti di questi veicoli e come si differenziano. Questo è cruciale per interpretare i trend attuali e per orientare le strategie di mercato e le politiche pubbliche. L'analisi di questi fattori e trend può aiutare a individuare target utili sia per i rivenditori che per le case automobilistiche, facilitando la profilazione del pubblico nelle loro campagne di marketing. Tale analisi viene condotta su un dataset, con l'intento di prevedere chi potrebbero essere i futuri utilizzatori di automobili elettriche in base alle loro caratteristiche socio-demografiche. È importante da fare una premessa: in questa tesi non si affronterà la questione se le automobili elettriche siano più o meno inquinanti rispetto ai veicoli a combustione interna, veicoli ibridi o a idrogeno. Non

verranno presi in considerazione altre tipologie di veicoli green, come veicoli che utilizzano carburante alternativi, o veicoli a idrogeno. Ci si focalizza invece sull'interesse di approfondire il profilo degli utilizzatori di automobili elettriche ed analizzarne le loro caratteristiche.

Attraverso l'analisi di un dataset socio-demografico, l'obiettivo di questo lavoro è identificare le variabili chiave che determinano le scelte d'acquisto e comprendere come queste differenzino i consumatori, contribuendo così a delineare meglio il quadro di questa evoluzione verso una mobilità più sostenibile.

1.2 OBIETTIVI E IPOTESI DELLA RICERCA

Questo lavoro di tesi si propone di esplorare le dinamiche socio-demografiche che influenzano la decisione di acquistare veicoli BEV (*Battery Electric Vehicle*, veicoli elettrici a batteria). L'obiettivo della ricerca è comprendere come differenti variabili, come reddito, aver posseduto in passato determinate tipologie di veicoli, la sensibilità verso tematiche ambientali, livello di istruzione, ecc. possano influire sull'acquisto di un veicolo elettrico. Sono state elaborate quattro ipotesi di ricerca, in base al dataset utilizzato.

1.2.1 IPOTESI 1 (H1) - INFLUENZA DEL REDDITO SULL'ACQUISTO DI VEICOLI BEV

In che misura il reddito può influire sull'acquisto di una vettura BEV? È corretto affermare che appartenere a una classe sociale superiore aumenta la probabilità di acquistare o possedere un veicolo BEV? L'obiettivo di quest'ipotesi è esaminare se consumatori con un reddito più elevato, o appartenente a una classe sociale superiore, sono più propensi a possedere o acquistare un veicolo elettrico, in quanto dotati di una maggiore disponibilità economica per acquistare un veicolo elettrico (e quali risultano più costosi rispetto ai classici veicoli a combustione interna) e una maggiore propensione verso tecnologie avanzate.

1.2.2 IPOTESI 2 (H2) - INFLUENZA DEL VEICOLO POSSEDUTO IN PRECEDENZA SULL'ACQUISTO DI VEICOLI BEV

La seconda ipotesi prevede tre sotto ipotesi, entrambe cercano di capire come la tipologia di veicolo posseduto in passato possa influire sull'acquisto futuro di un veicolo BEV. L'obiettivo di que-

ste tre ipotesi è indagare se determinati tipi di veicoli posseduti in passato, o attualmente, aumentano o riducono la probabilità di acquistare veicoli elettrici.

- Ipotesi 2.1 (H2.1): possedere o avere posseduto in passato un veicolo PHEV (*plug-in hybrid*) puoi influenzare l'acquisto di un nuovo veicolo BEV? Il veicolo PHEV è visto come un mezzo che permette di sperimentare ed eseguire un primo passo verso il mondo elettrico, in quanto è una tipologia di veicolo che prevede sia un motore a combustione interna e un motore elettrico con una piccola batteria, quindi permette agli utilizzatori di sperimentare l'uso di un veicolo che debba essere ricaricato combinato con la classica esperienza dei motori diesel o benzina. questa sotto ipotesi è utile per capire se questa tipologia di veicoli è veramente utilizzata come passaggio intermedio per poi passare al veicolo elettrico.
- Ipotesi 2.2 (H2.2): come varia la probabilità di acquistare un veicolo BEV in base al possedere un veicolo ICE (*Internal Combustion Engine*, Motori a Combustione Interna), un veicolo HEV (*Hybrid Electric Vehicle*¹) o un veicolo LPG (Veicoli dotati di alimentazione a GPL)?
- Ipotesi 2.3 (H2.3): chi ha posseduto, o possiede, un veicolo BEV ha una maggiore probabilità di acquistarne un altro in futuro rispetto agli utilizzatori di tipologie dei veicoli differenti? Questa sotto ipotesi cerca di esaminare la fedeltà dei consumatori verso la tecnologia dell'auto elettrica, cercando di capire se chi ha già avuto un'esperienza con auto elettrica è più incline a ripetere l'acquisto.

1.2.3 IPOTESI 3 (H3) - INFLUENZA DELLE LUNGHE DISTANZE PERCORSE SULL'ACQUISTO DI VEICOLI BEV

Percorrere lunghe distanze quotidiane o effettuare frequenti viaggi di lunga percorrenza può ridurre la probabilità di acquistare un veicolo BEV? Con l'avvento della mobilità elettrica è nata una nuova tipologia di ansia, l'ansia da ricarica (conosciuta anche come *range anxiety*), che riguarda i proprietari dei veicoli elettrici, i quali temono di non poter raggiungere la destinazione a causa della autonomia limitata o della carenza di infrastrutture di ricarica durante il loro percorso². Di conseguenza, molti potenziali acquirenti rinunciano a comprare una vettura elettrica scoraggiati dal rischio di rimanere "a piedi". Questo timore può derivare da una percezione di inadeguatezza dell'autonomia dei veicoli elettrici rispetto alle loro esigenze di mobilità, in particolare per chi deve percorrere lunghe distanze quotidiane o intraprendere frequenti viaggi.

¹ Per questa analisi verranno presi in considerazione solo i veicolo *Full Hybrid*, ovvero tipologie di autovetture che rispetto ai *Mild Hybrid* sono dotati di una batteria più capiente che li permette di effettuare dei piccoli spostamenti completamente in modalità elettrica

² A2A (2024). *Range anxiety* nell'era della mobilità elettrica

Con questa ipotesi si cerca di capire se la distanza del tragitto giornaliero e i lunghi viaggi possono influenzare la decisione di acquistare un veicolo elettrico, o si tratti soltanto un limite psicologico. Sebbene l'autonomia dei veicoli elettrici sia inferiore rispetto ai tradizionali veicoli a combustione interna, negli ultimi anni si sono registrati significativi progressi tecnologici. L'autonomia media dei veicoli elettrici è aumentata, e sono state sviluppate infrastrutture di ricarica rapida che permettono di ridurre drasticamente i tempi di rifornimento energetico.

1.2.4 IPOTESI 4 (H4) - L'INFLUENZA DELLA SENSIBILITÀ AMBIENTALE SULL'ACQUISTO DI VEICOLI BEV

Le persone che ritengono importante ridurre le emissioni, e che sono particolarmente sensibili ai temi della sostenibilità ambientale, tendono ad essere più propense all'acquisto di un veicolo BEV? Per quest'ultima ipotesi, l'obiettivo è valutare se questa sensibilità ambientale possa essere una valida motivazione che porta all'acquisto di veicoli elettrici, spingendo gli individui a optare per soluzioni di mobilità più sostenibili. Sebbene l'efficienza energetica e i costi di gestione possano giocare un ruolo importante, è plausibile che la percezione di contribuire attivamente alla riduzione dell'impatto ambientale rappresenti un incentivo aggiuntivo per i consumatori attenti alla sostenibilità.

Negli ultimi anni si è osservato un crescente interesse per l'acquisto di veicoli elettrici. Questo trend potrebbe indicare che la sensibilità ambientale è diventata un elemento importante nelle decisioni d'acquisto per una parte della popolazione.

1.3 STRUTTURA DELLA TESI

Il lavoro di questa tesi si svolge in sette capitoli, ognuno di essi è dedicato a un punto cruciale nell'analisi dell'adozione delle automobili elettriche. Il Capitolo 2 offre una panoramica sul settore dell'automotive analizzando l'evoluzione del mercato. Il Capitolo 3 affronta la ricerca del dataset utilizzato, inoltre vengono affrontate le operazioni di pulizia dei dati e della preparazione dei differenti dataset finali ottimizzati per differenti analisi. Successivamente, nei capitoli seguenti, si affrontano le varie analisi del dataset per capire chi sono gli acquirenti di auto elettriche, analizzando le varie correlazioni fra le variabili presenti nel dataset. È stata effettuata un'analisi di regressione logistica e sono state condotte analisi esplorative, come analisi delle corrispondenze multiple e un'analisi cluster. Infine, si affronta il tema dell'apprendimento automatico, con i metodi di *Machine Learning* e *Deep Learning*, utilizzando e confrontando diversi algoritmi per trovare quali di essi abbia un livello migliore di accuratezza nella predizione.

CAPITOLO 2

LA MOBILITÀ DEL FUTURO

2.1 CAMBIO DI MOBILITÀ, CAMBIO DI PARADIGMA

Negli ultimi anni, il settore della mobilità ha iniziato a subire un profondo cambiamento, spinto dall'esigenza di ridurre l'impatto ambientale dei trasporti e di promuovere una transizione verso nuove forme di mobilità più sostenibili. A tal fine, governi nazionali, enti locali e sovranazionali hanno iniziato ad implementare politiche e regolamentazioni finalizzate a incentivare il passaggio dai veicoli tradizionali a combustione interna, alimentati da carburanti fossili come benzina e diesel, verso soluzioni tecnologiche più sostenibili che riducono l'impatto ambientale.

In Italia, ad esempio, sono stati introdotti diversi incentivi per sostenere l'acquisto di veicoli a basse emissioni ed elettrici. Una delle misure utilizzate è stata l'Ecobonus³, un contributo messo a disposizione nel 2024 dal Ministero delle Imprese e del Made in Italy, che prevede un incentivo fino a 13750 € per l'acquisto di veicoli non inquinanti. Tale agevolazione riguarda l'acquisto di automobili elettriche, ibride, o più in generale automobili che abbiano un motore termico che rientra nei limiti di emissioni di CO₂ fino a 135 g/km, nonché di motocicli elettrici e veicoli commerciali elettrici. Oltre all'Ecobonus, nel 2024 sono stati previsti ulteriori incentivi che riguardano questa transizione verso novità più sostenibile, come il bonus per l'installazione di colonnine elettriche di ricarica e il fondo automotive, destinato a favorire la riconversione e lo sviluppo della filiera automobilistica italiana verso una transizione verde. Oltre agli incentivi e alle politiche statali, le varie regioni mettono a disposizione ulteriori risorse, bonus e politiche che sostengono e incentivano questa transizione.

A livello europeo, il Green Deal Europe⁴ rappresenta una delle politiche più rilevanti in materia

3 MISE - Ministero delle imprese e del made in Italy (2024). Ecobonus

4 Commissione Europea. Il Green Deal europeo

di sostenibilità, prevede una serie di iniziative mirate a far raggiungere la neutralità climatica entro il 2050 per l'intera Unione Europea.

Questa transizione non si limita a un cambiamento di natura tecnologica, ma implica una trasformazione significativa, forse il cambiamento più complicato, nelle abitudini, nei comportamenti e negli atteggiamenti dei consumatori.

2.1.1 L'AUTO ELETTRICA

Per affrontare questo cambiamento verso una mobilità più sostenibile, dal punto di vista della mobilità privata, è necessario adottare veicoli che riducano significativamente l'impatto ambientale. Attualmente, esistono diverse tipologie di autovetture alternative ai tradizionali veicoli ICE, tra cui le auto elettriche, che sono al centro di un acceso dibattito.

I veicoli BEV grazie alle loro batterie e motori elettrici permettono di azzerare le emissioni emesse dal veicolo. Tuttavia l'adozione di queste tecnologie impone un cambiamento radicale nel paradigma d'uso dell'automobile, in quanto il processo di rifornimento tradizionale, che avviene ogni determinato numero di chilometri, viene sostituito dalla necessità di pianificare le ricariche.

Mentre alcuni veicoli dotati di un motore diesel possono raggiungere autonomia superiore ai 1,000 km - come nel caso della Mercedes-Benz Classe E 220d, come riporta il giornalista si MotorOne Fabio Gemelli:

“Il grande serbatoio da 66 litri mi ha permesso di percorrere almeno 1,000 km con un pieno in ogni condizione di guida, ma facendo molta attenzione al pedale dell'acceleratore e su percorsi ideali di pianura è possibile avvicinarsi alla soglia dei 2,000 km che rappresentano un record assoluto di percorrenza”⁵

I veicoli BEV attualmente non possono garantire simili autonomie, richiedendo così un cambio di paradigmi nell'approccio alla mobilità.

Secondo le ricerche condotte dall'associazione di settore Motus-E, l'autonomia media in Europa dei nuovi veicoli BEV è aumentata significativamente, passando da 211 km nel 2015 a 350 km nel 2022, segnando un incremento del 65%. Mentre, negli Stati Uniti, nel 2022, i nuovi modelli hanno raggiunto autonomie leggermente più alte con medie di 414 km, con un valore massimo registrato di 800 km⁶. Tuttavia, è doveroso sottolineare che l'autonomia effettiva di un veicolo elettrico può variare in base a numerosi fattori, tra cui le condizioni atmosferiche, rendendo più complicato replicare i valori massimi.

La minore autonomia delle autovetture BEV rispetto alle ICE richiede una maggiore pianificazione e organizzazione, soprattutto per i lunghi viaggi, poiché le stazioni di ricarica non sono così

5 Gemelli Fabio (2024). Mercedes Classe E diesel mild hybrid (2024), la prova dei consumi reali. *Motor1*

6 Quanta autonomia hanno le auto elettriche? *Motus-E*

tanto diffuse come le tradizionali stazioni di rifornimento. Tuttavia, negli ultimi anni il tasso di crescita delle colonnine di ricarica è aumentato notevolmente, nel 2024 si sono raggiunti quasi 55.000 punti di ricarica in Italia, con un incremento del 31,5% registrato nel primo trimestre rispetto al 2023. Oltre alla diffusione, negli ultimi anni le stazioni di ricarica si sono evolute, offrendo diverse tipologie di colonnine con potenze differenti per ricariche veloci: ad esempio, lungo i tragitti autostradali si possono trovare delle colonnine di ricarica ultra rapida, come le High Power Charging della rete Free To X, che possono arrivare fino a 400 kW di potenza.

Dal punto di vista dell'efficienza energetica, i veicoli BEV garantiscono un'efficienza maggiore rispetto ai veicoli ICE, con un'efficienza che varia tra l'80% e il 90%, rispetto a un 20-35% di un motore a combustione interna. Parallelamente ai veicoli elettrici, negli anni si sono sviluppate soluzioni ibride che combinano i vantaggi del motore elettrico con le comodità di un motore a combustione interna. Sul mercato possiamo trovare veicoli *Micro*, *Mild*, *Full Hybrid* e *Plug-in Hybrid*. Sebbene queste soluzioni abbiano dei piccoli motori elettrici e piccole batterie non possono essere viste come declinazioni delle vetture BEV, esse rappresentano piuttosto un'evoluzione dei veicoli ICE in quanto migliorano la loro efficienza, abbassando il loro impatto ambientale.

I veicoli HEV, ovvero la tipologia di ibrido *Full*, può avere un tasso di efficienza del 40-50%, mentre nelle tipologie di veicoli *Mild* e *Micro Hybrid* il tasso di efficienza è inferiore. Mentre, i veicoli ibridi PHEV offrono un'efficienza maggiore, che varia da un minimo del 30% a un massimo di un 60%⁷ di efficienza seconda dell'utilizzo. Tuttavia, in alcuni casi l'efficienza di questi veicoli può risultare inferiore a quella delle vetture HEV, soprattutto se la loro parte elettrica non viene utilizzata appieno, non ricaricando le batterie e utilizzando il veicolo esclusivamente con il motore a combustione (in questo caso il veicolo plugin risulterà più pesante di un normale ICE, in quanto è dotato sia di motore a combustione, che di batterie e motore elettrico, il che richiederà più energia da parte del motore)⁸.

Nonostante questi progressi tecnologici, il passaggio alla mobilità elettrica richiede una significativa trasformazione culturale. I consumatori devono modificare le loro abitudini nell'utilizzo dell'automobile, sviluppando competenze organizzative per gestire e pianificare le ricariche e i propri spostamenti. Di conseguenza, la diffusione delle auto elettriche non rappresenta solo un cambiamento tecnologico è una riconfigurazione dell'infrastrutture esistenti, ma anche un processo di innovazione sociale.

2.1.2 L'AUTO A IDROGENO

Poiché l'adozione dell'auto elettrica comporta un cambiamento significativo di abitudini, si è cominciato a discutere della tecnologia dell'idrogeno. Questa tipologia di veicoli, pur avendo delle

7 Electric vehicle (EV) and driving towards sustainability: Comparison between EV, HEV, PHEV, and ICE vehicles to achieve net zero emissions by 2050 from EV

8 Angi Nicodemo (2022). Auto ibride plug-in: cariche o non cariche, questo è il dilemma. *Al Volante*

batterie, non richiede il cambio del paradigma richiesto dai veicoli elettrici, poiché la ricarica, o meglio rifornimento, avviene in apposite stazioni in tempi brevissimi, simili a quelli necessari per il rifornimento dei veicoli ICE. Il rifornimento consente di immagazzinare l'idrogeno in appositi serbatoi, per poi essere usato per caricare le batterie e alimentare il motore. L'idrogeno (H_2) utilizzato entra in contatto con l'aria (O) generando acqua (H_2O); infatti dai tubi di scarico delle automobili FCEV viene emessa acqua e non sostanze inquinanti. Questa tecnologia risulterebbe come l'opzione più pratica per una transizione verde con cambiamenti strutturali minimi, e unirebbe i vantaggi delle auto BEV con quelli delle auto ICE.

Oltre alla facilità di utilizzo, un ulteriore vantaggio di questa tecnologia risiede nella sua efficienza rispetto ad un motore ICE. L'idrogeno è un combustibile con una densità energetica elevata: 1kg di idrogeno contiene la stessa energia di 2,4 kg di metano o 2,8 kg di benzina.

Inoltre, i veicoli FCEV sono caratterizzati da un'efficienza di conversione, in quanto fino al 60% dell'energia chimica dell'idrogeno viene convertita in energia motrice per il veicolo, a fronte di un rendimento meccanico di motori termici, come quelli a benzina o gasolio, oscilla tra il 20% e il 35%. Tutto questo senza che l'automobile emetta CO_2 .

Nonostante ciò, i principali ostacoli all'adozione su larga scala di questa tecnologia sono legati ai suoi costi elevati e alla scarsità dei modelli di autovetture a idrogeno presenti sul mercato. Anche l'infrastruttura risulta essere un punto problematico di questa tecnologia, in quanto risulta, nel nostro paese, molto limitata. Sebbene le prime problematiche possano essere mitigate, il vero limite di questa tecnologia è nella sua produzione, poiché l'idrogeno non è presente in natura e deve essere prodotto. La produzione può avvenire con diversi metodi, principalmente tramite il reforming del metano o la gassificazione del carbone, i quali sono processi molto inquinanti che rilascia una notevole quantità CO_2 . Altri metodi sono la gassificazione delle biomasse o la scissione termodinamica dell'acqua mediante centrali nucleari o solari. Tra le opzioni sostenibili, troviamo la produzione di idrogeno verde, ottenuto tramite elettrolisi dell'acqua utilizzando esclusivamente energia rinnovabile, come l'eolico o il solare, evitando emissioni di CO_2 ⁹.

Oltre ai problemi legati alla produzione, l'efficienza dell'idrogeno nei confronti del motore elettrico è inferiore in termini di energia convertita. Come riportato da Zang, Fang e Sun:

“Regarding energy conversion, the final efficiency of HFCVs is only 25%–35%, while that of EVs can reach 70%–90%. On balance, hydrogen is not suitable for large-scale use as the power raw material of fuel cell vehicles. It causes HFCVs unable to replace fuel vehicles.”¹⁰

9 Tatiane da Silva Veras, et. al. (2017). Hydrogen: Trends, production and characterization of the main process worldwide. *International Journal of Hydrogen Energy*, 42, pp. 2018-2033.

10 Wenye Zhang, et. al. (2023). The alternative path for fossil oil: Electric vehicles or hydrogen fuel cell vehicles?. *Journal of Environmental Management*, 341, pp. 1-11

In termini di efficienza, i veicoli BEV presentano un rendimento energetico migliore, ossia del 70-90%, mentre per i veicoli FCEV l'efficienza varia dal 25% al 35%. Vista questa inefficienza, alcuni esperti suggeriscono che per ora l'idrogeno non possa sostituire i veicoli elettrici nella transizione verde, soprattutto per le automobili che circolano in città. Tuttavia, questa tecnologia può rappresentare una valida soluzione per i mezzi pesanti, come navi e camion, che necessitano di elevate autonomie di viaggio.

Per questi motivi, il lavoro di questa tesi si concentrerà soltanto sulle auto elettriche, tralasciando i veicoli a idrogeno.

2.2 L'ANDAMENTO DEL MERCATO DEI VEICOLI ELETTRICI IN ITALIA

2.2.1. UNA FOTOGRAFIA DEL CAMBIAMENTO IN ITALIA

In Italia, secondo l'ultimo aggiornamento dei dati elaborati dall'Osservatorio Europeo dei Combustibili Alternativi del 15 gennaio 2025, sono presenti complessivamente 44,442,469 veicoli leggeri, classificati come M1 e N1, rispettivamente autovetture e veicoli commerciali leggeri. Di questi, soltanto 4,456,522 sono alimentati con carburanti alternativi, rappresentando il 9.63% della flotta totale italiana.




Figura 1. Distribuzione di autovetture a carburante alternativo (veicoli M1 e N1)




Figura 2. Distribuzione di autovetture elettriche (M1 e N1) di nuova immatricolazione nel 2024

L'Unione Europea classifica come veicoli con carburanti alternativi i veicoli elettrici a batteria (BEV), i veicoli ibridi plug-in (PHEV), i veicoli a idrogeno (H2), i veicoli a gas di petrolio liquefatto (LPG, noto in Italia come GPL), i veicoli a gas naturale liquefatto (LNG) e i veicoli a gas naturale compresso (CNG).

Per quanto riguarda le nuove immatricolazioni di veicoli elettrici M1 e N1, in Italia nel 2024 sono stati registrati 69,416 nuovi veicoli elettrici e 52,379 veicoli ibridi plugin, che rappresentano, rispettivamente il 57% e il 43%. Negli ultimi anni si è osservato un aumento progressivo nel numero di nuove immatricolazioni di veicoli elettrici, con una significativa accelerazione a partire dal 2019, quando il numero di unità elettriche vendute è passato da 23 mila unità a 132 mila unità nel 2021, fino alle 303 mila unità nel 2024. Le vendite di veicoli ibridi plug-in seguono un trend simile, evidenziando un incremento consistente nello stesso periodo. Dai dati dell'osservatorio della Commissione Europea emerge che i veicoli a idrogeno sono ancora in una fase embrionale in Italia, con un numero di immatricolazioni molto basso. Questa situazione è dovuta a vari fattori, tra cui l'elevato costo dei veicoli a idrogeno e la scarsità di infrastrutture per il rifornimento, che attualmente si limita a due distributori aperti al pubblico, situati a Bolzano e Mestre.

Infine, per quanto riguarda i veicoli LPG e CNG, essi inizialmente hanno rappresentato e trainato i veicoli caratterizzati da combustibili alternativi in Italia, mostrando una crescita continua e moderata. Tuttavia, negli ultimi anni questa crescita ha subito un rallentamento, dovuto principalmente alla presenza di nuove alternative sul mercato, come i veicoli micro (prima, ora scomparsi dal mercato), *mild e full hybrid*. Inoltre, molte case automobilistiche hanno progressivamente ridotto l'offerta facendo uscire di produzione i modelli alimentati a GPL e GNC, contribuendo al calo delle vendite di queste tipologie di veicoli.

2.2.2 IL RALLENTAMENTO DEL MONDO DELL'ELETTRICO

Nonostante una crescita iniziale significativa, il mercato dei veicoli elettrici e dei veicoli ibridi plug-in ha mostrato segnali di rallentamento negli ultimi mesi. Questo fenomeno non riguarda solo l'Italia, ma interessa anche altri Paesi europei e americani, con un calo consistente delle immatricolazioni. In Europa, ad esempio, nel mese di agosto 2024, le immatricolazioni di veicoli elettrici all'interno dell'Unione Europea sono diminuite del 43.9% rispetto allo stesso periodo dell'anno precedente, passando da 165,000 a 92,000 unità vendute. In particolare, la Germania, che rappresenta il mercato automobilistico più grande dell'UE, ha registrato un calo del 68.8%, seguita dall'Italia con una riduzione del 40.9%, dalla Francia con un calo del 33.1% e dalla Spagna con una contrazione del 24.8%.

In generale, questa crisi ha caratterizzato tutto il settore automobilistico, infatti notiamo un calo generale di vendita di nuovi veicoli, ma questo è particolarmente evidente per i veicoli elettrici. Le cause principali di questo rallentamento sono legate ai prezzi elevati dei veicoli elettrici, che risultano me-

diamente superiori del 40-50% rispetto ai veicoli a combustione interna. E in un contesto di recessione economica e instabilità finanziaria, questi prezzi alti scoraggiano notevolmente i consumatori all'acquisto di questa tipologia di automobili. Inoltre, i veicoli elettrici attualmente tendono a svalutarsi molto rapidamente, fino al 50% in meno di tre anni dall'acquisto. Infine, a questi fattori si aggiunge la carenza di infrastrutture di ricarica in molti paesi europei, che rappresenta un ulteriore ostacolo alla diffusione dei veicoli appartenenti al mondo dell'elettrico.

Rimanendo sempre in Europa, ma al di fuori dell'Unione Europea, possiamo trovare una controtendenza nel Regno Unito, che ha registrato un aumento dell'immatricolazione dei veicoli elettrici del 10,8% rispetto allo stesso periodo estivo del 2023. Questo incremento è dovuto ai forti sconti praticati dai concessionari per smaltire la giacenza di veicoli elettrici invenduti. Di conseguenza, si può dedurre che il grande rallentamento del mondo dell'elettrico non sia dovuto a una mancanza di interesse da parte dei consumatori, ma piuttosto dai costi elevati di questa tecnologia.

In sintesi, il settore dei veicoli elettrici in Europa sta affrontando un periodo critico, caratterizzato da sfide economiche e infrastrutturali che devono essere superate, come dichiarato dall'Acea, la associazione dei costruttori di automobili europei (Association des constructeurs européens d'automobiles), e senza interventi mirati a superare questo periodo di flessione delle immatricolazioni di veicoli elettrici, la transizione verso la neutralità climatica rischia di rallentare compromettendo gli obiettivi ambientali dell'Unione Europea¹¹.

11 ACEA (2024). European auto industry calls for urgent action as demand for EVs declines

CAPITOLO 3

IL DATASET: LA RACCOLTA E LA PREPARAZIONE DEI DATI

3.1 FONTE DEL DATASET E LE SUE CARATTERISTICHE

Molte analisi volte a comprendere le caratteristiche degli utilizzatori di auto elettriche iniziano identificando gli individui in possesso di un veicolo elettrico attraverso i registri della motorizzazione. Successivamente, si effettua un campionamento per raccogliere dati socio-demografici, necessari per svolgere analisi statistiche. Tuttavia, in questo lavoro di tesi, questa fase preliminare è stata saltata, poiché il reperimento delle informazioni presso la motorizzazione, la costruzione di una lista di campionamento, il campionamento e la raccolta dei dati avrebbe richiesto un tempo notevole. Per tale motivo, è stato utilizzato un già esistente, composto da dati socio demografici relative ai possessori di veicoli elettrici.

Il dataset utilizzato, chiamato “Sociodemographic data for battery electric vehicle owning households in California”, è stato creato nel 2019 da Scott Hardman, ricercatore associato e assistente direttore presso l’Electric Vehicle Research Center dell’Università di UC Davis. Questo dataset è stato originariamente creato per la ricerca intitolata “Understanding the Early Adopters of Fuel Cell Vehicles”, condotta in collaborazione con il National Center for Sustainable Transport (NCST) e la UC Davis, con lo scopo di comprendere le caratteristiche dei primi utilizzatori di veicoli alimentati a idrogeno, i cosiddetti veicoli a celle combustibili (*Fuel Cell*).

È importante evidenziare che il dataset in questione, è stato creato per analizzare i veicoli a celle combustibile rispetto ai veicoli elettrici e ibridi, motivo per cui non contiene dati relativi ai possessori di vetture combustioni interna. I dati sono stati raccolti attraverso un questionario online dal centro di ricerca dell’UC Davis, i partecipanti a questa ricerca sono stati reclutati tramite indirizzi e-mail raccolti

dal Centro per l'Energia Sostenibile (CSE), in seguito alla loro domanda di richiesta di incentivi per il California Clean Vehicle Rebate Project.

Lo studio si concentra in California, poiché è l'unico stato degli Stati Uniti dove i veicoli a celle combustibili erano disponibili per la vendita, inoltre la California rappresenta il principale mercato globale per questa tipologia di veicoli.

Il dataset è composto da 27,021 casi e 27 variabili.

Variabili del dataset:

1. id. Response ID,
2. submitdate. Date,
3. submitted Month,
4. Year[subm...Date submitted],
5. Month[Month Yea...ate submitted]],
6. Year[Month Year...ate submitted]],
7. lastpage. Last page,
8. Carmain,
9. Previous PHEVs,
10. Previous BEVs,
11. Previous HEVs
12. Previous CNGs,
13. Previous ICEs,
14. Household Income,
15. Importance of reducing greenhouse gas emissions (-3 not important, 3 important),
16. Home ownership (own 1),
17. Home Type (detached 1),
18. Highest Level of Education,
19. Longest trip in the last 12 months,
20. Number of trips over 200 miles in the last 12 months,
21. One-way commute distance,
22. Number of people in the household,
23. Age,
24. Gender (Male 1),
25. Number of vehicles in the household,
26. Annual VMT Estimate,
27. FCV, BEV Dummy.

3.2 PULIZIA E CORREZIONE DEI DATI MANCANTI

Per una prima analisi iniziale del dataset e per le operazioni di pulizia e correzioni dati mancanti, è stato utilizzato il software open source OpenRefine. In questa prima fase iniziale, le variabili relative all'ID del rispondente, alla data, al mese e all'anno di compilazione del questionario da parte delle rispondente sono state rimosse, poiché non sono rilevanti a questo tipo di ricerca. Inoltre, è stata eliminata la variabile FCV, BEV Dummy, creata dal ricercatore per identificare i veicoli a idrogeno rispetto ai veicoli elettrici, dato che questa tesi si concentra esclusivamente su veicoli a propulsione elettrica. Le restanti variabili sono state tradotte in italiano per maggiore facilità nella ricerca. A seconda delle diverse tipologie di analisi da effettuare per questo lavoro di tesi, è emersa la necessità di creare diversi tipi di dataset da poter utilizzare per diverse tipologie di analisi. Ad esempio, è stato realizzato un dataset convertito, in cui le modalità di risposta sono state convertite in valore numerico, utile per la fase di apprendimento automatico, questo dataset è chiamato `dataset_conv`.

È stato creato anche un dataset in cui le variabili qualitative sono state trasformate in variabili dicotomiche, utile per svolgere un'analisi di regressione logistica, questo dataset è chiamato `dataset_dummy`. Infine è stata creata una terza versione chiamata `dataset_originale`, il cui le variabili dicotomizzate nel precedente dataset sono presenti sottoforma di variabile qualitative. Come anticipato precedentemente, oltre a rimuovere le variabili non inerenti all'analisi e a tradurle, sono state condotte delle operazioni di trasformazione delle variabili per adattare all'analisi condotta.

3.2.1 *VARIABILE CARMAIN*

Partendo dalla variabile Carmain, che rappresenta i modelli di automobili possedute dai rispondenti, le risposte sono state codificate dal ricercatore in tre elementi: anno del veicolo, marca e modello (ad esempio, "2017 Honda Clarity"). In alcuni casi è stata aggiunta da parte del ricercatore anche la tipologia del veicolo (come FCEV, BEV), ad esempio "2018 Honda Clarity Fuel Cell". A partire da questa variabile, per questo lavoro di tesi è stata effettuata una ricerca su tutti i modelli presenti nel dataset per identificare e classificare correttamente i veicoli e la loro tipologia. Spesso erano presenti errori di battitura o mancava l'indicazione della tipologia del veicolo; tramite questa ricerca è stato possibile correggere tali errori e creare una nuova variabile che identificasse esclusivamente la tipologia dell'auto, chiamata "Tipologia di auto attuale", con le seguenti categorie di risposta: BEV, FCEV, HEV e PHEV. Da questa nuova variabile qui è stata creata la variabile "BEV Dummy", che distingue esclusivamente i veicoli elettrici da tutti gli altri, ed è stata inserita esclusivamente nel `dataset_dummy`.

Le variabili nei diversi dataset sono strutturate come segue:

- `dataset_dummy`: BEV_dummy, dicotomica (si: 1, no: 0)
- `dataset_originale`: Tipologia di auto attuale, qualitativa (BEV, FCEV, PHEV e HEV)

- `dataset_conv`: creazione di 4 variabili binarie “Tipologia di auto attuale” con codifica (si: 1, no: 0) per: BEV, PHEV, HEV, FCEV

Inoltre, le risposte originarie della variabile `Carmain` sono state uniformate in una nuova variabile denominata “Auto”, da cui è stato rimosso l’anno del veicolo, poiché non rilevante per la ricerca. Questa variabile è stata utilizzata per un’analisi generale del dataset, ma non sarà inclusa nelle successive analisi statistiche.

3.2.2 *VARIABILI PREVIOUS...*

Le variabili `Previous PHEVs`, `Previous BEVs`, `Previous HEVs`, `Previous CNGs`, e `Previous ICEs` inizialmente si presentano nel dataset come singole variabili di dicotomiche, che successivamente sono state accorpate in nuova variabile “Tipologia di auto precedente”. Per il `dataset_dummy`, come per la variabile precedente, sono state generate variabili dummy, queste variabili assumono il valore di 1 quando l’auto precedente possiede la caratteristica indicata, e 0 quando non la possiede, rispetto ad una auto ibrida plugin, in quanto è un’ipotesi di ricerca della tesi. Per quanto riguarda il `dataset_conv` e il `dataset_originale`, queste variabili non sono presenti come entità distinte, ma sono rappresentate sotto forma di un’unica variabile qualitativa.

La struttura delle variabili nei vari dataset è la seguente:

- `dataset_dummy`: la variabile “Auto precedente” è suddivisa in dicotomiche (Auto precedente BEV vs PHEV, Auto precedente HEV vs PHEV, Auto precedente GNC vs PHEV, Auto precedente ICE vs PHEV), con codifica (si: 1, no: 0).
- `dataset_originale`: “Auto precedente” è una variabile qualitativa categoriale che può assumere le seguenti modalità: BEV, ICE, PHEV, GNC, HEV.
- `dataset_conv`: creazione di 5 variabili binarie “Auto precedente” con codifica (si: 1, no: 0) per: BEV, ICE, PHEV, GNC, HEV.

3.2.3 *VARIABILE HOUSEHOLD INCOME*

Per la variabile `Household Income`, che apparentemente è quantitativa, è emerso un problema: i valori che assume non sono continui, bensì suddivisi in undici categorie. Questo risulta insolito per una variabile che rappresenta il reddito, suggerendo che durante la raccolta dei dati ai partecipanti sia stato richiesto di indicare il reddito familiare in fasce, oppure che il ricercatore abbia successivamente classificato i redditi in classi.

Per affrontare questa problematica, è stata creata una nuova variabile qualitativa denominata “Classe Reddito Familiare”, che suddivide i rispondenti in diverse categorie di reddito: molto basso, basso, medio, alto, molto alto ed estremamente alto. Le classi sono state definite in base a uno studio del Pew Re-

search Center, che identifica le famiglie appartenenti alla classe media che abbiano un reddito compreso tra i due terzi e il doppio del reddito mediano. Inoltre, secondo le linee guida del *U.S. Census Bureau* e del *Department of Housing and Urban Development*, sono state individuate ulteriori categorie di reddito inferiore rispetto alla classe media, ovvero:

- *Extremely Low Income*: redditi inferiori a un terzo del reddito mediano.
- *Very Low Income*: redditi tra un terzo e la metà del reddito mediano.
- *Low to Moderate Income*: redditi tra la metà e i due terzi del reddito mediano.

Sopra la classe media, le famiglie con redditi elevati sono suddivise in:

- *High Income*: redditi tra il doppio e il triplo del reddito mediano.
- *Very High Income*: redditi fino a cinque volte il reddito mediano.
- *Extremely High Income*: redditi superiori a cinque volte il reddito mediano.

Secondo i dati di *Statista*, il reddito mediano in California nel 2019, anno in cui sono stati rilevati i dati relativi di questo dataset, era di 78,105 \$, tuttavia, il reddito mediano risulta di 175,000 \$, il che suggerisce che i casi presenti nel campione rappresentano una popolazione con un reddito significativamente più elevato rispetto alla media californiana. Sulla base di questi dati, è stato possibile suddividere le classi di reddito nel seguente modo:

- Estremamente Bassa: < 23,431.50 \$
- Molto Bassa: 23,431.50 \$ - 39,052.50 \$
- Bassa: 39,052.50 \$ - 58,578.75 \$
- Media: 58,578.75 \$ - 156,210.00 \$
- Alta: 156,210.00 \$ - 234,315.00 \$
- Molto Alta: 234,315.00 \$ - 390,525.00 \$
- Estremamente Alta: > 390,525.00 \$

In base ai casi presenti le modalità che può assumere questa variabile sono soltanto: bassa, media, alta, molto alta ed estremamente alta, in quanto non sono presenti i casi con un reddito inferiore a 39.052,50 \$.

La struttura delle variabili nei diversi dataset è la seguente:

- `dataset_dummy`: la variabile “Classe Reddito Familiare” è suddivisa in dicotomiche (Bassa vs Media, Alta vs Media, Molto Alta vs Media, Estremamente Alta vs Media), con codifica binaria (sì: 1, no: 0).
- `dataset_originale`: “Classe Reddito Familiare” è una variabile qualitativa categoriale che può assumere le seguenti modalità: Bassa, Media, Alta, Molto Alta ed Estremamente Alta.
- `dataset_conv`: “Classe Reddito Familiare” è trattata come variabile quantitativa con le se-

guenti codifiche numeriche: Bassa: 1, Media: 2, Alta: 3, Molto Alta: 4, Estremamente Alta: 5.

3.2.4 *VARIABLE HIGHEST LEVEL OF EDUCATION*

Il ricercatore ha utilizzato la variabile “Highest Level of Education” per registrare il livello di istruzione dei rispondenti, codificando le risposte sotto forma numerica, con valori che vanno da 1 a 4, dove 4 rappresenta il livello massimo. Sebbene i dati siano stati originariamente raccolti in forma numerica, grazie allo studio condotto da Scott, “Understanding the Early Adopters of Fuel Cell Vehicles” è stato possibile di identificare le categorie corrispondenti a ciascun valore:

- Valore 1: “Grade 8 or Less and Some High School”, ovvero coloro che non hanno completato il diploma di scuola superiore.
- Valore 2: “High School Graduate and Some College”, riferito a chi ha conseguito il diploma di scuola superiore o ha iniziato il college senza completarlo.
- Valore 3: “College Graduate and Some Graduate School”, che identifica chi ha ottenuto una laurea o ha iniziato corsi post-laurea senza portarli a termine.
- Valore 4: “Masters, Doctorate or Professional Degree”, che si riferisce a chi ha completato studi avanzati, come master, dottorato o un diploma professionale.

Tuttavia, trattandosi di una variabile che misura il livello di istruzione, risulta più adeguato trattarla come qualitativa, poiché la sua interpretazione in termini quantitativi potrebbe generare confusione o errori. Di conseguenza, è stata ricodificata da valori numerici a classi descrittive.

Come avvenuto per la variabile delle classi di reddito, nel dataset_dummy il livello di istruzione alto è stato utilizzato come riferimento, creando tre variabili che confrontano i diversi livelli di istruzione rispetto a quello alto.

La struttura delle variabili nei diversi dataset è la seguente:

- dataset_dummy: la variabile “Livello di istruzione” è suddivisa in dicotomiche (Licenza Media vs Laurea di Il livello o Dottorato, Diploma o Qualifica Professionale vs Laurea di Il livello o Dottorato, Laurea di I livello vs Laurea di Il livello o Dottorato), con codifica binaria (sì: 1, no: 0).
- dataset_originale: “Livello di istruzione” è una variabile qualitativa categoriale che può assumere le seguenti modalità: Licenza Media, Diploma o Qualifica Professionale, Laurea di I livello, Laurea di Il livello o Dottorato.
- dataset_conv: “Livello di istruzione” è trattata come variabile quantitativa con le seguenti codifiche numeriche: Licenza Media: 1, Diploma o Qualifica Professionale: 2, Laurea di I livello: 3, Laurea di Il livello o Dottorato: 4.

3.2.5 *VARIABILE AGE*

La variabile “Age”, come per la variabile “Household Income”, non presenta valori continui, ma è suddivisa in 8 categorie: 18, 25, 35, 45, 55, 65, 75 e 80. Questo indica che il ricercatore ha suddiviso le risposte in fasce d’età, ad esempio: da 18 a 24 anni per la prima classe, da 25 a 34 per la seconda, e così via fino alla fascia degli over 80. Oltre alla traduzione del nome della variabile in “Età”, i valori sono stati riclassificati nelle seguenti categorie d’età:

- <25 per 18,
- 25-34 per 25,
- 35-44 per 35,
- 45-54 per 45,
- 55-64 per 55,
- 65-74 per 65,
- 75-79 per 75,
- >80 per 80.

Nel dataset_dummy, essendo una variabile categoriale, sono state create tante variabili dummy quante sono le categorie che può assumere, meno una. Di conseguenza, per questa variabile, sono state generate sette nuove variabili dicotomiche, in quanto la variabile originale comprende otto categorie. Le sette variabili, così create, sono confrontate con la categoria di riferimento, ovvero la classe d’età 45-54, selezionata come riferimento poiché rappresenta la fascia più numerosa nel campione.

- dataset_dummy: la variabile “Classe d’età” è suddivisa in dicotomiche (Classe d’età: <25 vs 45-54, Classe d’età: 25-34 vs 45-54, Classe d’età: 35-44 vs 45-54, Classe d’età: 55-64 vs 45-54, Classe d’età: 65-74 vs 45-54, Classe d’età: 75-79 vs 45-54, Classe d’età: >80 vs 45-54), con codifica binaria (sì: 1, no: 0).
- dataset_originale: “Classe d’età” è una variabile qualitativa categoriale che può assumere le seguenti modalità: <25, 25-34, 35-44, 45-54, 55-64, 65-74, 75-79, >80.
- dataset_conv: “Classe d’età” è trattata come variabile quantitativa con le seguenti codifiche numeriche: <25: 1, 25-34: 2, 35-44: 3, 45-54: 4, 55-64: 5, 65-74: 6, 75-79: 7, >80: 8.

3.2.6 *RIMANENTI VARIABILI*

Per le restanti variabili non sono state apportate correzioni o modifiche, ma sono state semplicemente tradotte. Le nuove variabili tradotte, come “Casa di proprietà” e “Casa indipendente”, sono di tipo dicotomico e assumono valore 1 quando la caratteristica è presente e 0 quando è assente. La variabile “Genere” (Gender Dummy) assume valore 1 quando il rispondente è di sesso maschile e valore 0

quando è di sesso femminile.

Per quanto riguarda le variabili quantitative, come “Il viaggio Più Lungo negli Ultimi 12 Mesi”, “Numero di Viaggi Superiori a 200 Miglia negli Ultimi 12 Mesi”, “Distanza Casa-Lavoro”, “VMT Anno”, “Numero di Persone in Famiglia”, “Numero di Auto in Famiglia”, e la “Importanza di ridurre le emissioni di gas serra”, queste rimangono inalterate nei tre dataset.

3.3 PREPARAZIONE DEI TRE DATASET FINALI PER LE ANALISI

Dopo aver modificato le variabili per i diversi dataset, è stato possibile procedere con l'esportazione dei dataset da OpenRefine per analizzarli. Prima di esportarli, è stata condotta una breve analisi per verificare se tutte le variabili contenessero le risposte complete dei partecipanti. Questa analisi ha permesso di individuare eventuali risposte mancanti. Su un totale di 27,021 rispondenti, solo 10,694 hanno risposto a tutte le domande. Ciò significa che per circa 16,000 partecipanti mancavano dei dati, probabilmente a causa di risposte non fornite dai partecipanti o di errori nell'inserimento da parte del ricercatore. Data la quantità significativa di risposte mancanti, si è deciso di rimuovere questi 16,000 rispondenti dal dataset. Spesso mancavano risposte a più domande per un singolo partecipante (quindi, per ogni caso ce ne erano più valori mancanti), il che avrebbe potuto compromettere l'accuratezza dell'analisi. È stato deciso di non procedere con l'inserimento di valori medi al posto di quelli mancanti, in quanto avrebbe potuto introdurre distorsioni nei risultati, di conseguenza si è optato per escludere i rispondenti con dati incompleti.

Dopo la pulizia dei dati e le modifiche necessarie alle variabili, tutti e tre i dataset sono stati esportati in formato CSV, in modo da poter essere interrogati e utilizzati all'interno del software Google Colab per ulteriori analisi e modelli statistici utilizzando il linguaggio python.

Infine, a partire dal “dataset_originale” è stato ricavato un ulteriore dataset denominato “dataset_edu”, utilizzato per le analisi esplorative di analisi cluster e analisi delle corrispondenze multiple. Questo dataset non è stato creato con OpenRefine, che è stato utilizzato solo nelle fasi iniziali, ma è stato creato successivamente su Google Colab. In questa fase, le variabili quantitative, come il “VMT annuo”, il “Viaggio più lungo negli ultimi 12 mesi”, il “Numero di viaggi superiori a 200 miglia negli ultimi 10 mesi”, la “Distanza casa-lavoro”, il “Numero di persone in famiglia”, il “Numero di auto in famiglia”, la “Età” e la “Importanza di ridurre le emissioni di gas serra”, sono state convertite in variabili qualitative ordinali per consentire analisi esplorative volte a individuare pattern. Il processo di trasformazione di queste variabili in dati ordinali verrà trattato più approfonditamente nel Capitolo 6, dedicato alle analisi esplorative.




Figura 3. Schema di lavoro e destinazione dei tre differenti dataset

CAPITOLO 4

ANALISI PRELIMINARI

4.1 IL DATASET E LE SUE CARATTERISTICHE: ANALISI UNIVARIATA

Nel dataset, come anticipato nel Capitolo precedente, sono stati rimossi 16.000 casi, passando da un totale di 27,021 a 10,688 casi in ciascuno dei tre nuovi dataset. Per facilitare il processo di analisi, le variabili nel dataset sono state organizzate secondo una gerarchia precisa. Inizialmente, sono presenti le variabili del gruppo socio-demografico, che include il “genere”, la “classe d’età”, la “classe di reddito familiare”, il “livello di istruzione”.

Il secondo gruppo comprende le variabili abitative, che include le variabili “casa di proprietà”, “casa indipendente”, “numero di persone in famiglia” e “numero di auto in famiglia”.

Il terzo gruppo, sebbene non costituisca un vero e proprio gruppo, è composto soltanto dalla variabile “importanza di ridurre le emissioni di gas serra”, che riflette l’attenzione del rispondente verso le tematiche ambientali e di sostenibilità.

Il quarto gruppo, classe veicolare, riguarda le tipologie di veicoli e include la variabile “tipologia di veicolo attuale” e la variabile “tipologia di veicolo precedente” (è importante sottolineare che nella seconda variabile sono presenti quasi tutte le tipologie di veicoli, a differenza della prima. Questo perché sono stati intervistati esclusivamente i rispondenti che hanno acquistato veicoli a basso impatto ambientale, come elettrici, ibridi, ibridi plug-in e celle a combustibile a idrogeno, escludendo pertanto i possessori di veicoli con motore a combustione interna, poiché la ricerca si concentra su queste categorie).

Infine, il quinto gruppo di variabili richiama la mobilità e la percorrenza e comprende le variabili: “viaggio più lungo negli ultimi 12 mesi”, “numero di viaggi superiori a 200 miglia negli ultimi 12 mesi”, la variabile “distanza casa lavoro” e la variabile “VMT annuo”.

<i>Gruppo di variabili</i>	<i>Variabili</i>
<i>Variabili socio-demografiche</i>	Genere Classe d'età Classe di reddito Livello di Istruzione
<i>Variabili abitative</i>	Casa di proprietà Casa indipendente Numero di persone in famiglia Numero di auto in famiglia
<i>Variabile sensibilità ambientale</i>	Importanza di ridurre le emissioni di gas serra
<i>Variabili classe veicolare</i>	Tipologia di auto attuale Tipologia di auto precedente
<i>Variabili di mobilità e percorrenza</i>	Viaggio più lungo negli ultimi 12 mesi Numero di viaggi superiori a 200 miglia negli ultimi 12 mesi Distanza casa-lavoro VMT annuo

Tabella 1. Schema riassuntivo delle variabili nel dataset

4.1.1 VARIABILI SOCIO-DEMOGRAFICHE

Le variabili socio-demografiche analizzate includono il genere, la classe d'età, la classe di reddito e il livello di istruzione. Nel dataset, i casi sono suddivisi in 2,658 donne e 7,969 uomini, corrispondenti rispettivamente al 25% e al 75% del totale.




Figura 4. Grafico a torta: distribuzione della variabile "Genere"

Come già anticipato nel precedente Capitolo (precisamente, nel Sottoparagrafo 3.2.5.) la variabile “Classe d’età” è stata trattata come una variabile qualitativa, suddivisa in otto classi. Dalla Figura 5, si può notare che le classi maggiormente rappresentate sono le tre classi che variano tra i 35 e i 74 anni. In particolare, le fasce d’età 45-54 e 55-64 sono le più numerose, con una percentuale rispettivamente del 27.2% e del 26.0%. Insieme, queste due classi costituiscono oltre la metà del campione, esattamente il 53.2%. La classe d’età 35-44 è la terza più rappresentata, con il 19.2% del totale.




Figura 5. Grafico a barre: distribuzione della variabile “Classe d’età”

Nel dataset possiamo notare che nel 36.4% dei casi i rispondenti al questionario dichiarano di appartenere alla classe media, il cui reddito varia tra i 60,000 e i 160,000 dollari. La seconda classe più rappresentata è quella con un reddito alto, che comprende il 34.9% dei partecipanti. Il 16.8% dichiara di appartenere alla classe medio-alta, mentre il 9.2% si colloca nella fascia di reddito estremamente alto. Solo il 2.7% dei rispondenti dichiara di appartenere a una classe a basso reddito. È importante ricordare anche che nel dataset non sono presenti i casi che dichiarano di appartenere a classi di reddito molto




Figura 6. Grafico a barre: distribuzione della variabile “Classe Reddito Familiare”

basse ed estremamente basse, di conseguenza il dataset appare sbilanciato verso una parte della popolazione più ambiente, si nota anche dal fatto che nel 2019, l'anno in cui sono stati acquisiti questi dati, il reddito mediano californiano si attestava a 78,000 \$, mentre il reddito mediano è di 170,000 \$.

Per quanto riguarda la variabile “Livello di istruzione”, che prevede quattro modalità di risposta (Licenza media, Diploma o Qualifica professionale, Laurea di I livello e, infine, Laurea di II livello o Dottorato), la maggior parte dei rispondenti si colloca nel livello di Laurea di II livello o Dottorato, pari al 48.4%. Il 39% dei rispondenti ha un livello di istruzione di Laurea di I livello, mentre il 12.4% si attesta sul livello di Diploma o Qualifica professionale. Solo 22 rispondenti su oltre 10,000 dichiarano di avere la Licenza media o un livello inferiore.




Figura Grafico a barre: distribuzione della variabile “Classe Reddito Familiare”


4.1.2 VARIABILI ABITATIVE

Nel secondo gruppo di variabili, quelle legate al contesto abitativo, possiamo distinguere tra variabili qualitative e quantitative. Le variabili qualitative comprendono: “casa di proprietà”, che indica se i rispondenti possiedono una casa o vivono in affitto, e “casa indipendente”, che riporta se l’abitazione è indipendente, come le classiche villette americane, oppure un appartamento in condominio. Le variabili quantitative, invece, includono: “numero di auto in famiglia” e “numero di persone in famiglia”.

Analizzando la variabile “casa di proprietà”, emerge che l’86.6% dei rispondenti possiede una casa, mentre il 13.4% vive in affitto. Per quanto riguarda la variabile “casa indipendente”, l’84.2% dei rispondenti abita in una casa indipendente, mentre il restante 15.8% vive in appartamento. Quest’ultima

variabile potrebbe risultare particolarmente interessante, in quanto, apparentemente, chi vive in una casa indipendente, spesso dotata di garage o posto auto, ha maggiore facilità a ricaricare un'auto elettrica rispetto a chi risiede in appartamento, soprattutto per chi risiede in città. Inoltre, chi vive in una casa indipendente è, nella maggior parte dei casi, anche proprietario dell'abitazione, 93.1%; mentre tra chi vive in appartamento il 51.4% è proprietario e il restante 48.6% vive in affitto.

Distribuzione della variabile Casa di proprietà



Distribuzione della variabile Casa Indipendente




Figure 8 e 9. Grafici a torta: distribuzione della variabile “Casa di proprietà” e “Casa Indipendente”

La variabile “numero di persone in famiglia” è la terza variabile di questo gruppo, che indica la dimensione del nucleo familiare. Analizzando il dataset si può osservare che il valore minimo che si registra è di una persona e un valore massimo di tredici all'interno del nucleo familiare.

Il 38% dei rispondenti dichiara di appartenere a una famiglia composta da due persone, seguita dal 25.9% di famiglie con quattro persone e dal 18.9% con tre persone. Il 6.9% dei nuclei familiari è composto da cinque persone, mentre solo l'8% dei rispondenti vive da solo.

Distribuzione della variabile Numero persone in famiglia




Figura 10. Istogramma: distribuzione della variabile “Numero di persone in famiglia”

Nuclei familiari più grandi, composti da sei o più persone, sono presenti in percentuali molto ridotte: il 1.8% per famiglie di sei persone, mentre famiglie con più di sette membri, fino a un massimo di tredici, si riscontrano in pochissimi casi, in alcuni casi una singola occorrenza per ogni dimensione del nucleo familiare.




Figura 11. Istogramma: distribuzione della variabile “Numero di auto in famiglia”

Per la variabile “numero di auto in famiglia”, nel dataset si registrano casi con un valore minimo di una e un massimo di cinque auto per famiglia. Il 50.3% dei rispondenti possiede due auto, il 28.1% ne possiede tre, il 9.5% quattro, e solo il 7.9% dichiara di possedere una sola auto. Infine, il 4.2% delle famiglie possiede cinque autovetture. È importante notare che queste famiglie non possiedono alcuna auto con motore a combustione interna (ICE), ma soltanto veicoli a basso impatto ambientale, come auto elettriche, ibride, ibride plug-in o a celle a combustibile di idrogeno.

Analizzando più nel dettaglio queste due ultime variabili, si può notare che il nucleo familiare composto da una sola persona (854 casi) potrebbe essere collegato ai casi con un solo veicolo in famiglia (841 casi). Tuttavia, osservando più attentamente, si evince che, sebbene il 56% dei nuclei familiari composti da una persona possieda effettivamente un solo veicolo, il 33% dichiara di possederne due, l’8.2% tre, il 2.1% quattro, e lo 0.7% addirittura cinque. Questo suggerisce che, sebbene il numero di persone in famiglia possa influenzare il numero di auto possedute, non esiste una correlazione stretta. Per verificare questa relazione, è stato calcolato il *Coefficiente di Correlazione di Pearson (R)*, il cui valore è risultato essere 0.374. Questo indica una relazione tendenzialmente positiva, con una correlazione bassa-moderata. Pertanto, si può affermare che, sebbene i nuclei familiari più grandi tendano a possedere un numero maggiore di auto, non è possibile generalizzare questa osservazione in maniera assoluta.




Figura 12. Relazioni tra le variabili: “Numero di auto in famiglia” e “Numero di persone in famiglia”

4.1.3 VARIABILE SENSIBILITÀ AMBIENTALE

La variabile “Importanza di ridurre le emissioni di gas serra”, come si può vedere nell’istogramma sottostante (Figura 13), è una variabile quantitativa continua, suddivisa in sei bin, ciascuno dei quali rappresenta un intervallo di un’unità. Questa variabile può assumere valori che variano da -3, che indica che non si ritiene importante ridurre le emissioni di gas serra, fino a +3, che rappresenta il massimo livello di importanza attribuito alla riduzione delle emissioni. Dall’analisi dell’istogramma, si evince che la maggior parte delle persone attribuisce un valore molto positivo all’importanza di ridurre le emissioni di




Figura 13. Iistogramma con 6 bins: distribuzione della variabile “Importanza di ridurre le emissioni di gas serra”

gas serra, più del 60% degli intervistati ha assegnato un punteggio compreso tra 2 e 3, confermando che per queste persone il tema è considerato rilevante. La media dei punteggi di questa variabile nel dataset è di 1.62, mentre la mediana è di 2.51. Essendo che questo tipo di variabile è una variabile continua i cui valori assumono anche due valori decimali, è importante analizzare un istogramma più dettagliato, come la Figura 14 con più bin, in questo caso sessanta, in cui ogni bin corrisponde a 0.1.

Osservando il nuovo istogramma, si nota una concentrazione ancora maggiore di valori nella parte destra del grafico, con percentuali elevate per i punteggi compresi tra 2.5 e 3, che indicano una forte sensibilità ambientale. Inoltre, emergono due picchi significativi che non erano visibili nel grafico precedente: uno in corrispondenza del valore centrale, 0, e uno in corrispondenza del valore estremamente negativo.




Figura 14. Istogramma con 60 bins: distribuzione della variabile "Importanza di ridurre le emissioni di gas serra"

4.1.4 VARIABILI CLASSI VEICOLARI

Il gruppo delle variabili relative alle classi veicolari è composto esclusivamente da variabili qualitative. Analizzando la variabile riguardante la tipologia di automobile posseduta precedentemente, si osserva che il 56.8% dei rispondenti aveva un'auto con motore a combustione interna, il 20.2% possedeva un'auto ibrida, l'11.4% guidava una vettura ibrida plug-in, l'11.1% un'auto elettrica, mentre solo lo 0.4% aveva un'auto alimentata a gas naturale compresso (GNC). La bassa percentuale di auto alimentate a metano può essere spiegata dal fatto che negli Stati Uniti queste vetture sono poco diffuse, poiché il prezzo della benzina è generalmente più basso rispetto ai prezzi europei e la rete di distributori di metano è scarsamente sviluppata, limitandone così l'utilizzo. Inoltre, da questi dati emerge che oltre la metà degli intervistati è composta da nuovi utilizzatori di auto a basse emissioni, poiché quasi il 57% proviene da veicoli con motore a combustione interna.




Figure 15 e 16. Grafici a torta: distribuzione della variabile “Tipologia di auto precedente” e “Tipologia di auto attuale”

Nella seconda e ultima variabile di questo gruppo, quella relativa alla tipologia di auto attuale (soltanto quelle a basse emissioni) degli intervistati, emerge che il 54.2% dei casi ha scelto un'autovettura elettrica, il 42.7% una vettura ibrida plug-in, il 2.7% una vettura a celle combustibili a idrogeno, e solo lo 0.3% ha optato per un'auto ibrida. Quest'ultima percentuale, ovvero, chi utilizza un'auto ibrida, è sorprendentemente bassa questo probabilmente è dovuto al fatto che il ricercatore abbia incluso in questa tipologia di automobile soltanto le vetture *full hybrid*. Quest'ultime, a differenza delle auto *mild* e *micro hybrid*, hanno un impatto ambientale minore grazie alla presenza di batterie più capienti, che consente di immagazzinare una maggiore quantità di energia. Questo permette all'auto di percorrere alcuni chilometri in modalità completamente elettrica, riducendo così le emissioni in modo significativo. Al contrario, le vetture *mild* e *micro hybrid* non possono funzionare esclusivamente in modalità elettrica, ma utilizzano il motore elettrico solo per assistere quello a combustione interna, contribuendo a una riduzione delle emissioni, ma in misura inferiore.

Per quanto riguarda il tema della percentuale irrisoria delle vetture ibride presenti nel dataset, secondo un'analisi dell'*U.S. Energy Information Administration*, al momento della raccolta dei dati, le auto ibride rappresentavano il 2% del totale negli Stati Uniti (questa cifra include tutte le categorie di vetture ibride, non solo le *full hybrid*)¹². Di conseguenza, le basse percentuali osservate nel dataset possono essere spiegate dalla scarsa diffusione delle vetture ibride negli Stati Uniti rispetto all'Europa, dove queste tecnologie hanno una presenza più rilevante. Inoltre, la percentuale così basse è possibile che sia dovuta a possibili errori di campionamento che hanno contribuito a ottenere una percentuale così esigua nel dataset.

¹² U.S. share of electric and hybrid vehicle sales increased in the second quarter of 2024, U.S. Energy Information Administration

4.1.5 VARIABILI DI MOBILITÀ E PERCORRENZA

Il quinto gruppo di variabili, relativo alla mobilità degli intervistati, è composto esclusivamente da variabili quantitative. La prima variabile, “Viaggio più lungo negli ultimi 12 mesi”, indica la distanza in miglia (di sola andata) del viaggio più lungo effettuato dagli intervistati nell’ultimo anno. Questa rappresenta la destinazione più lontana che un rispondente ha raggiunto partendo da casa, e può includere viaggi di durata superiore a un giorno. Dal primo istogramma, Figura 17, si osserva che i valori si concentrano principalmente tra 0 e 1,000/1,400 miglia. La media delle distanze percorse è di 376.74 miglia, mentre il valore mediano è di 317.82 miglia.

Analizzando più nello specifico un ulteriore istogramma, Figura 18, che mostra soltanto i valori fino a un massimo di 1000 miglia, emerge che:

- il 7.3% degli intervistati ha effettuato un viaggio di sola andata tra 0 miglia e 100 miglia,
- il 22% dei casi ha viaggiato per un massimo tra 100 e 200 miglia,
- il 21.5% ha compiuto un viaggio tra 300 e 400 miglia,




Figure 17 e 18. Istogrammi relativa all distribuzione della variabile “Viaggio più lungo negli ultimi 12 mesi”, la Figura 18 è relativa solo ai valori 0-1,000 miglia

- il 18.1% ha percorso una distanza tra 200 e 300 miglia,
- il 14.5% ha viaggiato tra 400 e 500 miglia,
- il 7.3% ha percorso un massimo di 100 miglia,
- il 5.5% ha viaggiato tra 500 e 600 miglia,
- infine, il 6.9% degli intervistati ha effettuato viaggi tra 600 e 1,000 miglia, mentre il restante 4.2% ha percorso viaggi superiori alle 1,000 miglia.

La seconda variabile, “Numero di viaggi superiori a 200 miglia”, presenta valori che vanno da zero fino a un massimo di 65 viaggi compiuti in un anno. Dal primo istogramma, Figura 19, si nota che la maggior parte degli intervistati ha effettuato un numero limitato di viaggi; quindi, per analizzare più nel dettaglio questa distribuzione, il secondo istogramma (Figura. 20) si concentra esclusivamente sui valori compresi tra zero e un massimo di quindici viaggi all’anno.

Da questo secondo grafico, si nota che:

- il 29.3% non ha compiuto alcun viaggio superiore a 200 miglia nell’ultimo anno,
- il 40.2% ha compiuto un solo viaggio,




Figura 19 e 20. Istogrammi relativa alla distribuzione della variabile “Numero di viaggi superiori a 200 miglia”, la Figura 20 è relativa solo ai valori 0-15 viaggi

- Il 7.9% ha effettuato due viaggi,
- Il 4.5% ha compiuto tre viaggi,
- Il 4.2% ha compiuto quattro viaggi,
- Il 3.1% ha effettuato cinque viaggi,
- Il 2.5% ha compiuto fino a sei viaggi l'anno,
- Il restante 8.3% degli intervistati ha effettuato più di sette viaggi all'anno superiori a 200 miglia, con un picco del 2.1% per chi ha effettuato undici viaggi.

La terza variabile, “Distanza casa-lavoro”, come per la variabile “viaggio più lungo negli ultimi 12 mesi”, le distanze espresse in miglia si riferiscono soltanto ai viaggi di solo andata. Dall'istogramma Figura 18 si osserva che la maggior parte dei rispondenti percorre una distanza compresa tra zero e 100 miglia, con un notevole calo oltre dei 50 miglia. Analizzando più nel dettaglio l'istogramma Figura 22,




Figura 21 e 22. Iistogrammi relativa all distribuzione della variabile “Distanza casa-lavoro”, la Figura 22 è relativa solo ai valori 0-50 miglia

che mostra soltanto i valori da zero miglia a un massimo di 100 miglia, suddiviso in 20 *bin* da 5 miglia ciascuno, si nota che:

- il 19,8% degli intervistati percorre da 0 a 5 miglia,
- il 17,6% percorre da 5 a 10 miglia,
- il 15,6% percorre da 10 a 15 miglia.

Le percentuali diminuiscono progressivamente per le distanze superiori, scendendo sotto l'1% per i valori superiori a 55 miglia. In totale, il 67% dei rispondenti percorre meno di 20 miglia per recarsi al lavoro. La media della distanza casa-lavoro è di 18,78 miglia, mentre la mediana è di 14,12 miglia, in linea con i dati del *U.S. Census Bureau*, che indicano una media di 15-20 miglia per gli abitanti della California.

L'ultima variabile di questo gruppo, "VMT annuo" (*Vehicle Miles Traveled*), misura la distanza totale in miglia percorsa da un veicolo in un anno. Analizzando la distribuzione completa di questa variabile, si evince che la maggior parte dei valori si concentra tra 0 e 50,000 miglia annue. L'istogramma, Figura 21, si focalizza su questo intervallo, e mostra che la maggior parte dei casi percorrere tra le 5,000 e le 15,000 miglia annue, rispettivamente il 64.4% dei casi. Se si includono anche coloro che percorrono fino a un massimo di 20,000 miglia annue, la percentuale complessiva sale all'80.3%. La media e la mediana dei valori nel dataset sono rispettivamente di 14,280 e 11,557 miglia. Confrontando questi dati con quelli del *Bureau of Transportation Statistics*, emerge che gli abitanti delle aree urbane della California percorrono annualmente tra 14,000 e 15,000 miglia, mentre i residenti in aree suburbane o rurali raggiungono una media di 17,000 miglia¹³. I risultati ottenuti dal dataset sono in linea con le medie registrate dal *Bureau of Transportation Statistic*.




Figura 23. Iistogramma: distribuzione della variabile "VMT auuno", con valori da 0 a 50,000 miglia

13 Vehicle miles traveled and vehicle trips by State, *Bureau of Transportation Statistics*, <https://www.bts.gov/statistical-products/surveys/vehicle-miles-traveled-and-vehicle-trips-state>

4.2 COME SI DISTRIBUISCONO LE VARIABILI IN RELAZIONE ALLA VARIABILE DIPENDENTE

Dopo aver analizzato le distribuzioni delle singole variabili, essendo la variabile dipendente è “BEV dummy” la quale indica se un individuo possiede o meno un veicolo elettrico (BEV), è stata eseguita un’analisi per verificare come le variabili indipendenti si distribuiscano in relazione alla variabile dipendente, allo scopo di individuare differenze significative tra esse.

Innanzitutto, la distribuzione della variabile genere risulta abbastanza equilibrata, con una leggera prevalenza di uomini tra i possessori di veicoli elettrici. Per quanto riguarda l’età, i gruppi più giovani (<25 anni e 25-34 anni) e quelli più anziani (oltre 65 anni) tendono ad avere una minore adozione della tecnologia elettrica, con una maggiore concentrazione di possessori di BEV nelle fasce di età centrali (45-64 anni). Anche il reddito familiare svolge un ruolo importante: le persone con redditi più elevati tendono ad essere più inclini a possedere un BEV, mentre coloro con redditi più bassi mostrano una minore adozione. Parallelamente, il livello di istruzione emerge come un altro fattore discriminante, con una maggiore probabilità di possesso tra coloro che possiedono una laurea o un titolo di studio superiore. Un altro elemento interessante riguarda la proprietà della casa: chi possiede una casa, in particolare una casa indipendente, ha maggiori probabilità di possedere un BEV, suggerendo una relazione tra stabilità economica e adozione di tecnologie sostenibili. L’analisi della tipologia di auto precedentemente posseduta mostra che chi ha già posseduto un veicolo BEV tende a possederne maggiormente un altro, e solo in pochi ritornano a tecnologie più tradizionali. Chi ha avuto un’auto con motore a combustione interna (ICE) rappresenta una delle categorie con il numero maggiore di nuovi possessori di BEV. In termini di dimensioni familiari, le differenze tra possessori e non possessori di BEV sono minime, suggerendo che la composizione familiare non sia un fattore rilevante nel determinare la propensione ad adottare veicoli elettrici. Inoltre, non si riscontrano grandi differenze nel numero di auto possedute dalla famiglia, anche se i possessori di BEV tendono ad avere leggermente più veicoli rispetto ai non possessori.

Altri fattori legati alla sostenibilità, come l’importanza attribuita alla riduzione delle emissioni di gas serra, mostrano una differenza significativa, con i possessori di BEV che attribuiscono maggior peso alla causa ambientale. Questo riflette un impegno più forte verso la sostenibilità tra gli utenti di veicoli elettrici, anche se esiste una certa variabilità nelle risposte. Per quanto riguarda le abitudini di viaggio, i possessori di BEV tendono a fare meno viaggi lunghi, come evidenziato dalla minore incidenza di viaggi superiori a 200 miglia all’anno. Infine, la distanza casa-lavoro è leggermente inferiore per i possessori di BEV, suggerendo che questi ultimi potrebbero preferire vivere in zone più vicine al posto di lavoro o comunque a distanze che facilitano l’uso quotidiano di un veicolo elettrico. Il dato sul VMT annuo conferma questa tendenza; i possessori di BEV percorrono mediamente meno miglia all’anno, probabilmente a causa di un uso limitato del veicolo elettrico e della preferenza per soluzioni alternative di trasporto per viaggi più lunghi.

Questa analisi rivela che l'adozione dei veicoli BEV è influenzata da una combinazione di fattori socio-economici e comportamentali. I gruppi con un reddito più alto, un livello di istruzione superiore e una maggiore stabilità abitativa sono più propensi a scegliere un BEV, mentre le persone anziane, a basso reddito e con meno istruzione sembrano meno inclini ad adottare questa tecnologia. Nonostante ciò, la crescente attenzione verso la sostenibilità ambientale, le politiche di incentivazione governative e il miglioramento delle infrastrutture di ricarica potrebbero contribuire a ridurre queste disparità, favorendo una diffusione più ampia dei veicoli elettrici anche tra i gruppi meno favoriti. Il futuro della mobilità elettrica dipenderà quindi non solo dall'evoluzione della tecnologia, ma anche da una continua evoluzione dei fattori economici, sociali e culturali che influenzano le scelte dei consumatori. Queste prime analisi hanno permesso di redigere le quattro ipotesi, già esposte nel Capitolo 1.

Conteggi delle variabili dip. qualitative in relazione con la y (BEV dummy)




Figura 24. Grafici a barre impilate relativi alle variabili cardinali, in ordine le variabili: "Genere", "Classe d'Età", "Classe di Reddito Familiare", "Livello d'Istruzione", "Casa Indipendente", "Casa di Proprietà" e infine la variabile "Tipologia di auto precedente"




Figura 25. Boxplot delle variabili quantitative: “Numero di persone in famiglia”, “Numero di auto in famiglia”, “Importanza di ridurre le emissioni di gas serra”, “Viaggio più lungo negli ultimi 12 mesi”, “Numero di viaggi di 200 miglia negli ultimi 12 mesi”, “Distanza casa-lavoro”, e infine “VMT annuo”

Conteggi delle variabili dip. quantitative in relazione con la y (BEV dummy)




Figura 26. Grafici di densità relativi alle variabili quantitative, in ordine le variabili: "Numero persone in famiglia", "Numero auto in famiglia", "Importanza di ridurre le emissioni di gas serra", "Viaggio più lungo negli ultimi 12 mesi", "Numero di viaggi superiori a 200 miglia negli ultimi 12 mesi", "Distanza casa-lavoro" e infine la variabile "VMT annuo"

4.3 ANALISI DELLA MULTICOLLINEARITÀ: ANALISI VIF

Prima di procedere con l'analisi di regressione logistica, è stata condotta un'analisi sulla collinearità tra le variabili dipendenti. La multicollinearità si riferisce a una situazione quando due o più predittori sono fortemente correlati fra loro. Questa situazione può causare problemi nell'analisi di regressione logistica, in questo caso, poiché potrebbe essere difficile stimare gli effetti dei singoli coefficienti.

Per verificare la presenza di multicollinearità tra le variabili del dataset, è stato utilizzato il VIF, *Variance Inflation Factor*. Il VIF misura quanto la varianza di un parametro stimato aumenta quando il modello include altri predittori rispetto a quando viene considerato singolarmente. Un VIF pari a 1 indica l'assenza di collinearità, mentre un valore di VIF superiore a 5 o 10 segnala una collinearità problematica¹⁴. Il VIF è stato calcolato utilizzando Python, utilizzando la libreria Statsmodels¹⁵, sul dataset `dummy`, è stato necessario usare questo dataset poiché non è possibile calcolare il VIF per variabili categoriali.

I risultati, riportati nella Tabella 2, evidenziano valori elevati di VIF nel gruppo delle variabili relative all'abitazione, con alcune che superano sia la soglia di 5, come "Casa di proprietà", "Casa indipendente" e "Numero di persone in famiglia", sia quella di 10, come nel caso di "Numero di auto in famiglia". Per ridurre la collinearità è necessario rimuovere alcuni predittori che sono fortemente correlati.

Prima di procedere con l'eliminazione si è analizzata la matrice di correlazioni tra le variabili dipendenti, Figura 27, come si poteva intuire la coppia delle variabili "Casa di proprietà" e "Casa indipendente", e "Numero di persone in famiglia" e "Numero di auto in famiglia" sono moderatamente correlate fra di loro, hanno rispettivamente valori di 0.45 e 0.37¹⁶.


È stato deciso di eliminare "Numero di persone in famiglia", nonostante il suo valore VIF fosse inferiore rispetto a "Numero di auto in famiglia", poiché quest'ultima variabile è ritenuta più rilevante per l'analisi. Inoltre, è stata rimossa la variabile "Casa di proprietà" in favore di "Casa indipendente", poiché si ipotizza che una casa indipendente possa essere un fattore più significativo nell'acquisto di un veicolo elettrico, offrendo spazio, come un garage, per ricaricare l'auto, cosa che potrebbe essere più difficile per chi vive in un appartamento. Dopo l'eliminazione di queste variabili, il VIF è stato ricalcolato per verificare la riduzione della collinearità fra le variabili.

I nuovi valori ottenuti mostrano una lieve riduzione generale della collinearità, con una diminuzione più marcata per le variabili "Casa indipendente" e "Numero di auto in famiglia", che presentano valori di VIF rispettivamente pari a 6.5286 e 8.5056. Sebbene questi valori siano ancora relativamente elevati, rimangono al di sotto della soglia critica di 10.

14 James Gareth, Witten Daniela, Hastie Trevor, Tibshirani Robert (2013). An Introduction to Statistical Learning, with Applications in R. *Springer*, pp. 99-102

15 statsmodels.stats.outliers_influence.variance_inflation_factor, https://www.statsmodels.org/dev/generated/statsmodels.stats.outliers_influence.variance_inflation_factor.html

16 Ratner, B. (2009). The correlation coefficient: Its values range between +1/-1, or do they?. *Journal of Targeting, Measurement and Analysis for Marketing*, pp. 139-142



Motivo per cui le due variabili sono state mantenute nell'analisi, poiché si ritiene che possano essere rilevanti per il modello di regressione logistica e che potrebbe influenzare le decisioni d'acquisto di un'auto elettrica.

Per valutare l'effetto dell'eliminazione delle due variabili sulla capacità del modello di spiegare la variabile dipendente, è stato utilizzato il coefficiente di determinazione R^2 di *McFadden*¹⁷. Questo indice misura la bontà di adattamento di un modello di regressione logistica, indicando quanto il modello spiega la variabilità della variabile dipendente rispetto a un modello nullo, che non include predittori. In particolare, tramite una funzione sono stati confrontati due modelli con una tolleranza di 0.0001: uno con tutte le variabili indipendenti e l'altro in cui sono state rimosse le variabili “casa di proprietà” e “numero di persone in famiglia”. Per fare questo, è stato calcolato il valore di R^2 di *McFadden* per entrambi i modelli.

I risultati ottenuti sono i seguenti:

- R^2 di *McFadden* per il modello completo: 0.066623
- R^2 di *McFadden* per il modello ridotto: 0.066570

Entrambi i modelli presentano valori di R^2 simili, con una differenza di soli 0.000053 (entro la tolleranza di 0.0001). Questa piccola variazione suggerisce che la rimozione delle variabili non ha avuto un impatto significativo sulla capacità del modello di adattarsi ai dati.

Pertanto, si può concludere che non c'è una differenza sostanziale tra i due modelli. Si è deciso quindi di procedere con il modello ridotto, in cui sono state eliminate le variabili “casa di proprietà” e “numero di persone in famiglia”, per la successiva analisi di regressione logistica.

```
Optimization terminated successfully.
      Current function value: 0.646968
      Iterations 6
R2 di McFadden per modello completo: 0.066623

Optimization terminated successfully.
      Current function value: 0.647005
      Iterations 6
R2 di McFadden per modello ridotto: 0.066570
```

```
=====
| Entrambi i modelli hanno un R2 simile (entro 4 decimali), |
| si può procedere con il modello ridotto.                  |
=====
```

*Output della funzione per il calcolo dei coefficienti R^2 di *McFadden*, il primo riguarda il modello con tutte le variabili, il secondo quello con le variabili “Casa di proprietà” e “Numero di persone in famiglia” rimosse*

Gruppo di variabili	Feature	VIF
Variabili socio-demografiche	Genere	3.9257
	Classe d'età: <25 vs 45-54	1.0096
	Classe d'età: 25-34 vs 45-54	1.1568
	Classe d'età: 35-44 vs 45-54	1.6116
	Classe d'età: 55-64 vs 45-54	2.0295
	Classe d'età: 65-74 vs 45-54	1.8640
	Classe d'età: 75-79 vs 45-54	1.3428
	Classe d'età: >80 vs 45-54	1.0450
	Classe Reddito Familiare: Bassa vs Media	1.0904
	Classe Reddito Familiare: Alta vs Media	2.0238
	Classe Reddito Familiare: Molto alta vs Media	1.5586
	Classe Reddito Familiare: Estremamente alta vs Media	1.3518
	Livello di istruzione: Licenza media vs Laurea 2L o Dottorato	1.0110
	Livello di istruzione: Diploma o Qualifica professionale vs Laurea 2L o Dottorato	1.3083
	Livello di istruzione: Laurea 1L vs Laurea 2L o Dottorato	1.8105
Variabili abitative	Casa di proprietà	9.3862*
	Casa indipendente	8.3499*
	Numero di persone in famiglia	9.0637*
	Numero di auto in famiglia	10.9584**
Variabile sensibilità ambientale	Importanza di ridurre le emissioni di gas serra	1.9297
Variabili classe veicolare	Tipologia di auto precedente: BEV vs PHEV	1.7904
	Tipologia di auto precedente: HEV vs PHEV	2.3562
	Tipologia di auto precedente: GNC vs PHEV	1.0373
	Tipologia di auto precedente: ICE vs PHEV	4.6148
Variabili di mobilità e percorrenza	Viaggio più lungo negli ultimi 12 mesi	2.2013
	Numero di viaggi superiori a 200 miglia negli ultimi 12 mesi	1.3124
	Distanza casa-lavoro	1.7855
	VMT annuo	1.8482

Tabella 2: Valori iniziali VIF per il dataset *dummy*. I valori che superano la soglia di 5 e 10 sono indicati in grassetto, con * per i valori superiori a 5 e ** per quelli superiori a 10.

4.4 LIBRERIE PYTHON PER LE ANALISI PRELIMINARI

Nel presente capitolo sono state utilizzate diverse librerie Python per l'analisi dei dati e la visualizzazione. Di seguito vengono descritte brevemente le librerie principali:

- *Kaleido*: Una libreria utilizzata per esportare e salvare le visualizzazioni create con Plotly.
- *Plotly*: Una libreria usata per la creazione di grafici interattivi. Sono stati utilizzati i moduli: *plotly.graph_objects*, *plotly.express*, *Subplots* e *Figure Factory*.
- *NumPy*: Una libreria usata per il calcolo scientifico e l'elaborazione numerica degli array.
- *Pandas*: Fondamentale per la manipolazione e l'analisi dei dati. È stata utilizzata per gestire i dataset, effettuare operazioni di cleaning dei dati e trasformazioni.
- *Statsmodels*: Una libreria dedicata alle statistiche avanzate. In particolare, il modulo *variance_inflation_factor* è stato utilizzato per calcolare il *Variance Inflation Factor* (VIF) e analizzare la multicollinearità tra variabili indipendenti.

Tutti questi strumenti sono stati utilizzati per supportare le analisi statistiche e le visualizzazioni trattate nel corso di questo capitolo. Il codice utilizzato nel notebook Python può essere trovato nella repository GitHub al seguente link:

https://github.com/FedeGambe/Master_s_thesis_Data_science/tree/130fed101bc663d0ee1730347088c6fb0b4db5d5/Analisi_Statistiche

I concetti trattati in questo capitolo sono legati ai seguenti capitoli del notebook:

- Paragrafo 4.1 - Il dataset e le sue caratteristiche: descrizione delle distribuzioni delle variabili. (Cap. 2 del Notebook Python. [Analisi Statistiche: Analisi della distribuzione delle variabili](#)).
- Paragrafo 4.2 - Come si distribuiscono le variabili in relazione alla variabile dipendente. (Cap. 3 del Notebook Python. [Analisi Statistiche: Analisi della distribuzione delle variabili indipendenti in relazione con la dipendente](#)).
- Paragrafo 4.3 - Analisi della multicollinearità: analisi VIF. (Par. 5.1 del Notebook Python. [Analisi Statistiche: Python, Analisi VIF e Correlazione](#)).

CAPITOLO 5

ANALISI DI REGRESSIONE LOGISTICA

5.1 DEFINIZIONE DELLA REGRESSIONE LOGISTICA

Per analizzare la relazione tra due o più variabili, si utilizza frequentemente la tecnica della regressione, che consente di studiare come una o più variabili indipendenti influenzino una variabile dipendente. Le principali tipologie di regressione si distinguono in regressioni lineari e regressioni non lineari. In questa tesi, essendo la variabile dipendente una qualitativa dicotomica che può assumere solo due valori distinti, si è impiegata una regressione logistica, appartenente alla famiglia delle regressioni non lineari. Al contrario, i metodi di regressione lineare sono comunemente utilizzati per variabili quantitative, quindi non risultano adeguati a una variabile qualitativa. La regressione logistica binomiale, invece, permette di modellare una variabile dipendente dicotomica, cioè una variabile che può assumere solo due modalità, in funzione di una o più variabili indipendenti, che possono essere sia qualitative che quantitative.

La regressione logistica, quindi, è un metodo statistico che aiuta a stimare la probabilità che un dato evento si verifichi o meno. A differenza della regressione lineare, che prevede valori numerici continui, la regressione logistica calcola una probabilità compresa tra 0 e 1. Nella nostra applicazione si calcola la probabilità di possedere un veicolo elettrico in base a diverse variabili indipendenti, come la classe di reddito familiare, l'età del consumatore, il genere, e altre.

Per poter effettuare questo tipo di analisi, è necessario trasformare la funzione logistica, che predice valori tra 0 e 1, in una funzione che può assumere qualsiasi tipo di valore, compreso tra meno infinito e più infinito, chiamata funzione logit. Nella funzione logistica, la variabile dipendente Y assume solo due valori, mentre nella funzione logit questa può variare in un intervallo continuo.

Per questa analisi, la variabile dipendente è rappresentata da BEV dummy, che indica se un individuo possiede o meno un veicolo elettrico. Essendo una variabile dicotomica, segue una distribuzione bino-

miale, conosciuta anche come distribuzione di Bernoulli. In tale distribuzione, la variabile assume il valore 1 quando l'evento di interesse (possesso di un veicolo elettrico) si verifica, e 0 in caso contrario.

5.2 RISULTATI E INTERPRETAZIONE

5.2.1 APPLICAZIONE E SPIEGAZIONE GENERALE DEL MODELLO

Per effettuare la regressione logistica, così come per il calcolo del coefficiente VIF, è stata utilizzata la libreria Statsmodels¹⁸ con Python. La variabile dipendente selezionata è la BEV dummy, che identifica i soggetti che possiedono o meno un veicolo elettrico. Come precedentemente indicato, questa variabile assume il valore di 1 quando l'individuo possiede un veicolo elettrico, e 0 quando possiede un altro veicolo a basse emissioni non elettrico.

Le variabili indipendenti utilizzate includono tutte quelle presenti nel dataset dummy, escluse le due eliminate durante l'analisi di multicollinearità. L'applicazione di questa libreria ha generato un report (Tabella 3 e 4), contenente informazioni quali il pseudo R^2 , la *log-likelihood*, i *coefficienti beta*, gli *standard error*, i *valori z* e i *p-value*. Tuttavia, nel report non erano presenti gli odds ratio, necessari per interpretare i risultati della regressione logistica, che sono stati calcolati successivamente.

Logit Regression Results	
Dep. Variable:	BEV dummy
Model:	Logit
Method:	MLE
converged:	True
Covariance Type:	nonrobust
No. Observations:	10688
Df Residuals:	10661
Df Model:	26
Pseudo R-squ.:	0.06433
Log-Likelihood:	-6896.0
LL-Null:	-7370.1
LLR p-value:	3.451e-183

Tabella 3: Riepilogo del modello logit

Feature	Coef	Std err	Z	P> z	[0.025	0.975]
const	-0.7443	0.121	-6.173	0.000	-0.981	-0.508
Variabili socio-demografiche						
Genere	0.2195	0.048	4.619	0.000	0.126	0.313
Classe d'età: <25 vs 45-54	0.1286	0.502	0.256	0.798	-0.856	1.113
Classe d'età: 25-34 vs 45-54	-0.1127	0.121	-0.932	0.351	-0.350	0.124
Classe d'età: 35-44 vs 45-54	0.1093	0.062	1.767	0.077	-0.012	0.230
Classe d'età: 55-64 vs 45-54	-0.2308	0.057	-4.074	0.000	-0.342	-0.120
Classe d'età: 65-74 vs 45-54	-0.3456	0.064	-5.413	0.000	-0.471	-0.220
Classe d'età: 75-79 vs 45-54	-0.0811	0.093	-0.870	0.384	-0.264	0.102
Classe d'età: >80 vs 45-54	-0.6871	0.253	-2.714	0.007	-1.183	-0.191
Classe Reddito Familiare: Bassa vs Media	-0.3282	0.131	-2.502	0.012	-0.585	-0.071
Classe Reddito Familiare: Alta vs Media	0.1964	0.049	4.036	0.000	0.101	0.292
Classe Reddito Familiare: Molto alta vs Media	0.4751	0.062	7.629	0.000	0.353	0.597
Classe Reddito Familiare: Estremamente alta vs Media	0.7498	0.081	9.242	0.000	0.591	0.909
Livello di istruzione: Licenza media vs Laurea 2L o Dottorato	-0.8871	0.474	-1.873	0.061	-1.815	0.041
Livello di istruzione: Diploma o Qualifica professionale vs Laurea 2L o Dottorato	-0.3604	0.066	-5.425	0.000	-0.491	-0.230
Livello di istruzione: Laurea 1L vs Laurea 2L o Dottorato	-0.1214	0.044	-2.742	0.006	-0.208	-0.035
Variabili abitative						
Casa di proprietà	0.2257	0.064	3.521	0.000	0.100	0.351
Numero di auto in famiglia	0.1402	0.024	5.876	0.000	0.093	0.187
Variabile sensibilità ambientale						
Importanza di ridurre le emissioni di gas serra	0.1002	0.013	7.811	0.000	0.075	0.125
Variabili classe veicolare						
Tipologia di auto precedente: BEV vs PHEV	1.2453	0.091	13.651	0.000	1.066	1.424
Tipologia di auto precedente: HEV vs PHEV	-0.0206	0.074	-0.278	0.781	-0.166	0.125
Tipologia di auto precedente: GNC vs PHEV	0.3729	0.305	1.221	0.222	-0.226	0.972
Tipologia di auto precedente: ICE vs PHEV	0.4114	0.065	6.292	0.000	0.283	0.540
Variabili di mobilità e percorrenza						
Viaggio più lungo negli ultimi 12 mesi	4.264e-05	5.84e-05	0.730	0.466	-7.19e-05	0.000
Numero di viaggi superiori a 200 miglia negli ultimi 12 mesi	-0.0351	0.005	-7.688	0.000	-0.044	-0.026
Distanza casa-lavoro	-0.0019	0.001	-1.980	0.048	-0.004	-1.95e-05
VMT annuo	-1.504e-05	1.93e-06	-7.812	0.000	-1.89e-05	-1.13e-05

Tabella 4: output del modello logit, nel quale sono presenti tutte le variabili analizzate

Feature	OR (exp(β))	Coef	Std err	P> z	
const		-0.7443	0.121	0.000	***
Variabili socio-demografiche					
Genere	1.246077	0.2195	0.048	0.000	***
Classe d'età: 55-64 vs 45-54	0.793739	-0.2308	0.057	0.000	***
Classe d'età: 65-74 vs 45-54	0.707512	-0.3456	0.064	0.000	***
Classe d'età: >80 vs 45-54	0.503083	-0.6871	0.253	0.007	**
Classe Reddito Familiare: Bassa vs Media	0.720363	-0.3282	0.131	0.012	*
Classe Reddito Familiare: Alta vs Media	1.216527	0.1964	0.049	0.000	***
Classe Reddito Familiare: Molto alta vs Media	1.608014	0.4751	0.062	0.000	***
Classe Reddito Familiare: Estremamente alta vs Media	2.117000	0.7498	0.081	0.000	***
Livello di istruzione: Diploma o Qualifica professionale vs Laurea 2L o Dottorato	0.697676	-0.3604	0.066	0.000	***
Livello di istruzione: Laurea 1L vs Laurea 2L o Dottorato	0.886034	-0.1214	0.044	0.006	**
Variabili abitative					
Casa di proprietà	1.253576	0.2257	0.064	0.000	***
Numero di auto in famiglia	1.150274	0.1402	0.024	0.000	***
Variabile sensibilità ambientale					
Importanza di ridurre le emissioni di gas serra	1.105171	0.1002	0.013	0.000	***
Variabili classe veicolare					
Tipologia di auto precedente: BEV vs PHEV	3.472935	1.2453	0.091	0.000	***
Tipologia di auto precedente: ICE vs PHEV	1.508325	0.4114	0.065	0.000	***
Variabili di mobilità e percorrenza					
Numero di viaggi superiori a 200 miglia negli ultimi 12 mesi	0.965605	-0.0351	0.005	0.000	***
Distanza casa-lavoro	0.998002	-0.0019	0.001	0.048	*
VMT annuo	0.9999849 101138535	-1.509e-05	1.93e-06	0.000	***

Tabella 5: presenti solo le variabili significative, con p-value <0.05, con il relativo OR, o exp(β)

Per calcolare gli odds ratio, è stato creato un dizionario in Python, nel quale sono stati inclusi solo i valori relativi alle variabili con un p-value inferiore a 0.05, consentendo così di generare una Tabella contenente solo i coefficienti significativi (Tabella 5).

Nella Tabella 3 si possono osservare le informazioni generali dell'analisi logistica, tra cui le più importanti: la variabile dipendente (BEV dummy), il modello utilizzato (*logit*), il metodo impiegato (*MLE*, ovvero il metodo di massima verosimiglianza) e il pseudo R^2 , che ha un valore pari a 0.064. Quest'ultimo indica la porzione di varianza della variabile dipendente spiegata dalle variabili indipendenti; più alto è il coefficiente, maggiore è la capacità del modello di spiegare la varianza della variabile dipendente. Tuttavia, in questo caso, il coefficiente è piuttosto basso, indicando una capacità esplicativa limitata del modello.

La Tabella 4 riporta i coefficienti, gli errori standard, le *statistiche Z*, i *p-value* e gli intervalli di confidenza per l'intercetta e tutte le variabili, suddivise nei quattro gruppi. Per un'analisi più approfondita, ci si rifà alla Tabella 5, la quale riporta le variabili significative con un *p-value* inferiore a 0.05 e i relativi valori di odds ratio (*OR*). Questi ultimi sono stati ottenuti elevando esponenzialmente i coefficienti beta significativi. Gli odds ratio possono variare tra 0 e infinito, con un valore di riferimento pari a 1, il quale indica l'assenza di relazione tra la variabile dipendente e la variabile indipendente. Ad esempio, un *OR* pari a 1 per la variabile "genere" significa che essere uomo o donna non influisce sulla probabilità di possedere un veicolo elettrico. Un *OR* inferiore a 1 indica una relazione negativa: nel caso della variabile "genere", se l'*OR* per gli uomini fosse inferiore a 1, significherebbe che gli uomini hanno una probabilità inferiore di possedere un veicolo elettrico rispetto alle donne. Viceversa, un *OR* maggiore di 1 indica una relazione positiva, ovvero una maggiore probabilità che l'evento accada.

5.2.2 RISULTATI DELLE VARIABILI LEGATE ALLE IPOTESI DI RICERCA

In questo Paragrafo verranno presentate inizialmente le analisi delle variabili relative alle ipotesi di ricerca della tesi, seguite dalle rimanenti variabili.

Ipotesi 1 (H1) - Influenza del reddito sull'acquisto di veicoli BEV

Come anticipato nei capitoli precedenti, la variabile "Classe di Reddito Familiare" è una variabile qualitativa categoriale, che originariamente conteneva cinque classi. Per consentire il confronto con il reddito medio, sono state create quattro variabili dicotomiche: Bassa rispetto alla Media, Alta rispetto alla Media, Molto Alta rispetto alla Media, ed Estremamente Alta rispetto alla Media.

Dalla Tabella 5, si osserva che solo la variabile riferita alla Classe di Reddito Bassa rispetto alla Classe Media presenta un odds ratio (*OR*) inferiore a 1, indicando una diminuzione della probabilità di possedere un veicolo elettrico per questa categoria.

- Per la classe Bassa vs Media, l'*OR* è pari a 0.7068, indicando una riduzione del 29.32% della probabilità di possedere un veicolo elettrico rispetto a un individuo della classe media. Invece, le altre categorie di reddito presentano un *OR* maggiore di 1, a indicare che la probabilità di possedere un veicolo elettrico è più alta rispetto alla classe media:

- Classe Alta rispetto alla Media: *OR* pari a 1.224, implicando un aumento del 22.39% della probabilità di possedere un veicolo elettrico rispetto a un individuo della classe media.
- Classe Molto Alta rispetto alla Media: *OR* pari a 1.618, indicando un incremento della probabilità del 61.77% rispetto alla classe posta a residuo.
- Classe Estremamente Alta rispetto alla Media: *OR* pari a 2.126, il che indica un raddoppio della probabilità, con un aumento del 112.55% di possedere un'auto elettrica rispetto a un individuo della classe media.

Questi risultati suggeriscono che all'aumentare del reddito familiare, la probabilità di possedere un veicolo elettrico cresce notevolmente, confermando un'influenza positiva del reddito sull'adozione di veicoli BEV.

Infine, osservando le percentuali di possesso di veicoli elettrici nelle diverse classi di reddito, si nota una chiara tendenza di crescita all'aumentare del reddito: nella classe Bassa solo il 38.46% possiede un veicolo elettrico, contro il 47.71% nella Media, il 54.44% nella Alta, il 62.18% nella Molto Alta e infine il 69.20% nella Estremamente Alta. Queste percentuali confermano come il possesso di veicoli elettrici aumenti con il reddito, probabilmente anche a causa dell'elevato costo di acquisto dei veicoli elettrici rispetto alle automobili a combustione interna o ibride, come discusso nel Capitolo 2.

Ipotesi 2 (H2) - Influenza del veicolo posseduto in precedenza sull'acquisto di veicoli BEV

La seconda ipotesi analizza se il tipo di veicolo posseduto in passato influenzi la probabilità di acquistare un veicolo elettrico (BEV). Si ipotizza che individui che hanno posseduto in precedenza un veicolo ibrido plug-in abbiano una maggiore probabilità di acquistare un veicolo elettrico, poiché sono già parzialmente abituati alla ricarica elettrica e al cambiamento di paradigma che caratterizza un veicolo BEV. Dalla Tabella 5, è possibile vedere che le variabili utili per quest'ipotesi fanno tutte parte del gruppo variabili classi veicolare, poiché la variabile relativa al veicolo attualmente posseduto è stata posta come variabile dipendente. Poiché la variabile "Tipologia di auto precedente" si tratta di una variabile qualitativa categoriale, sono state generate variabili dummy per ciascun gruppo, eccetto il gruppo di riferimento, rappresentato dalla categoria ibrido plug-in.

Dalla Tabella 5, si osserva che le vetture precedentemente possedute, come quelle a metano o ibride, non risultano significative per questa ipotesi, con valori di p-value elevati. Le uniche due variabili risultate significative riguardano il possesso pregresso di veicoli elettrici e veicoli a combustione interna, confrontati con il possesso di veicoli ibridi plug-in. È ragionevole attendersi che chi abbia già posseduto un veicolo elettrico presenti una maggiore propensione a ripetere l'acquisto, essendo già familiare con questa tecnologia. Al contrario, si ipotizza che il possesso di un veicolo a combustione interna possa ridurre la probabilità di acquistare un veicolo elettrico, rispetto a chi ha posseduto un veicolo ibrido plug-in, per i motivi sopra riportati.

I risultati presentati nella Tabella 5 confermano solo in parte tali aspettative. Infatti, chi ha posseduto in passato un veicolo elettrico, rispetto a un veicolo ibrido plug-in, presenta un *OR* di 3.473, indicando una probabilità superiore del 247.3% di acquistare un veicolo elettrico. Inaspettatamente, però, chi ha posseduto in passato un veicolo a combustione interna presenta anch'esso un *OR* maggiore di 1, precisamente pari a 1.508, con una probabilità incrementata del 50.8% di possedere un veicolo elettrico rispetto a chi possedeva un ibrido plug-in. Tali risultati suggeriscono che il possesso pregresso di un veicolo ibrido plug-in, contrariamente alle aspettative iniziali, non aumenta necessariamente la propensione all'acquisto di un veicolo elettrico.

Ipotesi 3 (H3) - Influenza delle lunghe distanze percorse sull'acquisto di veicoli BEV

La terza ipotesi esplora l'effetto della percorrenza di lunghe distanze sull'acquisto di veicoli elettrici. Questa ipotesi è collegata al gruppo di variabili legate alla mobilità e alla distanza percorsa. Dall'analisi emerge che la variabile "viaggio più lungo effettuato negli ultimi 12 mesi" non risulta significativa; pertanto, vengono analizzate le variabili "numero di viaggi superiori a 200 miglia negli ultimi 12 mesi", "distanza casa-lavoro" e "VMT annuo". Tutte queste variabili presentano valori di Odds Ratio inferiori a 1, indicando che un aumento dei loro valori comporta una riduzione della probabilità di possedere un veicolo elettrico.

Per la variabile che calcola il numero di viaggi superiori a 200 miglia effettuati nell'ultimo anno, il valore di *OR* è pari a 0.965605, il che implica che per ogni viaggio superiore a 200 miglia la probabilità di possedere un veicolo elettrico diminuisce del 3.4% rispetto a chi non compie tali viaggi. Poiché questa variabile si riferisce a viaggi di andata e ritorno, ogni viaggio aggiuntivo comporta una riduzione ulteriore del 3.4%. Ad esempio, per chi effettua tre viaggi l'anno rispetto a chi ne effettua uno, la probabilità di possedere un veicolo elettrico diminuisce del 6.8%.

Per quanto riguarda la variabile "distanza casa-lavoro", essa presenta un *OR* di 0.998002. Di conseguenza, la probabilità di possedere un veicolo elettrico scende dello 0.2% per ogni miglio aggiuntivo percorso nel tragitto casa-lavoro. Un incremento di cinque miglia comporta una diminuzione dell'1% nella probabilità di possedere un veicolo elettrico. Ad esempio, una persona che percorre 30 miglia per il tragitto casa-lavoro ha una probabilità inferiore del 2% rispetto a chi ne percorre 20 miglia. Infine, analizzando le medie delle distanze nel dataset, chi possiede un veicolo elettrico percorre circa 18 miglia nel tragitto casa-lavoro, contro le 20 miglia di chi possiede un veicolo a combustione.

La variabile "VMT annuo", che rappresenta le miglia percorse annualmente, ha un valore di *OR* molto prossimo a 1 (0.9999849601131002). Questo implica che per ogni miglio percorso in più all'anno, la probabilità di possedere un veicolo elettrico scende dello 0.0015%, un valore relativamente basso in termini percentuali, ma che assume significatività sulle migliaia di miglia annuali. Ogni 1,000 miglia aggiuntive percorse annualmente riducono la probabilità di possedere un veicolo elettrico dell'1.509%, mentre per 5,000 miglia l'effetto arriva al 7.52%. Secondo i dati del Bureau of Transportation Statistics, riportati nel Capitolo precedente, si nota che le persone che risiedono in aree rurali, percorrendo mediamente dalle 2,000 alle 3,000 miglia in più all'anno, hanno una probabilità inferiore del 4% di acquistare un veicolo elettrico rispetto a chi abita in contesti urbani.

Infine, l'analisi delle distanze percorse conferma che chi possiede un veicolo elettrico tende a percorrere meno miglia all'anno rispetto a chi possiede un veicolo a combustione interna, con una riduzione associata della probabilità di acquisto di veicoli elettrici all'aumentare delle distanze percorse.

Ipotesi 4 (H4) - Influenza della sensibilità ambientale sull'acquisto di veicoli BEV

Per l'ultima ipotesi, si analizza la variabile relativa all'importanza attribuita alla riduzione delle emissioni. Come anticipato nel Capitolo precedente, questa è una variabile quantitativa che assume valori compresi tra -3 e +3, con un valore neutrale pari a zero. Il valore di *OR* per questa variabile è pari a 1.105, un valore positivo che indica che all'aumentare dell'importanza attribuita a questo tema aumenta anche la probabilità di possedere un veicolo elettrico.

In termini quantitativi, per ogni incremento di un'unità nella valutazione di questa variabile, la probabilità di possedere un'auto elettrica aumenta del 11.052%. Pertanto, per un individuo che attribuisce un'importanza elevata alla riduzione delle emissioni, il cui punteggio può variare tra 2 e 3, la probabilità di possedere un veicolo elettrico rispetto a una persona che assegna un punteggio neutrale (zero) aumenta significativamente, oscillando tra il 21% e il 32%. Al contrario, per le persone che attribuiscono punteggi molto negativi (da -3 a -2), la probabilità di possedere un veicolo elettrico diminuisce tra il 21% e il 32%. Confrontando un individuo che attribuisce un'elevata importanza al tema della riduzione delle emissioni con uno che non lo considera rilevante, si osserva che la probabilità di possedere un'auto elettrica può aumentare tra il 42% e il 64% per il primo rispetto al secondo.

In conclusione, si può affermare che maggiore è la sensibilità ambientale delle persone, maggiore è la probabilità che esse possiedano un veicolo elettrico.

Sulla base delle quattro ipotesi e delle prime variabili analizzate, si può affermare che l'identificazione di potenziali acquirenti di veicoli elettrici richiede un'attenta considerazione di diversi fattori. In particolare, è importante valutare l'attitudine degli individui verso la sostenibilità e la riduzione delle emissioni, poiché una maggiore sensibilità ambientale è associata a una probabilità più alta di possedere un'auto elettrica.

Inoltre, il chilometraggio annuale rappresenta un altro elemento rilevante, in quanto un aumento delle distanze percorse è correlato a una minore probabilità di possesso di veicoli elettrici. Anche il reddito gioca un ruolo determinante: le auto elettriche, pur essendo supportate da incentivi, risultano ancora costose rispetto ai veicoli a combustione interna, rendendo i consumatori con redditi più alti più propensi all'acquisto.

Per quanto riguarda il tipo di veicolo posseduto in precedenza, è emerso che alcune categorie, come i veicoli ibridi o a metano, non risultano significative per il possesso attuale di un veicolo elettrico. Tuttavia, tra chi ha già posseduto veicoli elettrici, a combustione interna o ibridi plug-in, risulta più probabile la transizione verso un veicolo elettrico. In particolare, chi ha già posseduto un veicolo elettrico ha una maggiore probabilità di acquistarlo nuovamente, così come coloro che provengono da un veicolo a combustione interna rispetto a chi possedeva un veicolo ibrido plug-in.

5.2.3 RISULTATI DELLE ALTRE VARIABILI

In questo Paragrafo sono analizzate le ulteriori variabili significative del modello. La prima variabile, il genere, mostra un valore di *OR* di 1.2461, il che indica che un soggetto di sesso maschile ha una probabilità di possedere un veicolo elettrico superiore del 24.61% rispetto a un soggetto di sesso femminile.

Relativamente alla classe d'età, la Tabella 5 evidenzia come le classi 55-64, 65-74 e >80, rispetto alla classe di riferimento 45-54, presentino valori di *OR* inferiori a 1. Questo suggerisce che, per queste fasce di età, la probabilità di possedere un veicolo elettrico rispetto alla classe di riferimento diminuisce. Le classi restanti, invece, non risultano significative, indicando che l'appartenenza a tali fasce d'età non altera la probabilità di possedere o meno un veicolo elettrico. Nello specifico, la classe 55-64 ha un *OR* di 0.79374, che implica una riduzione del 20.63% della probabilità di possedere un'auto elettrica rispetto ad un caso che appartiene alla classe 45-54. La classe successiva, 65-74, presenta un *OR* di 0.70751, quindi la probabilità di possedere un'auto elettrica diminuisce del 29.25% rispetto alla classe 45-54. Per le persone con età superiore agli 80 anni, l'*OR* è pari a 0.50308, indicando una riduzione del 49.69%, sempre in confronto alla classe 45-54. L'adozione di una variabile categoriale per rappresentare l'età, così come per la variabile che misura il reddito, risulta limitante poiché comporta una perdita di precisione nell'analisi. Ad esempio, nella categoria di riferimento considerata, una persona di 45 anni viene equiparata a una di 54 anni, senza distinguere l'effettiva differenza d'età tra i due individui. Inoltre, l'uso di una variabile quantitativa permetterebbe di calcolare con maggiore accuratezza gli effetti della variabile indipendente su quella dipendente, incrementando così la precisione e l'affidabilità complessiva dei risultati dell'analisi.

Analizzando il livello di istruzione, le modalità confrontate con il livello di laurea magistrale o dottorato risultano significative, ad eccezione della licenza media. Le categorie del diploma e della laurea triennale, hanno valori di *OR* inferiori a 1, ovvero indicano che un livello di istruzione inferiore riduce la probabilità di possedere un veicolo elettrico rispetto a chi possiede un titolo di laurea magistrale o dottorato. Chi ha un diploma rispetto a un laureato magistrale o che possiede un dottorato ha un *OR* di 0.69768, con una probabilità inferiore del 30.3%. Chi ha una laurea triennale presenta un *OR* di 0.88603, suggerendo una probabilità ridotta dell'11.4% di possedere un veicolo elettrico. È plausibile che il livello di istruzione possa essere correlato alla classe di reddito, dato che un reddito elevato potrebbe rappresentare una condizione necessaria per l'acquisto di un veicolo elettrico, mentre un'istruzione elevata può facilitare l'accesso a un reddito più alto. Analizzando i dati elaborati da Silicon Valley Indicator basati sullo United States Census Bureau, si osserva infatti che in California, nel 2019 (anno di creazione del dataset), il reddito medio varia sensibilmente a seconda del livello di istruzione: da circa 33,000 \$ annui per chi possiede solo una licenza media, a 41,000 \$ per chi ha un diploma, fino a 92,000 \$

per una laurea triennale e 138,000 \$ per una laurea magistrale¹⁹. Per verificare la relazione tra queste due variabili nel dataset, è stato calcolato sia il coefficiente D di Somers sia il coefficiente Tau-b di Kendall, entrambi con un valore pari a -0.003 e un p-value di 0.727. Con questi risultati, si può affermare che non emerge un'associazione significativa tra livello di istruzione e classe di reddito; pertanto, i dati non supportano l'ipotesi di dipendenza tra queste variabili, suggerendo che, nel dataset, livello di istruzione e reddito familiare siano indipendenti.

Infine, per le variabili relative alle caratteristiche abitative, si considerano la proprietà della casa e la dimensione del nucleo familiare. La proprietà dell'abitazione presenta un *OR* di 1.25358, indicando che chi vive in una casa di proprietà ha una probabilità di possedere un veicolo elettrico superiore del 25.36% rispetto a chi vive in affitto. La variabile legata alla dimensione familiare mostra un *OR* di 1.15027, suggerendo che, per ogni componente aggiuntivo nel nucleo familiare, la probabilità di possedere un'auto elettrica aumenta del 15.03%. Ad esempio, una famiglia di quattro persone ha una probabilità di possedere un veicolo elettrico superiore del 30.06% rispetto a una famiglia di due persone e del 45.09% rispetto a una famiglia composta da una singola persona. Di conseguenza, un maggior numero di componenti nel nucleo familiare è associato a una più alta probabilità di possedere un veicolo elettrico.

5.3 LIBRERIE PYTHON PER L'ANALISI DI REGRESSIONE LOGISTICA

In questo Capitolo, oltre a pandas e numpy già trattate precedentemente, è stata utilizzata la libreria *statsmodels.api* per l'analisi statistica, in particolare per la regressione logistica. Il notebook Python è disponibile nella repository GitHub al seguente link:

https://github.com/FedeGambe/Master_s_thesis_Data_science/tree/130fcd101bc663d0ee1730347088c6fb0b4db5d5/Analisi_Statistiche

I concetti trattati in questo Capitolo sono legati ai seguenti capitoli del notebook:

- Sottoparagrafo 5.2.1 - Applicazione e spiegazione generale del modello. (Par. 5.2 del Notebook Python. [Analisi Statistiche: Regressione Logistica](#)).
- Sottoparagrafo 5.2.2 - Risultati delle variabili legate alle ipotesi di ricerca. (Par. 5.3 del Notebook Python. [Analisi Statistiche: Validazione Ipotesi: analisi delle variabili](#)).
- Sottoparagrafo 5.2.3 - Risultati delle altre variabili. (Par. 5.4 del Notebook Python. [Analisi Statistiche: Analisi delle restanti variabili](#)).

¹⁹ Silicon Valley Indicators, Individual Median Income, by Educational Attainment, <https://siliconvalleyindicators.org/data/economy/income/personal-income/individual-median-income-by-educational-attainment/>

CAPITOLO 6

ANALISI ESPLORATIVE

6.1 PREPARAZIONE

In questo Capitolo vengono trattate le analisi esplorative, che consistono in un insieme di tecniche utilizzate per ridurre e semplificare i dati, individuando le ricorrenze presenti. Queste tecniche, a differenza della regressione logistica discussa nel Capitolo precedente, non si basano su una relazione causa-effetto, bensì su un approccio simmetrico. Esse rientrano nei modelli non supervisionati, dove non è presente una variabile dipendente e quindi non si cerca una causalità. Le principali tecniche di analisi esplorativa trattate includono:

- **Analisi delle corrispondenze multiple (MCA):** una tecnica utilizzata per ridurre la complessità delle variabili categoriali, identificando dimensioni latenti che spiegano le relazioni tra le variabili.
- **Analisi delle componenti principali (PCA):** una tecnica utilizzata per ridurre la complessità delle variabili quantitative, identificando nuove dimensioni che massimizzano la varianza spiegata.
- ***Factor Analysis of Mixed Data (FAMD):*** una combinazione di MCA e PCA, utilizzata per analizzare e ridurre la complessità di dataset contenenti sia variabili quantitative che categoriali.

Queste tecniche sono fondamentali per comprendere le strutture sottostanti nei dati e per preparare il terreno a successive analisi più dettagliate, come l'analisi cluster. Sono state effettuate analisi delle corrispondenze multiple su gruppi di variabili e una "*Factor Analysis of Mixed Data*" (FAMD) allo scopo di ridurre la complessità delle variabili, seguite da un'analisi cluster. L'analisi cluster rappresenta il nucleo di questo Capitolo, con l'obiettivo di identificare cluster, ovvero target di persone che possiedono un'auto elettrica. Le caratteristiche emerse dall'analisi cluster permetteranno di delineare gruppi di potenziali acquirenti di auto elettriche.

Come anticipato nel Capitolo 3, per questo Capitolo è stato creato un nuovo dataset in cui tutte le variabili sono qualitative. La conversione da variabili quantitative a qualitative è stata realizzata tramite Python. Le variabili convertite sono: “numero di persone in famiglia”, “numero di auto in famiglia”, “importanza di ridurre le emissioni di gas serra”, “viaggio più lungo negli ultimi 12 mesi”, “numero di viaggi superiori a 200 miglia negli ultimi 12 mesi”, “distanza casa-lavoro” e “VMT annuo”, di seguito verranno riportate le trasformazioni.

Le modalità delle variabili che misurano la composizione del nucleo familiare sono: single, coppie, famiglie con un figlio, famiglie con due figli e famiglie con tre o più figli. Per la variabile che misura il numero di auto possedute, le modalità sono: un’auto, due auto, tre auto, quattro o più auto.

Per la variabile “Importanza di ridurre le emissioni di gas serra”, sono stati identificati cinque punti equidistanti nella distribuzione: -3, -1.5, 0, 1.5 e 3, con l’obiettivo di creare una scala dispari comprendente un valore neutro. Successivamente, sono state calcolate le classi, ottenendo i seguenti intervalli:

- Molto bassa: [-3, -2.25],
- Bassa: [-2.25, -0.75],
- Media: [-0.75, 0.75],
- Alta: [0.75, 2.25],
- Molto alta: [2.25, 3].

Per le variabili legate alla mobilità, ad eccezione del Numero di viaggi superiori a 200 miglia negli ultimi 12 mesi”, sono state analizzate le distribuzioni per definire le categorie. Per la variabile “Viaggio più lungo negli ultimi 12 mesi”, i punti di riferimento sono stati i quartili, ottenendo le seguenti classi:

- Meno di 175 miglia,
- Tra 175 e 350 miglia,
- Tra 350 e 550 miglia,
- Più di 550 miglia.

Per la variabile “Numero di viaggi superiori a 200 miglia negli ultimi 12 mesi”, sono state create le classi sulla base della distribuzione osservata: nessun viaggio, un viaggio, due viaggi e tre o più viaggi lunghi all’anno.

Per la variabile “Distanza casa-lavoro”, sono stati considerati i quartili, suddividendo le osservazioni in cinque classi:

- Meno di 6.5 miglia,
- Tra 6.5 e 15 miglia,
- Tra 15 e 25 miglia,
- Tra 25 e 45 miglia,
- Più di 45 miglia.

Infine, per la variabile “VMT annuo”, sono state create cinque classi, utilizzando il valore centrale dei singoli quartili:

- Molto basso: [7.0, 4,199.0],
- Basso: [4,199.0, 9,974.0],
- Medio: [9,974.0, 13,758.0],
- Alto: [13,758.0, 196,980.0],
- Molto alto: [196,980.0, 378,000].

Dopo aver convertito tutte le variabili e creato il nuovo dataset_eda, per effettuare le analisi delle corrispondenze multiple, l'analisi FAMD e l'analisi cluster è stato utilizzato R.

6.2 RIDUZIONE DELLE VARIABILI: FAMD, MCA E PCA

L'obiettivo di questo Capitolo, come anticipato nel Paragrafo precedente, è di individuare possibili cluster di persone che attualmente possiedono un'auto elettrica e, basandosi sulle loro caratteristiche, identificare cluster di potenziali futuri utilizzatori di auto elettriche. Prima di effettuare l'analisi cluster, sono state condotte alcune analisi preliminari per verificare la possibilità di ridurre le variabili, rendendo così i risultati più facilmente interpretabili.

6.2.1 FAMD

La *Factor Analysis of Mixed Data* (FAMD) è una tecnica che consente di analizzare e ridurre la complessità delle variabili, sia quantitative che qualitative, esaminando le somiglianze tra le osservazioni e tenendo conto di tutte le variabili. Secondo A. Kassambara, l'algoritmo FAMD può essere considerato una combinazione tra l'analisi delle componenti principali (PCA) e l'analisi delle corrispondenze multiple (MCA), funzionando come una PCA per le variabili quantitative e come una MCA per le variabili qualitative²⁰. Durante l'analisi, le variabili quantitative e qualitative vengono normalizzate per bilanciare l'influenza di ciascun gruppo di variabili, consentendo così di condurre un'unica analisi considerando tutte le variabili di diversa natura.

L'analisi è stata condotta utilizzando il software R e le librerie FactorMineR²¹ per l'analisi e factoextra²² per la visualizzazione dei dati. Di default, la funzione FAMD del pacchetto FactorMineR visualizza i risultati su 5 dimensioni, ma per questa analisi è stato impostato un numero di 10 dimensioni visibili nei risultati.

20 Kassambara, A. (2017). Practical guide to principal component methods in R: PCA, (M)CA, FAMD, MFA, HCPC, factoextra. *STHDA*. Paragrafo: 7.1 Introduction

21 FactoMineR: Multivariate Exploratory Data Analysis and Data Mining, CRAN.R Project. <https://cran.r-project.org/package=FactoMineR>

22 factoextra: Extract and Visualize the Results of Multivariate Data Analyses, CRAN.R Project. <https://cran.r-project.org/package=factoextra>

L'obiettivo dell'analisi FAMD, come anche dell'analisi delle corrispondenze multiple, è di estrarre nuove dimensioni, ossia nuove variabili generate dalle variabili originali. Queste nuove dimensioni sono create in modo da massimizzare la varianza dei dati nelle prime dimensioni, rappresentando l'informazione in uno spazio ridotto con una minima perdita di informazione. Le prime dimensioni saranno caratterizzate da una maggiore varianza spiegata, che decresce progressivamente verso le dimensioni successive. Il numero di dimensioni estratte corrisponde alle nuove variabili ridotte, alle quali sarà necessario attribuire un significato.

L'analisi è stata applicata su un dataset contenente tutte le variabili nella loro forma originaria. Le variabili qualitative categoriali considerate includono: “genere”, “classe d'età”, “classe di reddito”, “livello di istruzione”, “possesso della casa”, “indipendenza dell'abitazione” e “tipologia di auto posseduta in precedenza”. Inizialmente è stata analizzata la varianza spiegata e la varianza accumulata. Come mostrano le Figure 28 e 29, la varianza spiegata dalle prime dimensioni è molto bassa: 7.6% per la prima dimensione, 5.4% per la seconda dimensione e 5.1% per la terza dimensione. Estrahendo tre dimensioni si ottiene una varianza accumulata di appena il 18.1%, un valore piuttosto basso.




Figure 28 e 29. Grafici per la varianza spiegata e per la varianza accumulata, con focus sulle prime 10 dimensioni




Figure 30 e 31. Grafici per la varianza spiegata e per la varianza accumulata, mostrando tutte e le 29 dimensioni

Con questo tipo di analisi è difficile raggiungere il 100% di varianza accumulata spiegata, poiché l'obiettivo principale non è spiegare tutta la varianza iniziale, ma semplificare le informazioni a costo di una lieve perdita di varianza. Secondo I.T. Jolliffe²³, una percentuale accettabile di varianza spiegata accumulata oscilla tra il 70% e il 90%. Nel caso di questa analisi, per raggiungere tali percentuali è necessario considerare molte dimensioni: per ottenere almeno il 70% di varianza spiegata occorre utilizzare 18 dimensioni, per raggiungere almeno l'80% sono necessarie 21 dimensioni, e per arrivare al 90% servono 25 dimensioni. Il numero massimo di dimensioni è 29. Dato che le variabili presenti nel dataset sono 15, non si è ritenuto opportuno proseguire con l'analisi FAMD, nel Paragrafo successivo verrà trattata l'analisi delle corrispondenze multiple per verificare la possibilità di ridurre le informazioni.

6.2.2 MCA

Poiché le nuove dimensioni individuate tramite l'analisi FAMD non permettevano una riduzione significativa delle variabili iniziali senza una consistente perdita di varianza accumulata, è stata condotta un'analisi delle corrispondenze multiple (MCA). Come indicato all'inizio di questo Capitolo, è stato utilizzato il dataset EDA, in cui tutte le variabili sono qualitative, categoriali e ordinali.

L'analisi delle corrispondenze multiple è un'estensione dell'analisi delle corrispondenze semplici, che analizza tipicamente solo due variabili qualitative. In questo caso è possibile analizzare più di due variabili. Analogamente alla tecnica precedente, la FAMD, la MCA è utilizzata per individuare dimensioni latenti e spiegare le variabili iniziali in meno dimensioni. A differenza delle corrispondenze semplici, il grafico ottenuto dall'analisi delle corrispondenze multiple permette di individuare l'associazione tra due variabili analizzando la loro vicinanza nel grafico. Questo risulta utile per validare l'analisi VIF precedentemente effettuata, al fine di verificare la collinearità delle variabili "casa di proprietà", "casa indipendente", "numero di persone in famiglia" e "numero di auto in famiglia". Anche in questa tecnica vengono estratte diverse dimensioni, ciascuna delle quali spiega una percentuale di varianza. Le prime dimensioni spiegano una quota maggiore di varianza, mentre le dimensioni successive spiegano percentuali minori. Come per l'analisi FAMD, è stato utilizzato il software R, impiegando le librerie FactorMineR e factoextra, e utilizzando il dataset data_edu precedentemente descritto, contenente solo variabili qualitative. È stata condotta una prima analisi MCA iniziale su tutte le variabili presenti nel dataset, seguita da tre analisi relative ai gruppi di variabili socio-demografiche, di mobilità e percorrenza, e abitative. Per ogni tipologia di analisi MCA sono stati creati nuovi data frame contenenti soltanto le variabili di interesse. Inoltre, per l'analisi relativa al gruppo delle variabili socio-demografiche, le modalità della variabile "classe di età" sono state raggruppate in quattro nuove categorie: under 35, da 35 a 44, da 45 a 64 e over 65.

MCA Totale, su tutte le variabili

Come prima analisi, è stata condotta un'analisi delle corrispondenze multiple sull'intero dataset, con l'obiettivo di individuare nuove dimensioni che spiegassero una buona percentuale di varianza, al fine di ottenere meno variabili per l'analisi cluster.

Come illustrato nelle Figure 32 e 33, per ottenere una quota di varianza ritenuta accettabile per questa analisi (70-90%), è necessario un numero considerevole di dimensioni.

Il dataset contiene 16 variabili, e se si prendessero 15 nuove dimensioni la varianza accumulata spiegata sarebbe del 44.94, quindi per ridurre soltanto di una variabile si perderebbe moltissima capacità di spiegazione da parte delle nuove variabili a fronte di una riduzione minima delle dimensioni. L'analisi MCA su l'intero dataset rispetto all'analisi precedente FAMD ha performato peggio, perché a dieci dimensioni estratte la varianza accumulata per l'analisi MCA è di 34.81%

Di conseguenza, si è proceduto con diverse analisi MCA sui differenti gruppi di variabili stabiliti precedentemente. Anche se queste ulteriori analisi MCA per gruppi non porteranno a una riduzione significativa delle variabili iniziali, saranno comunque utili per comprendere meglio le relazioni tra le variabili all'interno di ciascun gruppo, fornendo una panoramica più chiara.




Figure 32 e 33. Grafici per la varianza spiegata e per la varianza accumulata

MCA - Gruppo variabili abitative

Per le variabili relative al gruppo delle variabili abitative è stata effettuata un'analisi delle corrispondenze multiple (MCA) a seguito dell'analisi VIF, poiché queste variabili presentavano elevati coefficienti di multicollinearità, il cui obiettivo era verificare l'esistenza di relazioni tra le variabili.

L'analisi delle corrispondenze multiple per il gruppo di variabili abitative comprende le variabili: numero di persone in famiglia, numero di auto in famiglia (entrambe trasformate in variabili qualitative con cinque modalità di risposta ciascuna, come mostrato nell'introduzione di questo Capitolo), e due variabili già qualitative, ovvero se la casa è indipendente o meno e se la casa è di proprietà o meno.

Dalle Figure 34 e 35, si nota che le prime due dimensioni spiegano circa il 34% della varianza accu-

mulata totale, con la prima dimensione che spiega circa il 20% e la seconda circa il 14%. Dato che le variabili iniziali erano solo quattro, si è deciso di estrarre le prime due dimensioni, anche per poterle rappresentare graficamente.




Figure 34 e 35. Grafici per la varianza spiegata e per la varianza accumulata, per il gruppo di variabili abitative

Analizzando la Figura 36, che rappresenta il grafico a due dimensioni in cui sono proiettate le modalità delle variabili, si osserva che le variabili relative alla proprietà e indipendenza della casa mostrano punti molto vicini, suggerendo un'associazione tra queste caratteristiche. Una situazione simile si nota per le modalità delle variabili numero di persone in famiglia e numero di auto in famiglia: ad esempio, la modalità coppia è vicina al numero di due auto in famiglia, e la modalità famiglia con tre o più figli è vicina alla modalità più di quattro auto in famiglia. Questo conferma i risultati dell'analisi VIF, indicando che la rimozione di una delle variabili per ridurre i livelli di collinearità non dovrebbe compromettere l'analisi di regressione logistica del Capitolo precedente.




Figure 36. Rappresentazione grafica su due dimensioni del gruppo di variabili abitative




Figure 37 e 38. Grafici relativi alla percentuale di contributo delle modalità del gruppo delle variabili abitative

Dai grafici delle Figure 37 e 38 è possibile esaminare i contributi delle varie modalità alle due dimensioni scelte. Nella prima figura, i contributi più rilevanti alla prima dimensione includono: non possedere una casa di proprietà (18.7%), non possedere una casa indipendente (23.9%), possedere una sola auto (19.8%) ed essere single (15.4%). Un'interpretazione di questa dimensione potrebbe riferirsi a uno stile di vita caratterizzato da una limitata centralità dell'abitazione e una mobilità ridotta, suggerendo un profilo di individui con esigenze abitative più semplici o flessibili.

Analizzando le coordinate, i punti Casa di proprietà_No (1.70), Casa indipendente_No (1.75), Single (2.10) e Un Auto (2.73) hanno coordinate positive e molto alte. D'altra parte, le modalità Casa di proprietà_Sì (-0.22), Casa indipendente_Sì (-0.28) e Famiglie con 2 figli (-0.38) mostrano valori negativi, ma con contributi più bassi. Queste coordinate, insieme all'analisi dei contributi, indicano una contrapposizione tra individui in situazioni meno strutturate (affitto, case non indipendenti, single) e famiglie stabili che possiedono proprietà immobiliari e indipendenti, che seguono uno stile di vita più tradizionale americano. Inoltre, nella Figura 36, i punti relativi alla proprietà e indipendenza della casa sono molto vicini, suggerendo una relazione stretta. Altre modalità vicine includono coppie e nuclei familiari con due auto, grandi famiglie con tre o più figli e nuclei familiari con tre o quattro auto. Questo suggerisce che all'aumentare delle persone in famiglia aumentano anche le automobili.

Secondo l'*Office of Policy Development and Research* del *US Department of Housing and Urban Development*, la maggior parte delle famiglie statunitensi vive in contesti suburbani rispetto a contesti urbani e rurali. Questo supporta l'interpretazione che questa dimensione contrappone individui single in contesti urbani senza proprietà immobiliari a famiglie in contesti suburbani con case indipendenti di proprietà. Se si considerasse anche la variabile età, si noterebbe che la modalità under 35 si colloca come punto estremo sulla sinistra del grafico, indicando una relazione con il gruppo delle variabili abitative, e possiamo interpretare la prima dimensione come Stile di Vita: Urbano giovanile vs Suburbano Familiare.

Il secondo grafico (Figura. 38) relativo alla seconda dimensione mostra contributi elevati per le

modalità single (25.7%) e famiglie con un'auto (11.6%), ma anche per famiglie con due auto (14.6%), coppie (11.6%), famiglie con tre o più figli (7.3%) e famiglie con più di quattro auto (7.4%). Le coordinate positive più estreme sono per Single (2.29) e Un Auto (2.48), mentre le coordinate negative significative includono Coppie (-0.64) e Due Auto (-0.60). Questo suggerisce una contrapposizione tra famiglie numerose con un maggiore livello di motorizzazione e situazioni con pochi membri familiari (coppie) con meno auto a disposizione. Quindi, questa dimensione può essere interpretata come Dimensione Familiare, dove un maggior numero di auto è una conseguenza della grandezza del nucleo familiare.




Figura 39. Rappresentazione grafica su due dimensioni del gruppo di variabili abitative con l'aggiunta della variabile: Classe d'età

MCA - Gruppo variabili demografiche

Il gruppo delle variabili demografiche comprende le seguenti variabili: Genere, Classe di Reddito Familiare, Livello di Istruzione e Classe d'età (quest'ultima è stata modificata, come descritto nel Paragrafo 6.1, per creare un numero ridotto di classi). È stata inoltre aggiunta la variabile che misura la sensibilità verso l'ambiente. Di queste variabili, solo la variabile che misura la sensibilità ambientale non era qualitativa e, come descritto all'inizio di questo Capitolo, è stata trasformata in una variabile qualitativa con cinque modalità di risposta.

Procedendo con l'analisi MCA, si può osservare dalle Figure 40 e 41 che le prime dimensioni non hanno una grande capacità esplicativa, spiegando rispettivamente l'8.6% e il 7.8% della varianza. Sono state quindi scelte solo le prime due dimensioni, dato che le variabili inserite in questa analisi sono soltanto cinque. Dalla Figura 42, si possono osservare le modalità delle variabili inserite in questa analisi proiet-

tate su due dimensioni. In questo grafico, alcune modalità presentano desinenze maschili o femminili, ad esempio, “basso” e “bassa”. Le modalità con desinenza femminile si riferiscono alla variabile Classe di Reddito, mentre quelle con desinenza maschile si riferiscono al livello di sensibilità ambientale.




Figure 40 e 41. Grafici per la varianza spiegata e per la varianza accumulata, per il gruppo di variabili socio-demografiche




Figure 42. Rappresentazione grafica su due dimensioni del gruppo di variabili socio demografiche

Per quanto riguarda la prima dimensione, si notano punti con coordinate positive elevate per la classe d'età inferiore ai 35 anni (2.51) e la classe di reddito Bassa (2.54), mentre le coordinate negative estreme includono la classe di reddito Estremamente Alta (-1.04) e la Licenza Media (-0.69). Analizzando la percentuale di contribuzione delle modalità alla prima dimensione (figura 37), si osserva che la modalità relativa alla classe di reddito Media contribuisce per un 19%, seguita dalla classe d'età <35

per circa il 15%, dal Diploma o Qualifica professionale per il 12%, dalla Laurea 2L o Dottorato e dalla classe di reddito Estremamente Alta per circa il 10%. In base ai contributi delle modalità delle variabili e alle loro coordinate, per la prima dimensione si nota una contrapposizione tra giovani e persone con basso reddito, probabilmente con istruzione più bassa e situazioni economiche meno favorevoli, e persone con redditi elevati, spesso associate a livelli di istruzione avanzati e a uno stato economico più alto. Questo contrasto riflette una divisione tra persone con bassa istruzione e basso reddito, inclusi i giovani che potrebbero avere un reddito basso a causa della loro recente entrata nel mondo del lavoro o della minore esperienza rispetto alle persone di età superiore, e persone con istruzione elevata e redditi alti. Di conseguenza, questa dimensione può essere interpretata come una variabile di status socioeconomico.

Nella seconda dimensione, si trovano punti con coordinate positive elevate come il livello di sensibilità ambientale Molto Basso (1.29) e il livello di sensibilità ambientale Medio (1.16). Le coordinate negative includono la modalità over 65 per la classe d'età (-1.00), il livello di sensibilità ambientale Molto Alto (-0.60) e un punto estremo corrispondente alla Licenza Media. La percentuale di contribuzione delle modalità alla seconda dimensione vede principalmente la classe d'età over 65 contribuire per il 19.11%, seguita dal livello di sensibilità ambientale Molto Alto con il 18.60%. Altre modalità che contribuiscono per almeno il 5% includono il livello di sensibilità ambientale Medio, la classe d'età 35-44, il livello di sensibilità ambientale Molto Basso, il genere Femmina e il livello di sensibilità ambientale Alto.

Questa dimensione cattura principalmente la contrapposizione tra una sensibilità ambientale elevata e una sensibilità ambientale bassa. La sensibilità ambientale è stata misurata come l'importanza attribuita alla riduzione delle emissioni di gas serra. Dal grafico (Figura 42), si nota che all'aumentare della sensibilità ambientale aumenta anche la classe d'età, mentre una sensibilità ambientale più bassa è associata a classi d'età più giovani. In base alle coordinate dei punti e alla loro contribuzione alla seconda dimensione, questa può essere interpretata come una dimensione di distanza dalla sostenibilità ambientale: all'aumentare di questa dimensione, diminuisce il livello di sensibilità ambientale.




Figure 43 e 44. Grafici relativi alla percentuale di contributo delle modalità del gruppo delle variabili socio demografiche rispettivamente per la dimensione 1 e per la dimensione 2

MCA - Gruppo variabili di mobilità e percorrenza

L'ultimo gruppo di questa analisi delle corrispondenze multiple riguarda le variabili che misurano la mobilità e la percorrenza. Come anticipato all'inizio di questo Capitolo, queste variabili sono tutte quantitative e convertirle in variabili qualitative ne limita la capacità esplicativa. Le Figure 45 e 46 mostrano che le prime due dimensioni spiegano una varianza accumulata di circa il 25%. Sebbene la capacità esplicativa non sia elevata, sono state prese due dimensioni in considerazione per ridurre il numero di variabili in questo gruppo.




Figure 45 e 46. Grafici per la varianza spiegata e per la varianza accumulata, per il gruppo di variabili socio-demografiche

Analizzando la Figura 47, si possono individuare le coordinate negative elevate nella prima dimensione, corrispondenti a viaggi inferiori a 175 miglia (-1.62), chi non effettua viaggi lunghi (-1.47) e altre coordinate negative meno estreme come il tragitto casa-lavoro inferiore a 6.5 miglia e tra 6.5 e 15 miglia. Nella parte positiva della prima dimensione si trovano punti come viaggio tra 350 e 550 miglia, un viaggio lungo all'anno, tre o più viaggi lunghi all'anno, viaggio superiore a 550 miglia, e altre modalità rappresentate nel grafico.

Per quanto riguarda le modalità che contribuiscono a costruire la prima dimensione, la modalità che prevede un viaggio inferiore a 175 miglia ha un contributo di circa il 35%, seguita dalla modalità "chi non fa viaggi lunghi" con circa il 34%, mentre le modalità "viaggio tra 350 e 550 miglia" e "un viaggio lungo all'anno" hanno contributi rispettivamente dell'8% e dell'8.5%. In base ai contributi e alle coordinate, la prima dimensione riflette l'intensità e la frequenza dei viaggi lunghi, distinguendo tra chi viaggia poco o non viaggia affatto e chi viaggia frequentemente percorrendo lunghe distanze. Un nome per questa dimensione potrebbe essere "intensità dei viaggi lunghi".

Per la seconda dimensione, le coordinate estreme positive sono associate alle modalità: VMT Molto alto (2.24), Casa-Lavoro: più di 45 miglia (1.96), VMT Alto (1.21) e tre o più viaggi lunghi (1.07). Le coordinate negative non presentano valori estremi, ma includono le modalità: Casa-Lavoro: meno di 6.5 miglia (-0.54), Casa-Lavoro: tra 6.5 e 15 miglia (-0.45) e VMT Molto Basso.




Figura 47. Rappresentazione grafica su due dimensioni del gruppo di variabili socio demografiche

Per quanto riguarda i contributi delle modalità alla costruzione della seconda dimensione, la modalità VMT Alto ha la percentuale più alta (27%), seguita da VMT Basso (14%) e da tre o più viaggi lunghi (13%). Altri contributi significativi includono il tragitto casa-lavoro superiore a 45 miglia (13%), il tragitto casa-lavoro tra 25 e 45 miglia e un viaggio lungo all'anno.




Figure 48 e 49. Grafici relativi alla percentuale di contributo delle modalità del gruppo delle variabili socio demografiche rispettivamente per la dimensione 1 e per la dimensione 2

In base ai contributi e alle coordinate, questa dimensione rappresenta la combinazione tra distanza giornaliera percorsa per recarsi al lavoro e il livello di utilizzo del veicolo. Questa dimensione contrappone chi percorre lunghe distanze quotidianamente, e quindi ha un chilometraggio dell'auto elevato, a chi percorre distanze più ridotte. Il nome per questa dimensione, e per una futura variabile, potrebbe essere “mobilità quotidiana”, che cattura la distanza giornaliera percorsa per recarsi al lavoro e il conseguente livello di utilizzo dell'auto.

6.2.3 PCA

L'analisi delle componenti principali (PCA) è una tecnica che consente di ridurre la complessità delle variabili originali, a condizione che siano di natura quantitativa. Poiché le variabili relative alla mobilità e alla percorrenza sono tutte qualitative, e considerando che l'analisi precedente non riusciva a spiegare nemmeno il 30% della varianza totale con due dimensioni, si è optato per questa tipologia di analisi, con l'obiettivo di verificare se sia possibile ridurre il numero di dimensioni mantenendo una quota di varianza spiegata superiore a quella ottenuta in precedenza.

Reliability analysis
Call: alpha(x = data_pca)

raw_alpha	std_alpha	G6(smc)	average_r	S/N	ase	mean	sd	median_r
0.0025	0.33	0.28	0.11	0.49	0.00088	3294	3493	0.13

Tabella 6: Risultati: Alpha di Cronbach

Prima di effettuare l'analisi delle componenti principali, è prassi analizzare l'*Alpha di Cronbach*, un coefficiente che misura il grado di correlazione tra le variabili inserite nel modello. Il coefficiente varia da zero a uno: un risultato pari a zero indica variabili indipendenti, rendendo difficile creare poche dimensioni che spieghino la maggior parte della varianza, mentre un valore pari a uno indica variabili perfettamente correlate. I limiti soglia considerati accettabili si attestano intorno allo 0.7 - 0.8 (buono), 0.9 (eccellente), mentre valori molto elevati come 0.95 o 1 potrebbero suggerire una ridondanza tra le variabili nel modello. Per questa analisi sono state utilizzate le stesse librerie impiegate per l'analisi delle corrispondenze multiple e l'analisi dei dati misti, oltre alla libreria “psych²⁴” per il calcolo dell'*Alpha di Cronbach*.

24 psych: Procedures for Psychological, Psychometric, and Personality Research, CRAN.R Project. <https://cran.r-project.org/package=psych>

Dalla Tabella 6 è possibile analizzare l'output del calcolo dell'*Alpha di Cronbach*, con i valori di "*raw_alpha*" e "*std.alpha*". Poiché le variabili non sono ancora state scalate, presentando su alcune valori molto alti (es. VMT) e su altre valori molto bassi (es. "Numero di viaggi superiori a 200 miglia negli ultimi 12 mesi" e "Distanza casa-lavoro"), viene preso in esame lo "*std.alpha*", ovvero alpha standardizzato. Il valore di "*std.alpha*" trovato è molto basso (0.33), suggerendo che le variabili siano poco correlate tra loro. Calcolando la matrice di correlazione (Figura 50), si nota infatti una scarsa correlazione tra le variabili.




Figura 50, Matrice di correlazione per il gruppo delle variabili di mobilità e percorrenza




Figure 51 e 52. Grafici per la varianza spiegata e per la varianza accumulata (PCA), per il gruppo di variabili di mobilità e percorrenza

Le figure successive mostrano che estraendo le prime due dimensioni si riesce a spiegare il 60% della varianza (Figura 52). Questo tipo di analisi risulta più efficiente rispetto a quella condotta precedentemente. Tuttavia, dalla Figura 51 si osserva che le prime dimensioni non spiegano significativamente più varianza rispetto alle altre: la prima dimensione spiega il 33% della varianza, la seconda il 26%, la terza il 21% e la quarta il 20%. In genere, nelle analisi delle componenti principali, le prime dimensioni hanno una capacità esplicativa nettamente maggiore rispetto alle successive. Questo suggerisce che le nuove dimensioni non riescono a concentrare la varianza delle variabili iniziali in poche dimensioni, probabilmente a causa del basso coefficiente di *Alpha di Cronbach* e della scarsa correlazione tra le variabili.

Dalla Figura 54, si possono analizzare i vettori che rappresentano le variabili originali e come contribuiscono alla creazione delle prime due dimensioni, esprimendo la direzione delle variabili che spiegano le due dimensioni.

Feature	PC1	PC2	PC3	PC4
Variabili di mobilità e percorrenza				
Viaggio più lungo negli ultimi 12 mesi	-0.3696	0.7192	0.2728	-0.5213
Numero di viaggi superiori a 200 miglia negli ultimi 12 mesi	-0.5982	0.2948	-0.2388	0.7059
Distanza casa-lavoro	-0.5336	-0.4034	-0.5704	-0.4767
VMT annuo	-0.4610	-0.4828	0.7370	0.0528

Tabella 7: Fattori estratti relativi alle variabili e alle quattro dimensioni




Figura 53, 54 e 55. Grafici PCA: nel primo sono visualizzate sia le osservazioni che le variabili rappresentate come vettori; nel secondo sono mostrati solo i vettori per una visualizzazione più chiara di questi ultimi; e nel terzo sono presenti esclusivamente la distribuzione delle osservazioni.

I vettori VMT e Distanza casa-lavoro, come si nota dal grafico, sono molto vicini e in direzione della prima dimensione, contribuendo quindi a costruirla. Il vettore Viaggio più lungo è ortogonale ai precedenti e opposto alle altre due variabili, contribuendo alla seconda dimensione, mentre il vettore Numero di viaggi lunghi, pur non essendo ortogonale, tende a contribuire alla costruzione della seconda dimensione. Questi risultati sono simili a quelli ottenuti nell'analisi MCA dello stesso gruppo di variabili, dove si ottenne una dimensione caratterizzata principalmente dalle variabili VMT e Distanza casa-lavoro (nella MCA era la seconda dimensione, mentre nella PCA la prima) e un'altra dimensione caratterizzata principalmente dalle variabili Viaggio più lungo e Numero di viaggi lunghi.

6.2.4 CONCLUSIONI

In conclusione, le analisi esplorative effettuate per ridurre le variabili di partenza e creare nuove dimensioni ridotte non ha portato a risultati sperati, ha permesso di evidenziare degli schemi tra le variabili originali, ma con delle limitazioni nella capacità di riduzione delle variabili.

La *Factor Analysis of Mixed Data* è stata efficace nel combinare variabili quantitative e qualitative, ma le dimensioni estratte spiegano una varianza accumulata molto bassa. Dalle 16 variabili iniziali usate per queste analisi, per ridurle a 10 dimensioni avremmo ottenuto una varianza accumulata molto bassa, neanche del 50%. Per ottenere una rappresentazione soddisfacente (>70% varianza spiegata) sarebbero necessarie 18 dimensioni, rendendo la tecnica non adatta a semplificare le variabili di partenza.

La Analisi delle Corrispondenza Multiple (MCA) è stata fatta sia su tutte le variabili, per cercare di ridurre la complessità, che su gruppi di variabili. Per questa tipologia di analisi è stato utilizzato il dataset *data_eda*, nel quale le variabili quantitative sono state convertite a variabili qualitative. Come per la FAMD, la MCA non è riuscita a ridurre le variabili iniziali in nuove variabili per ridurre le dimensioni mantenendo comunque una certa percentuale di varianza spiegata, infatti se si volessero estrarre 10 nuove dimensioni si otterrebbe una varianza accumulata ancora più bassa rispetto a quella ottenuta dalla FAMD, non raggiungendo nemmeno il 40%. Le analisi MCA applicate a gruppi di variabili (abitative, demografiche, di mobilità) hanno però mostrato risultati più utili per esplorare associazioni tra modalità delle variabili, nonostante la loro capacità esplorativa limitata. Infine, le modalità di alcune variabili hanno mostrato una forte associazione interna, suggerendo che alcune possono essere rimosse senza perdita significativa di informazione, come si era potuto constatare dall'analisi VIF.

Infine, l'analisi delle componenti principali ha mostrato una maggiore capacità di riduzione delle variabili per il gruppo di mobilità e percorrenza rispetto alla MCA, spiegando il 60% della varianza con due dimensioni. Tuttavia, la bassa correlazione tra le variabili, e di conseguenza il basso livello dei coefficienti di *Alpha di Cronbach*, riduce la capacità delle nuove dimensioni di sintetizzare efficacemente le variabili originali.

6.3 ANALISI CLUSTER

Questo Paragrafo si concentra sull'analisi e l'individuazione di gruppi all'interno del dataset. I dati utilizzati includono esclusivamente le osservazioni relative ai possessori attuali di veicoli elettrici, come spiegato nei paragrafi precedenti. In base alle caratteristiche dei gruppi individuati, sarà possibile fare inferenze su possibili gruppi di futuri consumatori e utilizzare tali caratteristiche per mirare il mercato delle auto elettriche. L'obiettivo è individuare possibili gruppi all'interno delle oltre 5,000 osservazioni di possessori di veicoli elettrici.

L'analisi cluster, come le precedenti analisi FAMD, MCA e PCA, è un metodo esplorativo che non richiede la presenza di una variabile dipendente. Si tratta, quindi, di un'analisi di tipo asimmetrico che non prevede una relazione causa-effetto tra le variabili. Questo metodo mira a ridurre la complessità delle osservazioni raggruppandole in cluster, che devono essere omogenei e coesi al loro interno, ma differenti tra loro. Per individuare il numero ideale di gruppi, sono state effettuate diverse tipologie di analisi cluster utilizzando vari metodi, al fine di determinare quale fosse il migliore. Inizialmente verrà presentato il metodo *K-means*, seguito dal metodo *K-mode*. Una volta individuato il metodo migliore, si analizzerà la distribuzione delle variabili per ogni cluster, per comprendere meglio i gruppi ottenuti.

Per queste analisi, condotte utilizzando il software R, oltre ai pacchetti già utilizzati in precedenza (factoextra e FactorMineR), è stata impiegata la libreria “cluster²⁵”. Prima di procedere con un'analisi cluster utilizzando algoritmi partizionali, è stata condotta un'analisi gerarchica divisiva. Questo tipo di analisi inizia con un singolo gruppo che viene successivamente suddiviso in gruppi più piccoli, fino a raggiungere gruppi singoli. L'obiettivo era ottenere una visione preliminare della struttura dei gruppi all'interno del dataset. Dalla Figura 56 è possibile osservare la dendrogramma risultante, che mostra chiaramente la formazione di quattro gruppi distinti. Questo risultato suggerisce che esistono quattro cluster naturali tra le osservazioni di possessori di veicoli elettrici. L'analisi gerarchica divisiva è particolarmente utile perché fornisce una rappresentazione visiva della struttura dei dati, permettendo di identificare il numero ottimale di cluster. Inoltre, questo approccio non richiede di specificare il numero di cluster a priori, a differenza dei metodi partizionali come *K-means*.

In sintesi, l'analisi gerarchica divisiva ha fornito una solida base per individuare la struttura interna del dataset, evidenziando la presenza di quattro gruppi principali. Questo risultato ha guidato le successive analisi cluster, permettendo di confrontare e validare i cluster ottenuti con i metodi partizionali.

25 cluster: “Finding Groups in Data”: Cluster Analysis Extended Rousseeuw et al., CRAN.R Project. <https://cran.r-project.org/package=cluster>




Figura 56 Dendrogramma dell'analisi gerarchica, con focus su 4 gruppi

6.3.1 ALGORITMO K-MEANS

Il metodo *K-means* fa parte delle analisi non gerarchiche ed è uno dei metodi più utilizzati negli algoritmi di *machine learning* non supervisionati per suddividere il dataset in k gruppi. Esso classifica le osservazioni in diversi gruppi, in modo che i gruppi siano il più possibile omogenei al loro interno, ossia con alta somiglianza intraclasse, e diversi tra loro, cioè con bassa somiglianza interclasse. Ogni gruppo così ottenuto è rappresentato dal centroide, che corrisponde alla media dei punti del gruppo.

Questo metodo cerca di individuare il numero dei gruppi tale che la varianza intraclasse, chiamata anche *intra-cluster variation* o *total within-cluster variation*, sia la più bassa possibile. Per effettuare questo tipo di analisi, esistono diverse tipologie di algoritmi. In questa analisi per il metodo *K-means* è stato utilizzato l'algoritmo standard di *Hartigan-Wong*, che definisce il totale della varianza intraclasse come la somma delle distanze euclidee al quadrato delle osservazioni rispetto al centroide.

$$\text{tot.withinss} = \sum_{k=1}^K W(C_k) = \sum_{k=1}^K \sum_{x_i \in C_k} (x_i - \mu_k)^2$$

Dove:

- *tot.withinss* è la somma totale delle distanze quadrate all'interno di tutti i cluster e misura quanto i gruppi sono compatti e, di conseguenza, quanto è buona l'analisi. È desiderabile ottenere il valore più basso possibile,
- $W(C_k)$ rappresenta la varianza intracluster di un cluster C_k ,
- x_i è un punto di dati appartenente al k-esimo cluster C_k ,
- μ_k è il centroide del k-esimo cluster C_k .

Per l'analisi cluster con la metodologia *K-means* è necessario stabilire il numero di gruppi in cui suddividere tutte le osservazioni. Per determinare il numero ottimale di gruppi, vengono analizzati i grafici *Elbow* e *Silhouette*, Figure 57 - 64. I grafici *Elbow* mostrano la somma dei quadrati intraclasse (*WCSS*) in relazione al numero di cluster, generalmente indicando che più cluster si utilizzano, più questo valore diminuisce. Questi grafici aiutano a scegliere il numero ottimale di cluster da utilizzare, spesso individuando il punto in cui la variazione di *WCSS* inizia a ridursi significativamente. I grafici *Silhouette* utilizzano l'*indice di Silhouette*, che misura quanto ogni osservazione è simile alle osservazioni del proprio cluster rispetto a quelle degli altri cluster. L'indice varia tra -1 e +1, dove valori più alti indicano cluster più coesi.

Nelle Figure 51 - 58 sono presenti 4 grafici *Elbow* e 4 grafici *Silhouette*, poiché sono state testate quattro diverse versioni del dataset:

1. La prima versione, relativa ai primi due grafici, fa riferimento al dataset completo contenente tutte le variabili (quantitative e qualitative dicotomizzate).
2. Nella seconda versione, rappresentata dai grafici 3 e 4, le variabili del gruppo variabili abitative sono state sostituite con le nuove dimensioni trovate nell'analisi MCA riguardante tali variabili.
3. La terza versione, corrispondente ai grafici 5 e 6, ha sostituito le variabili del gruppo mobilità e percorrenza con le dimensioni trovate nell'analisi PCA e ha rimosso le variabili livello di istruzione e di reddito.
4. Nell'ultima versione, rappresentata dai grafici 7 e 8, sono state rimosse le variabili genere e sensibilità ambientale, mantenendo solo le variabili ritenute più rilevanti per suddividere i gruppi: classe d'età, le due dimensioni dell'analisi MCA abitative (dimensione familiare e stili di vita), la tipologia di auto posseduta in precedenza e le due dimensioni trovate nell'analisi PCA (mobilità quotidiana e viaggi).

Per ogni versione è stato creato un dataset ad hoc contenente solo le variabili elencate e queste variabili sono state standardizzate. Dai grafici emerge che l'ultima versione, rappresentata dai grafici 63 e 64, appare essere la migliore sia per quanto riguarda la somma dei quadrati intra-cluster che per l'indice di *Silhouette* medio.




Figura 57 - 64. Grafici Elbow e Silhouette (Algoritmo K-means)

Analizzando questi grafici, si può concludere che il numero ideale di cluster per questa tipologia di analisi è quattro, poiché il valore *WCSS* dopo 4 cluster diminuisce di poco, e presenta valori di Silhouette medio più alti, subito dopo i 5 cluster. I valori con quattro cluster sono: somma dei quadrati intra-cluster di 34,629.87 e Silhouette medio di 0.3953377. Sebbene il valore di Silhouette non sia ottimale (buoni risultati si ottengono con valori superiori a 0.5), il valore trovato di circa 0.4 non è troppo basso, indicando che la separazione tra i cluster non è molto netta, ma nemmeno del tutto confusa. In generale, i punti sono abbastanza separati, ma potrebbero esserci delle sovrapposizioni.

Queste operazioni per l'identificazione dei cluster sono state eseguite su R. Successivamente, è stata aggiunta al dataset una variabile "cluster" per indicare il numero del cluster di appartenenza di ciascuna osservazione. Questo nuovo dataset è stato analizzato con Python per comprendere la distribuzione delle variabili in base ai cluster trovati.

Con l'algoritmo *K-means*, le variabili risultano distribuite in maniera molto simile tra tutti i 4 cluster. Pertanto, questa analisi non è risultata utile per individuare gruppi con caratteristiche distintive tra i possessori di auto elettriche.

6.3.2 ALGORITMO K-MODE

Poiché l'algoritmo *K-means* non ha prodotto risultati soddisfacenti e i dati a disposizione sono principalmente categoriali, è stato provato l'algoritmo di clustering *K-mode*. Questo algoritmo, a differenza del *K-means* che analizza le distanze e le medie delle osservazioni, si concentra sulla moda delle osservazioni, ovvero sulla loro frequenza. Il *K-means* prevede che tutte le variabili siano quantitative e le variabili qualitative devono essere trasformate in variabili numeriche. Il *K-mode*, invece, è più adatto per i dati qualitativi. Per utilizzare questo algoritmo di clustering, le variabili quantitative devono essere trasformate in variabili categoriali. Sono state quindi utilizzate le variabili create nelle analisi precedenti, incluse quelle relative alla sensibilità ambientale, alla distanza percorsa annualmente, alla distanza casa-lavoro, al numero di viaggi e al viaggio più lungo.

Questa tipologia di analisi cluster è stata condotta sia su R, utilizzando la libreria *klaR*²⁶, sia su Python, utilizzando la libreria "KModes"²⁷. A differenza del *K-means*, che utilizza la distanza euclidea (dove una distanza minore indica una maggiore somiglianza), l'algoritmo *K-mode* utilizza le dissimilarità, in particolare la distanza di Hamming. La distanza di Hamming tra due punti è calcolata contando le differenze tra le variabili utilizzate; ogni disuguaglianza aumenta la distanza di 1, mentre un'uguaglianza non la modifica.

Come per il *K-means*, è necessario stabilire in anticipo il numero di cluster desiderati. Tuttavia,

26 *klaR*: Classification and Visualization, CRAN.R Project. <https://CRAN.R-project.org/package=klaR>

27 *kmodes*. Nelis J de Vos. <https://pypi.org/project/kmodes/>

invece di utilizzare misure come l'*indice di Silhouette* o il *WCSS*, si analizza una funzione di costo che somma tutte le dissimilarità tra i cluster. Questa funzione di costo può essere graficata rispetto al numero di cluster utilizzati, creando uno *scree plot* che aiuta a determinare il numero ottimale di cluster da utilizzare.




Figura 65. Grafico della funzione di costo in relazione al numero dei cluster

Dal grafico, Figura 65, si evince che il numero ideale di cluster è 4. In base a questo risultato, le osservazioni sono state raggruppate in quattro cluster, sia in R che in Python per confrontare i risultati a causa di problemi riscontrati con la libreria *klaR*. Utilizzando R, i gruppi risultanti sono: il primo cluster composto da 1,438 osservazioni, il secondo da 1,270, il terzo da 1,473 e l'ultimo da 1,615 osservazioni. Con la libreria "*KModes*" su Python, i gruppi risultanti sono: il primo cluster composto da 1,906 osservazioni, il secondo da 1,680, il terzo da 1,327 e il quarto cluster da 833 osservazioni.

Come si può notare, ci sono alcune differenze, soprattutto per quanto riguarda l'ultimo cluster, dove la libreria "*klaR*" su R ha prodotto quasi il doppio delle osservazioni rispetto alla libreria "*KModes*" su Python. Oltre a queste differenze nella composizione dei gruppi, sono presenti ulteriori differenze nella distribuzione delle modalità delle variabili. Le variabili che presentano una distribuzione nei cluster diversa rispetto alla loro distribuzione sull'intero dataset (analisi condotta nel Capitolo 4) includono: la "classe di reddito familiare", la "classe d'età", il "livello di istruzione", il "numero di persone nel nucleo familiare", il "numero di auto possedute in famiglia", la variabile "VMT annuo", il "viaggio più lungo effettuato", il "numero di viaggi lunghi" e la "distanza casa-lavoro". Per quanto riguarda le variabili che misurano la "proprietà della casa" e se la casa è "indipendente" o meno, queste presentano una distribuzione molto simile rispetto al dataset generale, ma mostrano diverse distribuzioni solo nel cluster 4, sia utilizzando la libreria "*KModes*" su Python che "*klaR*" su R.

RISULTATI utilizzando la libreria kLaR

I risultati ottenuti tramite la libreria “kLaR” verranno presentati evidenziando le percentuali più alte e significative che possono determinare il significato dei cluster.

Per quanto riguarda la variabile che misura la classe d’età, si può notare che nel primo cluster la maggioranza delle persone, circa il 79%, appartiene alla classe d’età 45-64 anni. Nel secondo cluster, quasi il 50% appartiene alla classe d’età over 65, il 23,6% alla classe d’età 45-64, e il 23,1% alla classe 35-44. Il terzo cluster presenta percentuali simili al secondo cluster, con un aumento di sei punti percentuali per la classe d’età 45-64, un punto percentuale circa per la classe 35-44, e circa otto punti percentuali in meno per la classe d’età over 65. Per l’ultimo cluster, l’80% delle persone appartiene alla classe d’età 45-64 anni. Pertanto, per il primo e l’ultimo cluster c’è una netta presenza di persone nella classe d’età 45-64, mentre nel secondo e nel terzo cluster le classi d’età sono più bilanciate, con una maggiore presenza della classe d’età over 65. In tutti questi cluster, c’è una bassa percentuale di target under 35.

Per la variabile classe di reddito, nel primo cluster il 38,5% delle persone appartiene a una classe di reddito molto alta, il 24,5% a una classe di reddito media, e il 20% a una classe alta. Il secondo cluster presenta circa il 50% delle persone appartenenti alla classe di reddito alta e il 26% alla classe di reddito media. Il terzo cluster presenta circa il 54% delle persone nella classe media e il 20% nella classe alta. Infine, l’ultimo cluster ha il 50% delle persone nella classe di reddito alta e il 24% nella classe media. Quindi, il secondo e il quarto cluster mostrano una distribuzione simile, con una preponderanza della classe alta, mentre il terzo cluster ha una prevalenza della classe media. Il primo cluster è più variegato, composto da persone delle classi media, alta e molto alta.

In tutti i cluster, il livello di istruzione più alto è preponderante, come nel dataset generale, eccetto per il primo cluster che presenta otto punti percentuali in più per il livello di istruzione massimo, con circa il 58% rispetto a circa il 50% degli altri cluster.

La dimensione familiare varia nei quattro cluster. Nel primo cluster, la modalità più frequente prevede una famiglia composta da quattro persone (due figli), seguita da famiglie composte da due persone (un figlio) e famiglie con più di cinque componenti. Il secondo cluster è composto per circa il 76% da coppie, seguito da famiglie con un figlio (12%). Il terzo cluster presenta coppie (63%) come modalità più frequente, seguite da famiglie con un figlio e single. Il quarto cluster è simile al primo, con la modalità più frequente rappresentata da famiglie con quattro componenti, seguite da tre componenti e più di cinque componenti. La variabile numero di auto in famiglia presenta come modalità più frequente due auto per nucleo familiare, passando da un 65% del primo cluster, a un 62% del secondo e a un 60% del terzo cluster. Nel quarto cluster, la modalità più frequente è tre auto per nucleo familiare.

Per la variabile VMT annuo, la maggioranza delle persone nel primo, secondo e terzo cluster ha un valore basso, mentre nel quarto cluster la modalità più frequente è il livello medio.

Per la variabile viaggio più lungo compiuto nell’ultimo anno, nel primo cluster la modalità più frequente è un viaggio tra 350 e 550 miglia, seguita da viaggi tra 175 e 300 miglia e viaggi inferiori a 175 miglia. Il

secondo cluster presenta ancora come modalità più frequente 350-550 miglia, seguito da 175-350 miglia e viaggi superiori a 550 miglia. Il terzo cluster mostra che circa il 70% delle persone non compie viaggi lunghi. L'ultimo cluster ha percentuali simili per viaggi tra 350-550 miglia e 175-350 miglia.

Per quanto riguarda il numero di viaggi lunghi, nel primo cluster circa il 61% delle persone compie un viaggio lungo all'anno. Il secondo e il quarto cluster mostrano valori simili al primo, con il secondo cluster che presenta anche un 23% di persone che compiono tre o più viaggi lunghi all'anno. La principale differenza è nel terzo cluster, dove il 74% delle osservazioni non compie viaggi lunghi.

La variabile distanza casa-lavoro mostra che nel primo cluster la modalità più frequente è una distanza tra 6.5 e 15 miglia, seguita da meno di 6,5 miglia e tra 25 e 45 miglia. Il secondo cluster presenta come modalità più frequente meno di 6,5 miglia, seguito da 15-25 miglia e 6.5-15 miglia. Il terzo cluster è simile al primo, ma la terza modalità più frequente è 15-25 miglia. Il quarto cluster mostra come modalità più frequente 15-25 miglia, seguita da 25-45 miglia e meno di 6.5 miglia.

RISULTATI utilizzando la libreria KModes

Come anticipato, utilizzando la libreria "KModes" si sono ottenuti risultati differenti. Per la variabile classe d'età, il primo cluster è caratterizzato da una netta presenza di persone tra i 45 e i 64 anni, seguito dalla classe 35-44. Il secondo cluster presenta una situazione simile. Il terzo cluster, pur avendo come classe più frequente quella dei 45-64 anni, risulta più eterogeneo degli altri. L'ultimo cluster, invece, mostra una netta predominanza di persone over 65.

Per la variabile classe di reddito, il primo cluster è abbastanza eterogeneo, con la classe più frequente media, seguita dall'alta, dalla molto alta e infine dall'estremamente alta. Il secondo cluster vede come classe più frequente, per il 57%, la classe di reddito alta, seguita dalla classe molto alta. Nel terzo e quarto cluster, la classe più frequente è quella media, seguita dalla classe alta e dalla molto alta.

Il livello di istruzione nei vari cluster mostra una predominanza del livello più elevato (laurea magistrale o dottorato), ad eccezione del terzo cluster, dove prevale la laurea di primo grado.

Il numero di auto per nucleo familiare varia principalmente tra il primo cluster e i restanti. Nel primo cluster, la modalità più frequente è tre auto per nucleo familiare. Nei cluster secondo, terzo e quarto, la modalità più frequente è due auto per famiglia. Nei cluster secondo e terzo, la modalità seguente è tre auto, mentre nel quarto cluster è una auto. Il quarto cluster presenta due auto per famiglia come modalità più frequente, con circa il 70%.

Per la variabile VMT annuo, il primo cluster mostra una predominanza del livello medio, seguito dal livello alto. Il secondo ha come modalità più frequente il livello basso, seguito dal livello alto. Nel cluster, il livello basso è seguito dal livello alto e infine dal livello medio, risultando più equilibrato ed eterogeneo rispetto al secondo. L'ultimo cluster, come i due precedenti, vede come modalità principale il livello basso, seguito dal livello alto e dal livello medio, con una maggiore preponderanza del livello basso

La variabile che misura la lunghezza del viaggio più lungo compiuto mostra che il primo e l'ultimo cluster sono caratterizzati da una predominanza della modalità inferiore a 175 miglia. Nel primo cluster, le modalità successive appaiono più eterogenee rispetto all'ultimo. Nel secondo cluster, la modalità più frequente è un viaggio tra 175 e 350 miglia, seguita da un viaggio tra 350 e 550 miglia. Il terzo cluster vede come modalità più frequente un viaggio tra 350 e 550 miglia, per circa il 63%.

La variabile che misura il numero di viaggi lunghi compiuti in un anno mostra che il primo e l'ultimo cluster, caratterizzati da "corti" viaggi lunghi, presentano zero viaggi lunghi. Nel quarto cluster, questa modalità è più preponderante (72% contro il 56% del primo cluster). Nel primo cluster, la seconda modalità più presente è un viaggio lungo all'anno (circa il 24%), mentre nell'ultimo cluster è tre o più viaggi lunghi all'anno (15%). Il secondo e il terzo cluster sono molto simili, con la modalità più preponderante rappresentata da un viaggio lungo all'anno, seguita da tre o più viaggi lunghi all'anno.

La variabile che misura la distanza percorsa per recarsi al lavoro vede, nel primo cluster, una predominanza di utenti che percorrono tra 6.5 e 15 miglia (44%), seguiti da utenti che percorrono 15-25 miglia (20%) e 25-45 miglia (20%). Il secondo cluster ha percentuali più equilibrate, con la modalità più frequente rappresentata da chi percorre meno di 6.5 miglia (35%), seguito da chi percorre 6.5-15 miglia (23%), 25-45 miglia (19%) e 15-25 miglia (19%). Il terzo cluster presenta come modalità più frequente chi percorre 15-25 miglia (41%), seguito da chi percorre 6.5-15 miglia (40%). Infine, l'ultimo cluster vede come modalità più presente chi percorre meno di 6.5 miglia (47%), seguito da chi percorre 6.5-15 miglia (23%).

6.3.3 RISULTATI

L'obiettivo principale dell'analisi cluster è stato delineare possibili futuri utilizzatori di veicoli elettrici, come introdotto precedentemente. Per individuare queste classi è stato scelto di utilizzare l'algoritmo "kmodes" con la libreria "kLaR" su R.

Cluster 1: Questo cluster comprende principalmente persone di sesso maschile, di età compresa tra 45 e 64 anni. Il reddito familiare è variegato, spaziando tra circa 60,000 \$ e 400,000 \$ annui. Hanno un livello di istruzione elevato, equivalente a una laurea magistrale o a un dottorato. Possiedono una casa indipendente e di proprietà, e precedentemente avevano un'auto a combustione interna. Le famiglie di questo cluster hanno generalmente due figli e possiedono due automobili. Percorrono annualmente un massimo di quasi 10,000 miglia con la propria auto, compiono soltanto un viaggio lungo all'anno che varia tra 175 e 550 miglia, e percorrono una distanza casa-lavoro nella media tra 6.5 e 15 miglia.

Cluster 2: Le persone appartenenti a questo cluster sono principalmente uomini di età superiore ai 45 anni, prevalentemente over 65. Hanno un reddito familiare medio-alto, variabile da 60,000 \$ a

200,000 \$ annui, con un focus tra 140,000 \$ e 200,000 \$ annui. Il livello di istruzione è elevato, prevalentemente laurea di secondo livello o dottorato, ma con alcuni casi di laurea triennale. Possiedono una casa di proprietà indipendente, e la loro auto precedente era a combustione interna. Le coppie rappresentano la maggioranza, possiedono due auto, percorrono fino a un massimo di 10,000 miglia annue, compiono almeno un viaggio lungo all'anno (tra 175 e 550 miglia) e percorrono una distanza casa-lavoro nella media tra 6,5 e 15 miglia.

Cluster 3: Le persone di questo cluster sono principalmente uomini, con una classe d'età variegata dai 35 anni in su, con un focus sugli over 65. Appartengono a una classe di reddito familiare media, con alcuni casi nella classe di reddito alta. Possiedono un titolo di studi universitario, laurea di primo o secondo livello, una casa di proprietà indipendente e la loro auto precedente era a combustione interna. Sono principalmente coppie con due auto, non fanno viaggi lunghi superiori a 200 miglia, hanno un VMT basso e percorrono al massimo 15 miglia per recarsi al lavoro.

Cluster 4: Sono principalmente uomini di età tra 45 e 64 anni, con un reddito familiare elevato tra 100,000 \$ e 200,000 \$ annui e un titolo di istruzione universitario. Abitano in case di proprietà indipendenti, e la loro auto precedente era a combustione interna. Le famiglie hanno principalmente due figli, ma possono avere anche un figlio, e possiedono tre auto. Percorrono annualmente tra 10.000 e 14.000 miglia, con alcuni che arrivano fino a 200,000 miglia annue. Effettuano almeno un viaggio lungo all'anno, tra 175 e 550 miglia. Infine, percorrono una distanza casa-lavoro superiore agli altri cluster, principalmente tra 15 e 25 miglia giornaliere, con alcuni che arrivano a percorrere fino a 45 miglia giornaliere.

Caratteristiche	Cluster 1	Cluster 2	Cluster 3	Cluster 4
Sesso	Principalmente maschi	Principalmente maschi	Principalmente maschi	Principalmente maschi
Età	45-64 anni	Over 65 anni	35+ anni (<i>focus over 65</i>)	45-64 anni
Reddito Familiare	\$60,000 – \$400,000	\$60,000 – \$200,000 (<i>focus 140,000 – 200,000</i>)	\$60,000 – \$140,000 (<i>alcuni casi 140,000 – 200,000</i>)	\$100,000 – \$200,000
Livello di Istruzione	Laurea magistrale / Dottorato	Laurea di secondo livello / Dottorato (<i>alcuni laurea triennale</i>)	Laurea di primo o secondo livello	Laurea di primo o secondo livello
Tipo di Abitazione	Casa indipendente di proprietà	Casa indipendente di proprietà	Casa indipendente di proprietà	Casa indipendente di proprietà
Tipo di Auto Precedente	Auto a combustione interna	Auto a combustione interna	Auto a combustione interna	Auto a combustione interna
Composizione Familiare	Coppie con 2 figli	Coppie	Coppie con 2 auto	Coppie con 2 figli (<i>alcuni 1 figlio</i>)
Numero di Auto	2	2	2	3
Miglia Annuali Percorse	Fino a 10,000 miglia	Fino a 10,000 miglia	10,000-15,000	10,000 – 14,000 miglia (<i>alcuni fino a 200,000 miglia</i>)
Viaggio Lungo	1 viaggio lungo annuo	1 viaggio lungo annuo	Viaggi lunghi sotto i 200 miglia	1 viaggio lungo annuo
Distanza Casa-Lavoro	6.5-15 miglia	6.5-15 miglia	Massimo 15 miglia	15-25 miglia (<i>alcuni fino a 45 miglia</i>)

Tabella 8: Riassunto dei risultati ottenuti con l'analisi cluster kmodes di kLaR (R)

6.4 LIBRERIE R E PYTHON PER LE ANALISI ESPLORATIVE

Nel presente capitolo sono state impiegate diverse librerie R e Python per l'analisi esplorativa dei dati. Oltre alle librerie già presentate, come *FactoMineR*, *factoextra*, *klaR* e *cluster* per R e *KModes* per Python vengono di seguito elencate le altre librerie utilizzate:

- *dplyr* (R): Strumento per la manipolazione e trasformazione dei dati in R.
- *gridExtra* (R): Libreria utile per organizzare tabelle e grafici in layout complessi.
- *corrplot* e *corrplot* (R): Utilizzate per la visualizzazione e il calcolo delle correlazioni tra variabili.
- *DT* (R): Permette di creare tabelle interattive in R.
- *ggplot2* (R): Libreria per la creazione di grafici personalizzati.
- *sklearn.metrics: silhouette_score* (Python): Strumento per calcolare il punteggio di silhouette per valutare la qualità di un clustering.

Tutti questi strumenti sono stati fondamentali per supportare le analisi statistiche e le visualizzazioni trattate nel capitolo. Il codice utilizzato nel notebook Python e nei file R è disponibile nella repository GitHub al seguente link:

https://github.com/FedeGambe/Master_s_thesis_Data_science/tree/130fcd101bc663d0ee1730347088c6fb0b4db5d5/Analisi_Statistiche

I concetti trattati in questo capitolo sono legati ai seguenti file R e al paragrafo del Notebook Python:

- Sottoparagrafo 6.2.1 - FAMD. (File R: [Analisi Esplorative FAMD](#)).
- Sottoparagrafo 6.2.2 - MCA. (File R: [Analisi Esplorative MCA](#)).
- Sottoparagrafo 6.2.2 - PCA. (File R: [Analisi Esplorative PCA](#)).
- Paragrafo 6.3 - ANALISI CLUSTER (File R: [Analisi Esplorative CLUSTER](#)).
- Sottoparagrafo 6.3.1 - ALGORITMO K-MEANS (File R: [Analisi Esplorative CLUSTER](#)).
- Sottoparagrafo 6.3.2 - ALGORITMO K-MODE (Par. 7.1 del Notebook Python. [Algoritmo: K-MODE](#). File R: [Analisi Esplorative CLUSTER](#)).

CAPITOLO 7

APPRENDIMENTO AUTOMATICO

7.1 CENNI SUI SISTEMI DI APPRENDIMENTO AUTOMATICO

In questo Capitolo verrà trattato il tema dell'apprendimento tramite modelli di *Machine Learning* e di *Deep Learning*. Questi modelli si riferiscono a tecniche che permettono agli algoritmi di apprendere e identificare pattern in una serie di dati. Attualmente, tali algoritmi sono di fondamentale importanza nello sviluppo di sistemi di intelligenza artificiale.

Il *Machine Learning* è una branca dell'intelligenza artificiale che si occupa di addestrare una macchina a imparare da un set di dati, riconoscendo schemi, regole, pattern e correlazioni, per formulare previsioni utili. Questo può essere applicato, ad esempio, nelle scelte aziendali, nelle previsioni di mercato, nel rilevamento di frodi nelle transazioni bancarie, nelle diagnosi mediche basate su dati storici e in molti altri ambiti. Esistono diverse tipologie di apprendimento nel *Machine Learning*: apprendimento supervisionato, apprendimento non supervisionato, apprendimento semi-supervisionato e apprendimento per rinforzo. La scelta della tipologia di apprendimento dipende dalla natura dei dati disponibili e dagli obiettivi che si intendono raggiungere. Ogni tipo di apprendimento utilizza diversi algoritmi, creati per fare previsioni, classificare, individuare pattern e prendere decisioni consapevoli. Questi algoritmi possono essere utilizzati singolarmente o insieme, per ottenere la massima precisione in presenza di dati complessi e variabili.

Il concetto fondamentale dell'apprendimento automatico si basa sull'idea che esista una relazione matematica tra un insieme di dati di *input* e un corrispondente insieme di dati di *output*. Tuttavia, il modello di *Machine Learning* non conosce questa relazione a priori, ma è in grado di inferirla attraverso i dati. Questa inferenza è possibile solo grazie all'addestramento, che avviene su un ampio insieme di dati, definito *training set*. I risultati ottenuti vengono poi confrontati con una piccola porzione di dati mai visti dall'algoritmo, per valutarne l'accuratezza.

A differenza delle analisi statistiche tradizionali, come l'analisi della regressione logistica e le analisi

esplorative (FAMD, MCA, PCA e Cluster), che non richiedono la divisione del dataset in due parti, nel *Machine Learning* questa divisione è essenziale. L'obiettivo principale dell'analisi statistica è comprendere le relazioni fra le variabili, testare ipotesi e trarre conclusioni basate sui dati, mentre l'obiettivo del *Machine Learning* è la predizione, ovvero costruire modelli che generalizzano efficacemente su nuovi dati.

Diverse tipologie di apprendimento nel *Machine Learning*:

- Apprendimento supervisionato: in questi modelli, i dati sono già etichettati, ossia si conosce la risposta. Si dispone di dati relativi al target (variabile dipendente) e alle *feature* (variabili indipendenti). Questo permette di addestrare il modello per effettuare previsioni su dati nuovi e non etichettati. Gli algoritmi utilizzati includono regressione lineare, regressione logistica e macchine a vettori di supporto.
- Apprendimento non supervisionato: in questa tipologia, i dati non sono etichettati, quindi non si conosce la variabile dipendente e le variabili indipendenti. Il modello cerca di individuare ricorrenze, pattern o strutture nei dati senza una variabile target. Esempi di algoritmi sono quelli per la riduzione delle dimensionalità, il clustering e il rilevamento delle anomalie.
- Apprendimento semi-supervisionato: combina l'apprendimento supervisionato e non supervisionato, utilizzando una ridotta quantità di dati etichettati insieme a una grande quantità di dati non etichettati. I pochi dati etichettati servono per addestrare parzialmente l'algoritmo, che successivamente etichetterà i dati non etichettati.
- Apprendimento per rinforzo: in questa tipologia, il modello impara attraverso un processo iterativo di tentativi ed errori. L'algoritmo effettua aggiustamenti in base alle penalizzazioni e ricompense, con l'obiettivo di massimizzare una ricompensa cumulativa.

In questa tesi verranno utilizzate diverse tipologie di algoritmi di *Machine Learning* supervisionati e di *Deep Learning*. Il *Deep Learning* è una sotto-branca del Machine Learning, caratterizzata da reti neurali artificiali complesse, strutturate in più strati (da cui il termine “*deep*”, cioè “profondo”). Queste reti neurali sono modellate sul cervello umano e sfruttano una logica simile a quella degli esseri umani per analizzare i dati. Nel *Deep Learning* viene creata una rete neurale artificiale per elaborare i dati su più livelli. Questi livelli includono uno strato di *input*, attraverso il quale i dati fluiscono nei livelli nascosti (*hidden layers*), che possono essere molteplici, fino a raggiungere uno strato finale di *output*. Gli *hidden layers* sono livelli intermedi dove ogni nodo è collegato ai nodi del livello precedente e del livello successivo. Questi livelli sono essenziali per trasformare le informazioni in modo che possano essere utilizzate per risolvere un problema specifico. Ogni strato nascosto esegue una serie di operazioni sui dati per permettere alla rete neurale di apprendere e fare previsioni.

La complessità strutturale del *Deep Learning* consente di elaborare informazioni in modo più efficace rispetto agli algoritmi classici di *Machine Learning*. Il *Deep Learning* è particolarmente utilizzato per

dati non tabulari, come video, immagini, suoni e testi, che sono informazioni complesse da elaborare. Le reti neurali, ispirate dal funzionamento del cervello umano, sono composte da diversi nodi, chiamati neuroni, suddivisi su vari strati. Ogni strato riceve informazioni dallo strato precedente (a parte per il livello di *input*) e le rielabora inviandole allo strato successivo, fino a raggiungere il livello di *output*, che produce il risultato finale in risposta all'*input* iniziale. A seconda del tipo di problema che la rete sta cercando di risolvere, il livello di *output* può fornire diversi tipi di risposte. In un problema di classificazione, il livello di *output* può restituire la probabilità di ciascuna classe, mentre in un problema di regressione, fornirà un valore continuo, come una previsione numerica. Una rete neurale artificiale con più strati nascosti diventa una rete neurale profonda, capace di elaborare informazioni complesse.

Il *Deep Learning* e il *Machine Learning* sono tecniche che permettono di apprendere le caratteristiche dei dati. Il *Machine Learning* include diverse tecniche tradizionalmente utilizzate per elaborazioni più semplici rispetto al *Deep Learning*. Il *Deep Learning*, invece, è una branca avanzata del *Machine Learning* che sfrutta le reti neurali profonde per apprendere informazioni complesse da grandi volumi di dati. In questo lavoro di tesi, poiché i dati sono di tipo tabulare e in quantità non elevata, le tecniche classiche di *Machine Learning* sono più che adeguate. Tuttavia, si è deciso di provare ad addestrare il modello anche con tecniche di *Deep Learning* per poi confrontarle con le tecniche classiche e vedere quali delle due performano meglio su queste tipologie di dati.

7.2 MACHINE LEARNING

7.2.1 PREPARAZIONE

Per questa parte di tesi, le variabili qualitative utilizzate sono state trasformate. Le variabili qualitative che presentavano una caratteristica di ordinalità, come le classi d'età e il livello di istruzione, hanno assunto un valore continuo. Ad esempio, per i livelli di istruzione (licenza media, diploma, laurea di primo livello, laurea di secondo livello), le modalità hanno assunto valori da 1 a 4. Per tutte le variabili ordinali, il valore basso è stato associato al valore più basso delle variabili per mantenere una logica continua nell'analisi e evitare fraintendimenti.

Per la variabile qualitativa nominale, come la tipologia di auto posseduta precedentemente, è stata utilizzata la metodologia dell'*hot encoding*, diversamente dalla *label encoding* delle variabili ordinali. Sono state create nuove variabili per ciascuna modalità, che assumono valori dicotomici (0-1) per indicare la presenza o l'assenza della caratteristica. Infine, per le variabili dicotomiche, come genere, casa di proprietà e la variabile BEV dummy, erano già presenti valori di zero per l'assenza e uno per la presenza della caratteristica descritta.




Figura 66. Correlation Matrix delle feature

Una volta rese numeriche le variabili qualitative, il dataset è stato standardizzato per evitare che variabili con valori elevati, come VMT annuo, influenzassero il lavoro e rendessero ininfluenti le variabili con valori bassi. Successivamente, le variabili sono state divise nel gruppo delle *feature* e del target. Come per le analisi precedenti, la variabile target sarà BEV dummy. *Feature* e target sono stati quindi divisi in *training set* (80%) e *test set* (20%).

Prima di procedere con le tecniche di *Machine Learning*, sono state verificate le correlazioni fra le variabili attraverso la matrice di correlazioni. Non sono stati rilevati valori di alta correlazione tali da richiedere la rimozione di alcune variabili; il valore più alto è stato ± 0.58 , inferiore alla soglia di 0.7 indicata da Ratner Bruce (2009)²⁸. Pertanto, tutte le variabili originali sono state mantenute. Successivamente, è stata effettuata un'analisi con un modello ridotto di variabili, rimuovendone alcune in base alla loro importanza, all'analisi VIF e alla matrice di correlazione. Questa parte del modello ridotto verrà approfondita più avanti.

Dopo aver controllato le correlazioni, si è proceduto con la verifica dei valori mancanti, che non erano presenti poiché il dataset era già stato trattato per le analisi precedenti. Infine, è stato verificato che la variabile target fosse bilanciata. Il bilanciamento delle classi nella variabile target è importante, soprattutto per i problemi di classificazione. Uno sbilanciamento dei valori può generare un bias verso la classe più rappresentata durante l'apprendimento predittivo. In presenza di una variabile sbilanciata, il modello potrebbe non apprendere bene e ignorare la classe minoritaria, portando a previsioni imprecise. L'analisi della distribuzione della variabile target ha indicato che la variabile è abbastanza bilanciata e non necessita di interventi di ribilanciamento. I valori ottenuti sono circa 46% per la classe che non

28 Ratner, B. (2009). The correlation coefficient: Its values range between +1/-1, or do they?. *Journal of Targeting, Measurement and Analysis for Marketing*, pp. 139-142




Figura 67. Distribuzione della variabile BEV dummy (Target)

possiede un veicolo elettrico e 54% per la classe che lo possiede. Anche i training e *test set* sono stati verificati per assicurare che la separazione abbia mantenuto le stesse percentuali nel valore target, con una differenza di solo 0.1 punto percentuale.

7.2.2 SCELTA DEI MODELLI

Per risolvere questo problema di classificazione, sono state utilizzate diverse tipologie di algoritmi della libreria scikit-learn²⁹: lineari, non lineari, basati su probabilità. Gli algoritmi usati sono: *Logistic Regression*, *K Neighbors Classifier*, *Support Vector Classifier*, *Decision Tree Classifier*, *Random Forest Classifier*, *Gradient Boosting Classifier*, *AdaBoost Classifier*, *Bernoulli Naive Bayes*, *Linear Discriminant Analysis*, *Quadratic Discriminant Analysis*, *SGD Classifier*, *Multi-layer Perceptron Classifier* e *Ridge Classifier*.

Per evitare di provare tutti gli algoritmi e trovare il più performante, poiché richiederebbe molto tempo per le operazioni di settaggio e per trovare i migliori parametri, si è proceduto prima con un confronto. È stata effettuata una *K-Fold Cross Validation*³⁰ con 10 folds per ogni algoritmo, per determinare l'accuratezza. La *K-Fold Cross Validation* confronta le prestazioni dei vari modelli sul dataset di addestramento. Il *training set* viene suddiviso in dieci sottoinsiemi, e ad ogni iterazione uno di questi sottoinsiemi viene usato come *validation set*, mentre i restanti nove sottoinsiemi come set di addestramento. Questa procedura viene ripetuta dieci volte, garantendo che tutti i sottoinsiemi siano utilizzati

²⁹ Scikit-Learn: <https://scikit-learn.org/>

³⁰ `cross_val_score`. sklearn.model_selection, Scikit Learn. https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.cross_val_score




Figura 68. Confronto Modelli, Boxplot relativi ai punteggi di accuratezza trovati nella Cross-Validation

sia per l'addestramento sia per la validazione. Si otterranno quindi dieci valori di accuratezza, dai quali si calcolerà un valore medio.

Attraverso questa procedura, è possibile valutare e confrontare le performance dei diversi algoritmi di *Machine Learning* per scegliere quelli più performanti. Dalla Figura n. 68, che mostra i box plot relativi all'accuratezza dei modelli messi a confronto, si può notare che i modelli migliori, cioè quelli con valore di accuratezza più alto, sono: *Gradient Boosting*, *AdaBoost*, *Random Forest*, *Support Vector Classifier (SVM)* e *Multi-layer Perceptron Classifier (MLP)*. Inoltre, è stato aggiunto anche l'algoritmo *Regressione Logistica* per avere come confronto un modello lineare, e sarà utilizzato anche nel *Voting Classifier* per garantire diversità nel modello.

I primi tre algoritmi appartengono alla famiglia dell'*ensemble learning*, una tecnica di *Machine Learning* che combina più modelli per creare un modello finale con una performance migliore rispetto a ciascun modello singolo. *Gradient Boosting* e *AdaBoost* fanno parte della famiglia del boosting, metodi di *ensemble learning* che combinano diversi *weak learners* (classificatori deboli) in un strong learner (classificatore forte). *Random Forest*, invece, fa parte della famiglia del *Bagging*, acronimo di *Bootstrap Aggregating*, una tecnica di *ensemble learning* il cui scopo principale è migliorare la stabilità e la precisione di un modello riducendo la varianza.

Saranno utilizzati questi sette algoritmi, per ognuno dei quali verrà prima effettuata l'analisi sul modello base. Successivamente, sarà utilizzata la tecnica della *Grid Search CV*³¹ per trovare i migliori iperparametri, testando diverse combinazioni di parametri per trovare quella migliore attraverso la *Cross Validation*.

31 GridSearchCV. sklearn.model_selection, Scikit Learn. https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV

tion, ottenendo così un modello più efficiente.

Infine, trovati i migliori iperparametri, verranno utilizzati in combinazione con la tecnica della *Cross Validation*. Ad ogni passaggio verrà calcolata l'accuratezza per verificare se questa è aumentata o meno. Queste procedure, oltre ad aumentare il valore dell'accuratezza, rendono il modello più robusto, cioè in grado di generalizzare meglio su nuovi dati non visti durante l'addestramento, senza essere troppo sensibile al rumore. Un modello robusto è capace di fare previsioni accurate anche in presenza di variabilità nei dati, riducendo il rischio di *overfitting* e mantenendo buone performance anche su dati non perfettamente rappresentativi di quelli utilizzati per l'addestramento.

7.2.3 ENSEMBLE LEARNING

Gradient Boosting

Dall'analisi preliminare dei modelli, l'algoritmo *Gradient Boosting*³² emerge come quello con le migliori performance, con un'accuratezza mediana sul *validation set* pari a 0.69. Questo algoritmo appartiene alla famiglia degli algoritmi di boosting, una tecnica che rientra nell'ambito dell'*ensemble learning*. Il *Gradient Boosting* può essere utilizzato sia per problemi di regressione che di classificazione e si basa sull'idea che l'apprendimento possa migliorare correggendo gli errori commessi dai modelli precedenti. In particolare, l'algoritmo costruisce modelli in modo sequenziale, dove ogni nuovo modello è addestrato per ridurre gli errori commessi dai modelli precedenti.

I principali vantaggi del *Gradient Boosting* includono la sua capacità di gestire dati eterogenei e la robustezza rispetto a variabili irrilevanti. Tuttavia, presenta anche alcune limitazioni, tra cui una forte suscettibilità all'*overfitting* e una relativa lentezza computazionale.

Inizialmente, utilizzando il modello base senza ottimizzazione degli iperparametri, l'accuratezza sul *test set* risulta essere di circa 0.66. Successivamente, sono stati ottimizzati gli iperparametri mediante *Grid Search CV*, testando i seguenti parametri:

- *n_estimators*: 200, 250, 300. Inizialmente si sono testati valori anche più bassi di 200, ma si è constatato che non erano efficienti, poiché il processo di training richiede un'ora, si è deciso di escludere tali valori. Questo parametro definisce il numero di alberi (o iterazioni) che verranno utilizzati nel modello. Valori più alti tendono a migliorare l'efficienza, ma aumentano il rischio di *overfitting*.
- *learning_rate*: 0.01, 0.05, 0.1, 1. Il tasso di apprendimento, o learning rate, controlla quanto ogni albero corregge l'errore residuo. Un tasso di apprendimento basso significa che ogni albero avrà un impatto ridotto e il modello impiegherà più iterazioni per convergere. Un valore alto fa sì che ogni albero abbia un grande impatto, ma può anche causare *overfitting*.

32 GradientBoostingClassifier. sklearn.ensemble Scikit Learn. <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.GradientBoostingClassifier>

Tendenzialmente si utilizza un learning rate basso e si aumenta il numero di alberi per ottenere buone performance.

- *max_depth*: 1, 2, 3. Definisce la profondità massima degli alberi, limitando il numero di livelli che ogni albero può avere. Alberi troppo profondi tendono a catturare il rumore nei dati, aumentando il rischio di *overfitting*.
- *subsample*: 0.5, 0.7, 0.8. Questo parametro determina la frazione di dati utilizzata per addestrare ciascun albero, ad ogni iterazione, un sottoinsieme casuale dei dati viene utilizzato per costruire l'albero successivo. Un valore più basso di può ridurre l'*overfitting*, poiché ogni albero è costruito solo su una parte dei dati, ma potrebbe aumentare il bias, e ovviamente a valori alti diminuisce il bias ma può aumentare l'*overfitting*.
- *min_samples_split*: 2, 5, 10. È il numero minimo di campioni necessari per suddividere un nodo durante la costruzione dell'albero, ovvero, se per esempio il valore è di 2 e un nodo ha 2 campioni non verrà diviso. Valori bassi (come per esempio 2) consentono agli alberi di essere molto complessi e profondi, aumentando il rischio di *overfitting*. Valori più alti favoriscono alberi più semplici e riducono il rischio di *overfitting*, ma potrebbero non riuscire a catturare correttamente le complessità dei dati.

Per la selezione degli iperparametri è stata utilizzata una *K-Fold Cross Validation* con 5 fold. In pratica, il dataset è stato suddiviso in 5 parti, e il modello è stato addestrato su 4 fold e testato sul restante fold, ripetendo il processo per 5 volte. I migliori parametri ottenuti dalla *Grid Search* sono stati: *learning_rate*=0.05, *max_depth*=3, *min_samples_split*=5, *n_estimators*=200, *subsample*=0.7.

Il miglior punteggio di accuratezza ottenuto durante la *Cross Validation* è stato di 0.685, mentre l'accuratezza del modello con i parametri ottimizzati sui dati di test è risultata pari a 0.66. La differenza

Visualizzazione dei 15 Stratified KFold




Figura 69. Struttura della 15 K-Fold Cross Validation, il train set è diviso in 80% train set (area blue) e 20% validation set (area rossa)

tra queste due metriche (circa 2.5%) suggerisce la possibile presenza di *overfitting*. Sebbene la differenza non sia considerevole, è comunque significativa e va tenuta in considerazione. Tuttavia, poiché questa ricerca non è destinata a contesti applicativi critici (come la diagnosi medica o la rilevazione di frodi finanziarie), una differenza del 2.5% nella previsione della proprietà di un veicolo elettrico non ha un impatto rilevante. Si proseguirà quindi con l'analisi dei modelli successivi, monitorando sempre queste differenze per valutarne l'eventuale persistenza.

Nel caso della *Grid Search*, l'accuratezza è aumentata solo marginalmente, poiché con il modello base si avvicinava a 0.66, mentre con la *Grid Search* è di 0.66. Successivamente, per garantire una valutazione ancora più robusta, è stata eseguita una seconda *Cross Validation* con 15 fold, rispetto ai 5 della *Grid Search*. Un numero maggiore di fold fornisce una stima più affidabile della performance del modello, riducendo il rischio di *overfitting* e migliorando la generalizzazione.



Figura 70. Modello Gradient Boosting. Istogramma dei punteggi predetti

I risultati della *Cross Validation*³³ con 15 fold mostrano una leggera differenza tra l'accuratezza sul *test set* (0.659) e l'accuratezza media nella *Cross Validation* (0.6798), con una differenza di circa 2 punti percentuali. Durante questa fase sono state anche calcolate altre metriche di valutazione:

- *F1 Score*: 0.7028. Questo valore misura la media armonica tra la precisione e il *Recall*, ed è una metrica che bilancia la capacità del modello di fare previsioni corrette con quella di identificare tutti i casi positivi. Un valore di 0.70 indica una performance moderata, ma lontana da una classificazione perfetta (1.0).
- *Recall*: 0.7548. Indica la capacità del modello di identificare correttamente i veri casi positivi. In questo caso, il modello riesce a identificarli nel 75% dei casi.
- *Precision*: 0.6575. Indica la porzione di vere previsioni positive, ossia quanti casi classifica-

³³ `cross_validate`. `sklearn.model_selection`, Scikit Learn. https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.cross_validate

ti come positivi dal modello sono effettivamente corretti. Il valore di 0.66 indica che il 66% delle previsioni positive fatte dal modello sono corrette.

- *AUC*: 0.7142. L'area sotto la curva *ROC* (Receiver Operating Characteristic) misura la capacità del modello di distinguere tra le due classi. Un valore di 0.71 indica una capacità discriminante discreta, anche se lontana dall'ottimale (1.0), ma è anche abbastanza lontano dal valore di 0.5 che indica una performance pari a un modello casuale.




Figure 71-73. Modello Gradient Boosting. TPR e FPR per ogni threshold, ROC Curve, PR Curve

Analizzando i grafici sottostanti, Figura. 71-73, il primo grafico mostra l'andamento dei tassi di vero positivo (TPR) e falso positivo (FPR) al variare dei vari Threshold (soglie decisionali). Il secondo grafico (Figura 66) presenta la curva ROC, che confronta i valori di TPR e FPR per tutte le soglie decisionali possibili. L'Area sotto la Curva (*AUC*) è una misura complessiva che indica la capacità del modello di distinguere correttamente tra le classi. Un grafico ottimale dovrebbe avere un'area prossima a 1, con la curva che si avvicina sempre di più all'angolo in alto a sinistra, dove il TPR è massimo e il FPR è minimo. In questo caso, la curva supera la diagonale tratteggiata, che rappresenta un modello casuale (con *AUC* pari a 0.5), indicando che il modello non effettua previsioni in modo casuale.

Il terzo grafico (Figura. 73) mostra la curva *Precision-Recall*. Anche in questo caso, l'obiettivo è che l'area sotto la curva si avvicini a 1. Più la curva si sposta verso l'angolo in alto a destra, migliore è la performance del modello. La diagonale in questo grafico rappresenta, come nel caso della curva ROC, il comportamento di un modello casuale. L'area sotto la curva in questo caso è pari a 0.72, suggerendo una discreta precisione del modello nella classificazione dei casi positivi. Tuttavia, esaminando il grafico si nota un andamento insolito: la curva appare relativamente piatta, piuttosto che curvata, il che suggerisce che il modello fatica a mantenere un buon equilibrio tra precisione e *Recall* per i diversi threshold. Questo comportamento potrebbe essere dovuto a difficoltà nel discriminare correttamente tra le due classi.

I tre modelli analizzati mostrano prestazioni complessivamente simili, con differenze minime. L'accuratezza complessiva si è mantenuta intorno al 66%, suggerendo che i modelli sono riusciti a fare previsioni corrette in modo abbastanza simile. Il modello con *Grid Search CV* ha mostrato un leggero miglioramento rispetto agli altri modelli, soprattutto nell'F1-score, che è aumentato marginalmente sia per la classe 0 che per la classe 1. Sebbene la *Cross Validation* riduca il rischio di *overfitting* e fornisca una stima più robusta della performance, in questo caso non ha prodotto un miglioramento significativo rispetto agli altri modelli.

Le matrici di confusione e i report di classificazione dei tre modelli evidenziano che il modello con la *Grid Search* ottimizza leggermente sia i veri positivi che i veri negativi, riducendo i falsi positivi e falsi negativi, risultando quindi il più equilibrato. Rispetto al modello base, il numero dei veri positivi e veri negativi aumenta leggermente, mentre quello dei falsi positivi e falsi negativi diminuisce. Il modello con la *Cross Validation*, invece, migliora la classificazione dei casi negativi, ma introduce un lieve aumento nei falsi negativi, suggerendo che, sebbene migliori i risultati sui negativi, potrebbe compromettere la classificazione corretta di alcuni positivi.

In conclusione, sebbene il modello con *Grid Search* sembri il più performante, è preferibile optare per il modello con *Cross Validation*, che risulta più robusto e capace di generalizzare meglio su nuovi dati, anche a costo di una leggera perdita di performance.




Figure 74-76. Confronto delle Confusion Matrix dei tre modelli Gradient Boosting: Base, con Grid Search e in fine con Cross-Validation

Modello Base: *Gradient boosting*

Classe	Precision	Recall	F1-Score	Support
0.0	0.66	0.54	0.59	996
1.0	0.65	0.76	0.70	1142
Accuracy			0.66	2138
Macro Avg	0.66	0.65	0.65	2138
Weighted Avg	0.66	0.66	0.65	2138

Tabella 9: Report di classificazione: Modello Gradient Boosting Base

Modello con Grid Search: *Gradient boosting*

Classe	Precision	Recall	F1-Score	Support
0.0	0.67	0.54	0.60	996
1.0	0.66	0.76	0.71	1142
Accuracy			0.66	2138
Macro Avg	0.66	0.65	0.65	2138
Weighted Avg	0.66	0.66	0.66	2138

Tabella 10: Report di classificazione: Modello Gradient Boosting con Grid Search CV

Modello con Cross-Validation: *Gradient boosting*

Classe	Precision	Recall	F1-Score	Support
0.0	0.66	0.55	0.60	996
1.0	0.66	0.75	0.70	1142
Accuracy			0.66	2138
Macro Avg	0.66	0.65	0.65	2138
Weighted Avg	0.66	0.66	0.65	2138

Tabella 11: Report di classificazione: Modello Gradient Boosting con K-Fold Cross Validation (15 fold)

AdaBoost

L'algoritmo *AdaBoost*³⁴, acronimo di *Adaptive Boosting*, è un metodo di *ensemble learning* che appartiene alla famiglia dei boosting. Come il *Gradient Boosting*, *AdaBoost* combina più modelli deboli, tipicamente classificatori semplici come alberi decisionali poco profondi, per ottenere un modello complessivamente più potente e performante. Di default, *AdaBoost* utilizza come classificatore debole l'albero decisionale (*Decision Tree Classifier*) con una profondità massima di 1 (*max_depth=1*). Per verificare quale classificatore debole fosse il più efficace, nel modello di base, senza ottimizzazione degli iperparametri, sono stati testati anche altri classificatori: il classificatore Decision Tree ha ottenuto un'accuratezza di 0.6604, il classificatore logistico ha restituito un'accuratezza di 0.6179, l'*SVC* è risultato significativamente più lento nella fase di computazione e ha raggiunto un'accuratezza di 0.6099, mentre il Perceptron, un classificatore lineare, ha ottenuto un'accuratezza di 0.5982. Pertanto, per il classificatore debole associato a *AdaBoost*, è stato scelto di utilizzare l'albero decisionale con profondità 1 (*max_depth=1*), in quanto ha restituito l'accuratezza più alta.

AdaBoost funziona in maniera iterativa, ovvero, allena i classificatori uno alla volta, concentrandosi sugli errori commessi dai classificatori precedenti e cercando di correggerli. I principali vantaggi di questo algoritmo sono la sua capacità di migliorarsi progressivamente, concentrandosi sugli errori commessi dai classificatori precedenti, e la possibilità di utilizzare diversi classificatori deboli, come dimostrato in precedenza. Inoltre, *AdaBoost* presenta una bassa predisposizione all'*overfitting*. Tuttavia, un grande svantaggio è la sua sensibilità al rumore nei dati: la presenza di outlier può influire negativamente sulle prestazioni del modello.

Una delle principali differenze tra *AdaBoost* e *Gradient Boosting* è che, mentre *AdaBoost* consente l'uso di differenti tipi di classificatori deboli, nel caso di *Gradient Boosting* è necessario utilizzare solo alberi decisionali, che, tra l'altro, possono essere più complessi e profondi. Un'altra differenza riguarda la correzione degli errori: *AdaBoost* si concentra sugli errori dei classificatori precedenti e modifica i pesi, senza considerare l'errore complessivo, mentre *Gradient Boosting* cerca di minimizzare la funzione di perdita utilizzando il gradient descent, cercando di ridurre l'errore totale ad ogni iterazione.

Per ottimizzare i parametri di *AdaBoost*, è stata utilizzata la *Grid Search CV* con 10 fold di *Cross Validation*, dato che l'algoritmo ha un numero ridotto di parametri da testare. I parametri esaminati sono stati:

- *max_features*: *None*, *0.5*, *0.8*. Rappresenta il numero di caratteristiche prese in considerazione quando si suddivide un nodo nell'albero decisionale.
- *n_estimators*: *50*, *100*, *150*, *200*. Questo parametro indica il numero dei classificatori deboli (in questo caso alberi decisionali) che vengono utilizzati durante l'addestramento, un

34 AdaBoostClassifier. sklearn.ensemble, Scikit Learn. <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.AdaBoostClassifier>

numero maggiore di `n_estimators` aumenta la capacità di apprendimento del modello, ma aumenta anche il rischio di *overfitting*.

- *learning_rate*: 0.01, 0.1, 0.5, 1. Come nel *Gradient Boosting*, il tasso di apprendimento indica quanto ogni nuovo classificatore modifica il modello.
- *algorithm*: default. Il parametro di default è *SAMME.R*, poiché il problema è di classificazione binaria. L'algoritmo *SAMME* sarebbe utilizzato per problemi di classificazione multiclasse. A partire dalla versione 1.6 di *AdaBoost*, non è più necessario specificare l'algoritmo, in quanto viene automaticamente selezionato in base al tipo di problema.

Il parametro `base_estimator`, che avrebbe testato diversi classificatori deboli, non è stato incluso in quanto il miglior classificatore debole era già stato determinato manualmente e i *test* precedenti avevano confermato che l'albero decisionale con profondità 1 (*max_depth=1*) era la scelta ottimale. I migliori parametri ottenuti tramite *Grid Search CV* sono: *DecisionTreeClassifier (max_depth=1)*, *max_features=0.8*, *learning_rate: 0.5*, *n_estimators: 100*. Il miglior punteggio di accuratezza nella *Grid Search* è di 0.6739, mentre l'accuratezza del modello sul *test set* è di 0.6553.

In seguito, è stata eseguita una *K-Fold Cross Validation* con 15 fold, ottenendo i seguenti risultati: l'accuratezza media durante la *Cross Validation* è stata di 0.6739, mentre l'accuratezza finale sul *test set* è risultata pari a 0.6544. Come nel caso del modello precedente, l'accuratezza del modello con *Cross Validation* è leggermente inferiore rispetto a quella ottenuta dalla *Grid Search*, un risultato che potrebbe essere dovuto a fenomeni di *overfitting* durante la *Grid Search*, a differenze nei sottoinsiemi di dati utilizzati o alla variabilità intrinseca della *Cross Validation*. Nonostante ciò, il modello con *Cross Validation* è considerato più robusto, anche se l'accuratezza è leggermente inferiore.




Figura 77. Modello AdaBoost. Istogramma dei punteggi predetti




Figure 78-80. Modello AdaBoost. TPR e FPR per ogni threshold, ROC Curve, PR Curve

Le ulteriori metriche di valutazione sono le seguenti:

- F1-Score: 0.6968,
- Recall: 0.7434,
- Precision: 0.6556,
- AUC-ROC (Area Under the Curve): 0.6976.

Questi valori sono leggermente inferiori rispetto al modello basato su *Gradient Boosting*, ma comunque indicano una buona performance del modello *AdaBoost*.

Le curve *ROC* e *Precision-Recall*, mostrate nelle Figure 78-80, evidenziano comportamenti simili a quelli osservati per *Gradient Boosting*. Anche in questo caso, la curva *Precision-Recall* appare irregolare, con una rapida discesa all'inizio, seguita da un appiattimento nei valori successivi.

Esaminando la figura 77, rispetto alla figura 70, si nota che questo modello ha una performance inferiore, con una maggiore sovrapposizione dei valori positivi e negativi nell'area centrale. Un grafico ideale per una classificazione ottimale dovrebbe posizionare i valori positivi e negativi agli estremi, ma in questo caso il modello appare meno deciso nelle sue predizioni.

In conclusione, per l'algoritmo *AdaBoost*, i valori di accuratezza tra i tre modelli analizzati si sono mantenuti simili, con lievi differenze. L'accuratezza si è aggirata intorno al 66%, con il modello base che ha ottenuto il punteggio più alto (66.1%), suggerendo la presenza di *overfitting*, rispetto al modello con *Cross Validation* (65.6%). Analogamente, nella precisione, il modello base ha ottenuto una leggera superiorità, con una differenza di circa mezzo punto percentuale. Tuttavia, per quanto riguarda la *Recall*, il modello con *Grid Search* ha ottenuto i migliori risultati.

In generale, i tre modelli mostrano prestazioni simili, con differenze marginali. Il modello base offre una maggiore precisione, ma una *Recall* inferiore rispetto agli altri due modelli. Il modello con *Grid Search* eccelle nella *Recall*, ma presenta una precisione leggermente inferiore. Il modello con *Cross Validation* si trova a metà strada, bilanciando meglio precisione e *Recall*. Nonostante le piccole differenze, tutte le

metriche F1-Score sono simili, indicando che nessun modello si distingue in modo netto in termini di bilanciamento tra precisione e *Recall*.

Pertanto, la scelta del modello dipende principalmente dalla sua robustezza piuttosto che dalle metriche di performance, che risultano comparabili. In questo contesto, il miglior modello è quello in cui è stata applicata la *Cross Validation* sui parametri ottimizzati tramite *Grid Search*, poiché risulta essere il più robusto rispetto ai dati futuri.




Figure 81-83. Confronto delle Confusion Matrix dei tre modelli AdaBoost: Base, con Grid Search e in fine con Cross-Validation

Modello Base: AdaBoost

Classe	Precision	Recall	F1-Score	Support
0.0	0.66	0.57	0.62	996
1.0	0.65	0.74	0.70	1142
Accuracy			0.66	2138
Macro Avg	0.66	0.65	0.65	2138
Weighted Avg	0.66	0.66	0.66	2138

Tabella 12: Report di classificazione: Modello AdaBoost Base

Modello con Grid Search: *AdaBoost*

Classe	Precision	Recall	F1-Score	Support
0.0	0.67	0.54	0.59	996
1.0	0.66	0.76	0.79	1142
Accuracy			0.66	2138
Macro Avg	0.66	0.65	0.65	2138
Weighted Avg	0.66	0.66	0.65	2138

Tabella 13: Report di classificazione: Modello *AdaBoost* con Grid Search CVModello con Cross-Validation: *AdaBoost*

Classe	Precision	Recall	F1-Score	Support
0.0	0.66	0.55	0.60	996
1.0	0.66	0.75	0.70	1142
Accuracy			0.66	2138
Macro Avg	0.66	0.65	0.65	2138
Weighted Avg	0.66	0.66	0.65	2138

Tabella 14: Report di classificazione: Modello *AdaBoost* con K-Fold Cross Validation (15 fold)

Random Forest

L'algoritmo *Random Forest*³⁵ si posiziona come il terzo migliore modello in termini di accuratezza, come accennato in precedenza. Questo algoritmo appartiene alla famiglia degli algoritmi di *ensemble learning*, ma a differenza di quelli basati su boosting (come *AdaBoost* e *Gradient Boosting*), fa parte della famiglia *Bagging*, che costruisce una “foresta” di alberi decisionali. In sostanza, *Random Forest* può essere visto come un’evoluzione della combinazione tra *Bagging Classifier* e *Decision Tree Classifier*. Il funzionamento di *Random Forest* si basa sulla creazione di un insieme di alberi decisionali tramite il processo di *Bootstrap Aggregation (Bagging)*. Ogni albero è costruito utilizzando un campione casuale dei dati di addestramento, con sostituzione (*Bootstrapping*). Per ogni nodo di ciascun albero,

35 RandomForestClassifier. sklearn.ensemble, Scikit Learn. <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier>

viene selezionato un sottoinsieme casuale di caratteristiche da considerare per la divisione. Quando viene effettuata una previsione, ogni albero fornisce una classe, e il risultato finale è determinato dalla classe che ottiene il maggior numero di voti tra gli alberi. In altre parole, *Random Forest* aggrega i risultati di tutti gli alberi per ottenere una previsione più robusta e stabile.

Il modello base, senza alcuna modifica dei parametri, ha ottenuto un'accuratezza pari a 0.6459. Per ottimizzare i parametri, è stata utilizzata una *Grid Search CV* con una *Cross Validation* di 5 fold. I parametri testati sono stati:

- *n_estimators*: 10, 100, 200, 300. Questo parametro determina il numero di alberi da utilizzare. Aumentando il numero di alberi, il modello tende a migliorare l'accuratezza e a ridurre l'*overfitting*, ma al contempo aumenta anche il tempo di calcolo.
- *max_features*: 'None', 'sqrt', 'log2'. Questo parametro determina il numero massimo di caratteristiche da considerare quando l'algoritmo cerca il punto di divisione migliore per ogni nodo dell'albero. *None* indica che l'algoritmo utilizza tutte le caratteristiche disponibili, *sqrt* indica che l'algoritmo utilizza la radice quadrata del numero totale di caratteristiche, mentre *log2* indica che l'algoritmo utilizza il logaritmo di base due del numero totale di caratteristiche. Queste due ultime misure permettono di limitare il numero di caratteristiche da esplorare per ogni divisione, portando una riduzione della correlazione tra i vari alberi.
- *max_depth*: None, 10, 20, 50. Limita la profondità massima degli alberi. Un limite alla profondità può ridurre il rischio di *overfitting*, ma alberi troppo poco profondi potrebbero non essere in grado di catturare la complessità dei dati, portando a *underfitting*.
- *min_samples_split*: 2, 5, 10. Questo parametro definisce il numero minimo di campioni necessari per dividere un nodo. Un valore basso aumenta la complessità dell'albero, aumentando il rischio di *overfitting*, mentre valori più alti potrebbero non cogliere tutta la variabilità nei dati.
- *min_sample_leaf*: 2, 5, 10. Determina il numero minimo di campioni necessari nel nodo terminale (chiamato anche foglia). Avere foglie più grandi può ridurre il rischio di *overfitting* ma limitare la capacità dell'albero di adattarsi ai dati.
- *bootstrap*: True. Questo parametro quando è impostato su *True*, ogni albero della foresta è costruito su un campione casuale con sostituzione dei dati originali, questo vuol dire che ogni albero può vedere più volte lo stesso campione, ma ogni albero vedrà solo una parte dei dati, riducendo la varianza del modello e migliorando la sua robustezza, e quindi diminuendo il rischio di *overfitting*.

I migliori parametri trovati sono: *n_estimators*: 300, *max_depth*: None, *max_features*: sqrt, *min_samples_split*: 5, *min_sample_leaf*: 10, *bootstrap*: True. Il miglior punteggio di accuratezza ottenuto durante la *Grid Search CV* è stato 0.6861, mentre l'accuratezza del modello con i parametri ottimizzati sul *test set* è stata 0.6543.

Successivamente, è stata condotta una *K-Fold Cross Validation* con 15 fold, che ha portato a un'accuratezza media di 0.6821. L'accuratezza finale, calcolata sul *test set*, è risultata pari a 0.6590, leggermente superiore rispetto alla *Grid Search*. Le altre metriche ottenute sono:

- *F1-Score*: 0.7021,
- *Recall*: 0.7522,
- *Precision*: 0.6582,
- *AUC-ROC (Area Under the Curve)*: 0.7136.




Figura 84. Modello Random Forest. Istogramma dei punteggi predetti




Figure 85-87. Modello Random Forest. TPR e FPR per ogni threshold, ROC Curve, PR Curve

Le curve *ROC* e *Precision-Recall*, mostrate nelle Figure 85-87, rivelano un comportamento simile a quello osservato negli altri algoritmi. La curva *Precision-Recall* (Figura. 87) continua a presentare una forma irregolare, con una discesa ripida iniziale, meno accentuata e più frastagliata rispetto ai modelli precedenti. Anche l'istogramma dei punteggi predetti (Figura. 84) mostra un comportamento simile a quello del *Gradient Boosting*, con un'analoga distribuzione dei punteggi.

In conclusione, esaminando le matrici di confusione e i report di classificazione per i tre modelli, si osserva che l'accuratezza dell'algoritmo *Random Forest* è migliorata rispetto al modello base. L'accuratezza è passata da 64.59% nel modello base a 65.43% nel modello ottimizzato tramite *Grid Search*, fino a 65.90% nel modello con 15-fold *Cross Validation*. Questo miglioramento si riflette principalmente nell'incremento della capacità del modello di identificare i positivi (classe 1.0), come evidenziato dal valore massimo di *Recall* pari a 0.75.

Tuttavia, entrambi i modelli ottimizzati presentano alcune difficoltà nel classificare correttamente i negativi (classe 0.0), con un *Recall* inferiore (intorno a 0.55) rispetto al modello base. Nonostante ciò, i modelli ottimizzati mostrano un miglioramento significativo nella capacità di identificare i positivi, evidenziando il trade-off tra precisione e *Recall*.

In sintesi, l'algoritmo *Random Forest*, pur mostrando un buon miglioramento rispetto al modello base, presenta ancora alcune sfide nel bilanciare la classificazione delle due classi. Il modello con *Cross Validation* risulta essere il più robusto, offrendo una maggiore generalizzazione rispetto agli altri modelli, sebbene le differenze tra i vari approcci siano relativamente marginali.




Figure 88-90. Confronto delle Confusion Matrix dei tre modelli *Random Forest*: Base, con *Grid Search* e infine con *Cross-Validation*

Modello Base: *Random Forest*

Classe	Precision	Recall	F1-Score	Support
0.0	0.63	0.57	0.60	996
1.0	0.66	0.71	0.68	1142
Accuracy			0.65	2138
Macro Avg	0.64	0.64	0.64	2138
Weighted Avg	0.64	0.65	0.64	2138

Tabella 15: Report di classificazione: Modello Random Forest Base

Modello con Grid Search: *Random Forest*

Classe	Precision	Recall	F1-Score	Support
0.0	0.65	0.55	0.60	996
1.0	0.66	0.75	0.70	1142
Accuracy			0.65	2138
Macro Avg	0.65	0.65	0.65	2138
Weighted Avg	0.65	0.65	0.65	2138

Tabella 16: Report di classificazione: Modello Random Forest con Grid Search CV

Modello con Cross-Validation: *Random Forest*

Classe	Precision	Recall	F1-Score	Support
0.0	0.66	0.55	0.60	996
1.0	0.66	0.75	0.70	1142
Accuracy			0.66	2138
Macro Avg	0.66	0.65	0.65	2138
Weighted Avg	0.66	0.66	0.65	2138

Tabella 17: Report di classificazione: Modello Random Forest con K-Fold Cross Validation (15 fold)

Voting Classifier

L'ultimo algoritmo di *ensemble learning* è il *Voting Classifier*, che combina le previsioni di più classificatori per migliorare l'accuratezza complessiva del modello. Il principio alla base di questo algoritmo è semplice: combinare le previsioni di diversi modelli di classificazione per ottenere una previsione finale più robusta e precisa rispetto a quella prodotta da ciascun modello individuale. Il *Voting Classifier* si distingue per il fatto che il suo "voto" può essere di due tipi:

- Voto maggioritario (*hard voting*): ogni classificatore fornisce una previsione di classe, e la classe che ottiene il maggior numero di "voti" diventa la previsione finale.
- Voto ponderato (*soft voting*): in questo, ogni classificatore fornisce una probabilità per ciascuna classe, e la classe con la probabilità complessiva più alta (media ponderata delle probabilità) viene scelta come previsione finale.

Questo algoritmo prende in considerazione diversi modelli di classificazione, come quelli descritti nel Paragrafo 7.2: *SVC*, *Gradient Boosting*, *AdaBoost*, *Regressione Logistica*, *Random Forest* e *MLPClassifier*. Per tutti questi modelli, è stato utilizzato il modello ottimizzato tramite *Grid Search CV*, e non quello base. Tutti i modelli utilizzati sono compatibili con il *Voting Classifier*, ad eccezione dell'*SVM* (*SVC*), per il quale è necessario impostare il parametro *probability=True* affinché possa essere integrato nel modello di *Voting*. Per questa ragione, il parametro verrà impostato nei futuri modelli *SVC*, permettendo così l'utilizzo della modalità di *Voting*.

Modelli come *Gradient Boosting* e *AdaBoost* restituiscono direttamente la probabilità di classe, mentre *Regressione Logistica*, *Random Forest* e *MLP* supportano attivamente il *soft voting* in quanto sono in grado di restituire le probabilità delle classi.

Quando il modello deve fare una previsione, ciascun classificatore "vota" per una classe. Nel caso di *hard voting*, la classe che ottiene il maggior numero di voti viene scelta come previsione finale. Nel caso di *soft voting*, viene scelta la classe con la probabilità complessiva più alta, cioè quella che ha la media ponderata più alta delle probabilità previste dai singoli classificatori.

Questa tecnica presenta numerosi vantaggi, tra cui una maggiore robustezza e prestazioni superiori rispetto ai singoli modelli. Tuttavia, ci sono anche delle limitazioni. La principale di queste è l'aumento della complessità computazionale, che potrebbe non sempre portare a miglioramenti significativi nelle performance. A volte, l'aumento della complessità può non giustificare i miglioramenti, specialmente se questi sono minimi. se aumenta di molto la complessità computazionale per bassissimi miglioramenti.

Poiché gli algoritmi coinvolti provengono da diverse famiglie (ad esempio, *boosting* e *Bagging*), la loro combinazione può risultare vantaggiosa. Questo approccio permette di sfruttare i punti di forza di ciascun algoritmo e ridurre le debolezze degli altri, creando un modello finale più robusto. Sebbene il *Voting Classifier* aiuti a ridurre l'*overfitting*, è importante non aggiungere troppi modelli simili fra loro, in quanto ciò potrebbe aumentare il rischio di *overfitting*. Nel nostro caso, sono stati utilizzati sei algoritmi.

In linea teorica, per ridurre l'*overfitting*, si potrebbero scegliere uno fra *AdaBoost* o *Gradient Boosting*, poiché appartengono entrambi alla famiglia del boosting e sono simili nel loro approccio. Tuttavia, *Gradient Boosting* tende a essere più sofisticato, quindi questo è stato preferito. Inoltre, si potrebbe decidere di mantenere *MLP* o *SVC*, poiché sono modelli non lineari che cercano di modellare relazioni complesse, sebbene non siano molto simili tra loro. Entrambi i modelli sono complessi e potrebbero essere inclini a *overfitting* con dati limitati.

Il *Voting Classifier* completo, che include tutti e sei i classificatori, ha ottenuto un'accuratezza di circa 65%. Più precisamente:

- il modello *soft voting* ha un'accuratezza di 0.6586,
- il modello *hard voting* ha un'accuratezza di 0.6539.

Quando si utilizzano solo alcuni classificatori (modello ridotto), con l'inclusione dei soli algoritmi di *Gradient Boosting*, *Random Forest*, *MLP* e Regressione Logistica, il modello *hard voting* ha una leggera superiorità in termini di accuratezza, con un valore di 0.6562, mentre il modello *soft voting* ha un'accuratezza di 0.6572 (leggermente più bassa).



Figura 91. Modello Voting Classifier (Hard, Completo). Istogramma dei punteggi predetti




Figure 92-94. Modello Voting Classifier (Hard, Completo). TPR e FPR per ogni threshold, ROC Curve, PR Curve

Le metriche aggiuntive calcolate sul modello *hard* completo, che ha ottenuto l'accuratezza migliore, sono le seguenti:

- *F1 Score*: 0.6935
- *Recall*: 0.7329
- *Precision*: 0.6580
- *AUC (Area Under the Curve)*: 0.7112

In generale, i modelli basati su *soft voting* si rivelano più efficaci nell'individuare i veri positivi, con un *Recall* e un *F1 Score* più alti rispetto ai modelli *hard voting*. Infatti, il modello *soft* completo ha una maggiore sensibilità, riuscendo a identificare meglio i veri positivi, ma può soffrire di una precisione inferiore. D'altro canto, i modelli *hard voting* tendono a classificare meglio i veri negativi e presentano un tasso inferiore di falsi positivi, segnando una maggiore precisione nella classificazione dei negativi, ma con una minore sensibilità verso i positivi.

Confrontando il modello completo e il modello ridotto, quest'ultimo mostra una precisione migliore sui negativi, grazie a tassi più bassi di falsi positivi. Tuttavia, perde in termini di identificazione dei veri positivi. Al contrario, il modello completo ha una maggiore sensibilità, con minori falsi negativi e un numero maggiore di veri positivi.

Confusion Matrix a confronto




Figure 95-96. Confronto delle Confusion Matrix del modello Voting Classifier Completo soft e hard

Confusion Matrix a confronto




Figure 97-98. Confronto delle Confusion Matrix del modello Voting Classifier Ridotto soft e hard

Modello Soft: Voting Classifier (Completo)

Classe	Precision	Recall	F1-Score	Support
0.0	0.66	0.55	0.60	996
1.0	0.66	0.76	0.70	1142
Accuracy			0.66	2138
Macro Avg	0.66	0.65	0.65	2138
Weighted Avg	0.66	0.65	0.65	2138

Tabella 18: Report di classificazione: Modello Voting Classifier (Soft, Completo)

Modello Hard: Voting Classifier (Completo)

Classe	Precision	Recall	F1-Score	Support
0.0	0.65	0.56	0.60	996
1.0	0.66	0.73	0.69	1142
Accuracy			0.65	2138
Macro Avg	0.65	0.65	0.65	2138
Weighted Avg	0.65	0.65	0.65	2138

Tabella 19: Report di classificazione: Modello Voting Classifier (Hard, Completo)

Modello Soft: Voting Classifier (Ridotto)

Classe	Precision	Recall	F1-Score	Support
0.0	0.66	0.55	0.60	996
1.0	0.66	0.75	0.70	1142
Accuracy			0.66	2138
Macro Avg	0.66	0.65	0.65	2138
Weighted Avg	0.66	0.65	0.65	2138

Tabella 20: Report di classificazione: Modello Voting Classifier (Soft, Ridotto)

Modello Hard: Voting Classifier (Ridotto)

Classe	Precision	Recall	F1-Score	Support
0.0	0.65	0.60	0.62	996
1.0	0.66	0.71	0.69	1142
Accuracy			0.66	2138
Macro Avg	0.65	0.65	0.65	2138
Weighted Avg	0.65	0.65	0.65	2138

Tabella 21: Report di classificazione: Modello Voting Classifier (Hard, Ridott0)

7.2.4 SUPPORT VECTOR MACHINE

Support Vector Classifier

L'algoritmo *SVM*, nello specifico il *Support Vector Classifier (SVC)*³⁶, si è classificato come il quarto più efficiente. D'ora in poi, gli algoritmi trattati saranno analizzati con meno dettaglio, in quanto hanno avuto prestazioni inferiori rispetto ai precedenti. Tuttavia, il metodo di lavoro per questi algoritmi è stato lo stesso. L'*SVC* appartiene alle tecniche di apprendimento supervisionato e viene utilizzato sia per problemi di classificazione (come in questo caso) che per problemi di regressione. L'obiettivo principale di *SVC* è identificare una superficie di separazione che divide i dati in diverse classi. È applicabile sia a problemi lineari che non lineari, a seconda del tipo di kernel scelto. I kernel principali sono:

- *Linear*: usato per dati separabili linearmente.
- *RBF (Radial Basis Function, anche noto come Gaussian Kernel)*: molto potente per dati non lineari, mappa tutti i dati in uno spazio ad alta dimensione, nel quale è più facile separare meglio di dati.
- *Poly*: viene utilizzato quando i dati non sono separabili linearmente. Rispetto al kernel lineare, il kernel polinomiale introduce due parametri: un offset (o costante) e un grado di polinomio. Quando il kernel è di grado 1, si comporta come un kernel lineare, ma con l'aggiunta di un parametro di offset che influisce sul prodotto scalare.
- *Sigmoid*: basato sulla funzione sigmoide logistica.

L'*SVC* è tradizionalmente utilizzato per problemi di classificazione, dove l'obiettivo è separare le classi in uno spazio multidimensionale, e per la regressione (*Support Vector Regression, SVR*), dove l'obiettivo è predire valori continui. Tuttavia, uno aspetto utile dell'*SVC* è la sua capacità di identificare gli out-

36 SVC. sklearn.svm, Scikit Learn. <https://scikit-learn.org/stable/modules/generated/sklearn.svm.SVC>

lier nei dati, ovvero quegli esempi che si discostano significativamente dal comportamento “normale” del resto dei dati.

Il modello base ha restituito un'accuratezza di 0.6333. Successivamente, è stata eseguita una *Grid Search CV* per ottimizzare i parametri. I parametri testati includono:

- *Kernel: rbf, linear, poly, sigmoid.* Usati per mappare i dati in spazi ad alta dimensione e trovare l'iperpiano che separa le classi.
- *C: 0.1, 1.0, 10.0.* Questo parametro controlla la penalizzazione degli errori di classificazione, aumentandolo si dà maggiore importanza alla minimizzazione di tali errori, di conseguenza un valore più basso consente una tolleranza maggiore verso gli errori.
- *gamma: scale, auto, 0.01, 0.1.* è un parametro usato solo nei kernel rbf, sigmoid e poly, il quale controlla l'influenza di ogni singolo punto di addestramento sulla classificazione, ovvero è legato al kernel e determina quanto lontano un esempio può influenzare il processo di classificazione. Più il valore è alto più diventa rigido il processo di classificazione. I valori scale e auto si riferiscono rispettivamente a: scale imposta il valore di gamma in base alla varianza dei dati e al numero delle caratteristiche, mentre auto corrisponde all'inverso del numero delle caratteristiche del dataset (*feature*).
- *Degree: 1, 2, 3.* È un parametro utilizzato soltanto dal *kernel poly*, e definisce il grado del polinomio utilizzato.
- *Coef0: 0.0, 0.1, 1.0, 10.0.* Questo parametro è utilizzato soltanto con il *kernel ploy* e sigmoid, ed un valore che regola l'influenza del termine costante nel calcolo del *kernel*. Più il valore basso più questo rende il modello meno complesso e generalizzabile, mentre più è alto aumenta di conseguenza il rischio di *overfitting*.
- *shrinking: True, False.* Quando questo parametro viene impostato su *True* l'algoritmo ottimizza il processo per velocizzare l'apprendimento
- *probability: True, False.* Quando è impostato su *True*, questo parametro abilita il calcolo delle probabilità per ogni classe.
- *class_weight: None, Balanced.* utilizzato per bilanciare l'importanza delle diverse classi nel caso in cui i dati siano sbilanciati, in questo caso, essendo che le classi erano abbastanza bilanciate, sarà settato su *None*

Sono state eseguite tre analisi di *Grid Search*, una per ogni tipo di kernel, dato che ogni analisi richiedeva ore di calcolo. La performance migliore è stata ottenuta utilizzando il *kernel RBF* con i parametri: *C: 10.0, gamma: 0.01, probability: True, shrinking: False, class_weight: None*. Questo modello ha raggiunto un'accuratezza di 0.6370, con un miglioramento marginale rispetto al modello base. Successivamente, è stata effettuata una 15-fold *Cross Validation*, che ha riportato un'accuratezza di 0.6333, tornando al valore iniziale del modello base.




Figura 99. Modello SVC. Istogramma dei punteggi predetti




Figure 100-102. Modello SVC. TPR e FPR per ogni threshold, ROC Curve, PR Curve

Le restanti metriche, come, *F1 Score* di 0.6998, *Recall* 0.8004, *Precision* 0.6218, mentre l'area sotto la curva *ROC* è di 0.6829. La *Recall* di questo modello è il più alto tra quelli ottenuti, indicando che ha identificato correttamente circa l'80% dei veri positivi. Come evidenziato dalla Figura 102, la curva che mette in relazione precisione e *Recall* mostra un andamento particolare: un iniziale calo, seguito da una risalita, quindi un andamento frastagliato prima della discesa finale.

Confrontando le matrici di confusione (Figure 103-105), si nota che i veri positivi aumentano con ogni miglioramento del modello. Tuttavia, cresce anche il numero di falsi positivi. Il modello sembra concentrarsi maggiormente sull'identificare i positivi, riducendo i falsi negativi, ma questo porta a un aumento dei falsi positivi. Ciò suggerisce che il modello sta migliorando nella capacità di identificare correttamente i positivi, ma a costo di classificare troppi negativi come positivi. Questo comportamento

potrebbe risultare particolarmente utile in applicazioni come le diagnosi mediche, dove è più importante identificare correttamente i positivi (ad esempio, i malati) piuttosto che minimizzare i falsi positivi.




Figure 103-105. Confronto delle Confusion Matrix dei tre modelli SVC: Base, con Grid Search e in fine con Cross-Validation

Modello Base: SVC

Classe	Precision	Recall	F1-Score	Support
0.0	0.65	0.46	0.54	996
1.0	0.63	0.78	0.69	1142
Accuracy			0.63	2138
Macro Avg	0.64	0.62	0.62	2138
Weighted Avg	0.64	0.63	0.62	2138

Tabella 22: Report di classificazione: Modello SVC Base

Modello con Grid Search: SVC

Classe	Precision	Recall	F1-Score	Support
0.0	0.66	0.46	0.54	996
1.0	0.63	0.80	0.70	1142
Accuracy			0.64	2138
Macro Avg	0.64	0.63	0.62	2138
Weighted Avg	0.64	0.64	0.63	2138

Tabella 23: Report di classificazione: Modello SVC con Grid Search CV

Modello con Cross-Validation: SVC

Classe	Precision	Recall	F1-Score	Support
0.0	0.66	0.44	0.53	996
1.0	0.62	0.80	0.70	1142
Accuracy			0.63	2138
Macro Avg	0.64	0.62	0.61	2138
Weighted Avg	0.64	0.63	0.62	2138

Tabella 24: Report di classificazione: Modello SVC con K-Fold Cross Validation (15 fold)

7.2.5 LINEAR MODEL

Logistic Regression

L'algoritmo di regressione logistica³⁷ è uno dei più utilizzati nei problemi di classificazione, sia per classificazione binaria che per classificazione multiclasse, come visto nel Capitolo 5. Nonostante il modello di regressione logistica non abbia raggiunto i migliori risultati in termini di accuratezza nei confronti degli altri algoritmi, è stato comunque incluso nell'analisi. La decisione di farlo è stata presa per aggiungere un algoritmo lineare nel *Voting Classifier*, in quanto i modelli lineari possono catturare sfumature nei dati che altri algoritmi non riescono a rilevare.

Il modello di regressione logistica ha restituito un'accuratezza di base pari a 0.6183, mentre l'accuratezza ottenuta con la *Grid Search CV* è salita a 0.6249, segnando un leggero miglioramento.

Durante la *Grid Search*, sono stati testati diversi parametri:

- *C*: 0.1, 1, 10, 100. Questo parametro è usato per la regolarizzazione, bilanciando il trade-off tra ridurre l'errore sul *training set* e mantenere la complessità del modello. Valori bassi di *C* aumentano la regolarizzazione, riducendo il rischio di *overfitting*, mentre valori alti consentono una maggiore complessità e capacità di adattamento ai dati, ma con il rischio di sovradattamento.
- *Solver*: *liblinear*, *newton-cg*, *lbfgs*, *saga*. Il solver è l'algoritmo usato per ottimizzare i pesi nel modello. *Liblinear* è basato sulla discesa del gradiente ed è molto efficace nei problemi con piccoli set di dati o quando utilizzata la regolarizzazione l1. *Newton-cg* e *Lbfgs* utilizza il metodo di Newton per ottimizzare il modello, ed è efficiente per dataset grandi dimensio-

37 LogisticRegression. `sklearn.linear_model`, Scikit Learn. https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LogisticRegression

ni e con una regolarizzazione l_2 . *Saga* è un solver basato sulla stochastic average gradient descent, che è molto efficiente per dataset di grandi dimensioni e può gestire sia la regolarizzazione L_1 che L_2 .

- *Penalty: l1, l2, elasticnet*. Questo parametro è il tipo di regolarizzazione applicata al modello, nel primo caso si tratta di una regolarizzazione lasso, ovvero aggiunge un termine di penalizzazione proporzionale alla somma dei valori assoluti dei coefficienti. Il secondo termine riguarda la regolarizzazione ridge, il quale penalizza coefficienti in base al quadrato dei loro valori riducendo al loro grandezza senza annullarli completamente. Mentre l'ultimo è una combinazione delle due realizzazioni precedenti, rendendo il modello più flessibile.
- *max_iter: 100, 200, 500*. È la specificazione del numero massimo di interazioni che l'algoritmo di ottimizzazione, ovvero solver, può eseguire prima di fermarsi. Più il valore alto più consente all'algoritmo di esplorare fino a fondo.
- *Tol: 0.0001, 0.001*. Questo parametro riguarda la tolleranza che stabilisce il criterio di arresto dell'algoritmo di ottimizzazione.
- *class_weight: balanced, None*. Riguarda il bilanciamento delle classi nel caso di un dataset sbilanciato, in questo caso essendo che il dataset è bilanciato verrà impostato su *None*.

I migliori parametri trovati sono: *C: 1, class_weight: None, max_iter: 100, penalty: l1, solver: liblinear, tol: 0.001*.

In base a questi parametri è stata effettuata una *K-Fold Cross Validation*, con 15 folds, la quale ha riportato un valore di accuratezza di 0.6207, anche in questo caso leggermente più basso rispetto alla fase precedente. Le metriche aggiuntive sono: *F1 Score: 0.6362, Recall: 0.6208, Precision: 0.6523*, e *AUC (Area Under Curve): 0.6647*.




Figura 106. Modello Logistic. Istogramma dei punteggi predetti




Figure 107-109. Modello Logistic. TPR e FPR per ogni threshold, ROC Curve, PR Curve

In conclusione, nel confronto delle matrici di confusione, il modello con *Grid Search* ha migliorato la capacità di identificare i veri negativi, passando da 479 a 622. Tuttavia, la matrice del modello con *Cross Validation* appare leggermente peggiore, con una diminuzione sia dei veri positivi che dei veri negativi, ma un aumento delle predizioni errate (falsi positivi e falsi negativi).

In generale, la regressione logistica si è rivelata particolarmente efficace nell'individuare i veri negativi, equilibrando meglio le previsioni positive e negative rispetto agli altri modelli. A differenza di modelli come *SVM*, che tendono a fare più predizioni positive (a scapito dei negativi), la regressione logistica tende a fare un bilanciamento migliore tra le due classi, risultando più adatta in contesti in cui è cruciale identificare correttamente i valori negativi.




Figure 110-112. Confronto delle Confusion Matrix dei tre modelli Logistic: Base, con Grid Search e in fine con Cross-Validation

Modello Base: Logistic

Classe	Precision	Recall	F1-Score	Support
0.0	0.61	0.50	0.55	996
1.0	0.62	0.72	0.67	1142
Accuracy			0.62	2138
Macro Avg	0.62	0.61	0.61	2138
Weighted Avg	0.62	0.62	0.61	2138

Tabella 25: Report di classificazione: Modello Logistic Base

Modello con Grid Search: Logistic

Classe	Precision	Recall	F1-Score	Support
0.0	0.59	0.63	0.61	996
1.0	0.66	0.62	0.64	1142
Accuracy			0.62	2138
Macro Avg	0.62	0.63	0.62	2138
Weighted Avg	0.63	0.62	0.63	2138

Tabella 26: Report di classificazione: Modello Logistic con Grid Search CV

Modello con Cross-Validation: Logistic

Classe	Precision	Recall	F1-Score	Support
0.0	0.59	0.62	0.60	996
1.0	0.62	0.62	0.64	1142
Accuracy			0.62	2138
Macro Avg	0.62	0.62	0.62	2138
Weighted Avg	0.62	0.62	0.62	2138

Tabella 27: Report di classificazione: Modello Logistic con K-Fold Cross Validation (15 fold)

7.2.6 NEURAL NETWORK (SKLEARN)

Multi-layer Perceptron Classifier

L'algoritmo *Multi-Layer Perceptron Classifier*³⁸ (MLP) è una tipologia di rete neurale *feedforward*, utilizzata per compiti di classificazione. Questo modello è stato scelto anche per il suo utilizzo nel *Voting Classifier*, oltre a servire come base per confrontare le prestazioni con modelli più complessi, come quelli implementati con TensorFlow, di cui si parlerà nel Paragrafo 7.4. L'algoritmo *MLP*, appartenente alla famiglia delle reti neurali artificiali (*ANN*), è composto da vari strati: *input*, strati nascosti, che permettono alla rete di apprendere e fare trasformazioni non lineari sui dati, e lo strato di *output*, che produce il risultato finale. Inizialmente, l'algoritmo assegna casualmente i pesi. Successivamente, tramite la *forward propagation*, i dati attraversano i vari strati, passando per i neuroni che applicano funzioni di attivazione. Quando i dati raggiungono lo strato di *output*, viene calcolato l'errore, cioè la differenza tra la predizione della rete e il valore reale, misurato con una funzione di perdita (*loss function*), come la cross-entropy.

Una volta calcolato l'errore, processo di *backpropagation*, lo riporta attraverso la rete per aggiornare i pesi, ottimizzandoli e riducendo progressivamente l'errore. Questo ciclo di *forward propagation*, e viene ripetuto per un numero di epoche stabilito. La spiegazione di questo processo, avverrà in maniera più dettagliata nel Sottoparagrafo 7.4.1. Introduzione alle Reti Neurali Artificiali.

Il modello base, come per tutti gli altri, utilizza parametri di default, come la funzione di attivazione *ReLU*, il solver *Adam* e 100 strati nascosti, e restituisce un'accuratezza di 0.6338. Tuttavia, il modello con *Grid Search*, dove i *K-Fold* sono stati ridotti a 3 per ridurre il tempo di elaborazione, mostra un miglioramento. Come indicato in precedenza, nei paragrafi successivi verrà introdotta una rete più complessa e articolata.

In questo caso, i parametri considerati sono:

- *hidden_layer_sizes*: 100, 50+50, 200
- *activation*: *ReLU*, *tanh*, *logistic*
- *solver*: *Adam*, *SGD*
- *alpha*: *uniform* (0.00001, 0.01)
- *learning_rate_init*: *uniform* (0.001, 0.1)

I migliori parametri risultano essere: *hidden_layer_size*: 200, *activation*: *ReLU*, *solver*: *SGD*, *alpha*: 0.006, *learning_rate_init*: 0.003. Con questi parametri si ottiene un incremento dell'accuratezza di quasi un punto percentuale, portando il nuovo valore a 0.6469. Utilizzando la *Cross Validation* con 15 *K-Fold*, l'accuratezza sale a 0.6506. Le ulteriori metriche sono: *F1 Score* di 0.6992, *Recall* di 0.7601, *Precision* di 0.6473 e l'area sotto la curva *ROC* di 0.6945.

38 MLPClassifier. `sklearn.neural_network`, Scikit Learn. https://scikit-learn.org/stable/modules/generated/sklearn.neural_network.MLPClassifier



Figura 113. Modello MLP. Istogramma dei punteggi predetti




Figure 114-116. Modello MLP. TPR e FPR per ogni threshold, ROC Curve, PR Curve

In conclusione, il modello ha mostrato un miglioramento marginale dell'accuratezza, passando da 0.627 a 0.651. La differenza è evidente soprattutto nell'aumento dei veri positivi, che passano da 819 a 868, riducendo di conseguenza i falsi negativi. I valori di veri negativi e falsi positivi restano pressoché invariati. Pertanto, l'adozione della tecnica *Grid Search* prima e della *Cross Validation* successivamente ha portato miglioramenti significativi nelle performance predittive del modello.




Figure 117-118. Confronto delle Confusion Matrix dei tre modelli MLP: Base, con Grid Search e in fine con Cross-Validation

Modello Base: MLP

Classe	Precision	Recall	F1-Score	Support
0.0	0.61	0.53	0.57	996
1.0	0.63	0.72	0.67	1142
Accuracy			0.63	2138
Macro Avg	0.63	0.62	0.62	2138
Weighted Avg	0.63	0.63	0.62	2138

Tabella 28: Report di classificazione: Modello MLP Base

Modello con Grid Search: MLP

Classe	Precision	Recall	F1-Score	Support
0.0	0.65	0.52	0.58	996
1.0	0.64	0.75	0.70	1142
Accuracy			0.65	2138
Macro Avg	0.65	0.64	0.64	2138
Weighted Avg	0.65	0.65	0.64	2138

Tabella 29: Report di classificazione: Modello MLP con Grid Search CV

Modello con Cross-Validation: MLP

Classe	Precision	Recall	F1-Score	Support
0.0	0.66	0.53	0.58	996
1.0	0.65	0.76	0.70	1142
Accuracy			0.65	2138
Macro Avg	0.65	0.64	0.64	2138
Weighted Avg	0.65	0.65	0.65	2138

Tabella 30: Report di classificazione: Modello MLP con K-Fold Cross Validation (15 fold)

7.3 I MIGLIORI MODELLI E LE MIGLIORI FEATURES NEGLI ALGORITMI DI ML

7.3.1 IL MIGLIORE MODELLO

Inizialmente, è stata condotta una *K-Fold Cross Validation* su tredici algoritmi proposti, con l'obiettivo di identificare i cinque migliori. Tuttavia, sono stati selezionati sei algoritmi, in quanto è stato ritenuto opportuno aggiungere un ulteriore modello lineare tra quelli analizzati. Da questi sei è stato successivamente costruito un settimo modello che li integra, con l'algoritmo *Voting*. L'analisi complessiva ha riguardato tutti e sette i modelli, al fine di identificare il migliore algoritmo predittivo

Per la valutazione delle prestazioni, sono state utilizzate le seguenti metriche: accuratezza, *F1 Score*, *Recall* e *precision*. Per quest'ultime tre metriche, sono stati forniti anche i valori separati per ciascuna delle due classi target. I risultati, come mostrato nelle Tabelle 31 e 32 e nei grafici (Figure 119-122), evidenziano che le differenze tra gli algoritmi sono minime, con un'accuratezza che varia tra il 65% e il 66%, con una differenza inferiore ad un punto percentuale, per la maggior parte degli algoritmi.

In particolare, per quanto riguarda l'accuratezza, l'algoritmo con la prestazione migliore è il *Gradient Boosting*, con un valore di 0.66, seguito dal *Voting Classifier* (0.657) e da *AdaBoost* (0.654). I modelli con le prestazioni inferiori sono *SCV* e *Logistic Regression*. Il modello *Gradient Boosting* non solo ha ottenuto il valore più alto per l'accuratezza, ma si è distinto anche nelle metriche di *F1 Score*, sia per quella complessiva quanto per ciascuna delle due classi. L'*F1 Score* rappresenta la media armonica tra precisione e *Recall* ed è particolarmente utile quando si desidera un compromesso tra queste due metriche. L'algoritmo *Gradient Boosting* ha raggiunto un punteggio complessivo di 0.702, seguito dal *Voting Classifier* (0.70) e da *AdaBoost* (0.697), oltre alla metrica complessiva, il modello nel quale è stato usato *Gradient Bosting* è quello con le metriche più alte sia per la classe 0 che 1.




Figure 119 - 122. Confronto delle Metriche dei differenti modelli: Accuracy, F1 Score, Recall e Precision

Per quanto concerne la *precision*, che misura la proporzione di previsioni positive corrette, il miglior algoritmo è nuovamente il *Gradient Boosting* con un punteggio di 0.6610, seguito da *AdaBoost* (0.656) e *Random Forest* (0.646). Questo risultato indica che il modello *Gradient Boosting* è il più efficace nel minimizzare i falsi positivi e nel predire correttamente la classe positiva.

Per la *Recall*, che misura la proporzione dei valori veri positivi correttamente identificati, il modello con il punteggio più alto è il *Support Vector Classifier* per la metrica complessiva (0.80). Tuttavia, il punteggio più alto per la classe 0 è stato ottenuto con la *Logistic Regression* (0.62), mentre per la classe 1 il migliore è stato il *Voting Classifier* (0.80). Questo suggerisce che molti modelli si sono concentrati maggiormente nel rilevare correttamente gli esempi della classe 1, con un *Recall* per la classe 0 generalmente inferiore, l'unico modello che bilancia i valori di *Recall* per le due classi è *Logistic Regression*. Il *Recall* complessivo varia tra il 62% e l'80%, con un forte focus sulla classe 1, che ha generalmente valori di *Recall* superiori rispetto alla classe 0. La classe 1 è ben identificata dalla maggior parte dei modelli, con un *Recall* che supera spesso il 70%, arrivando anche all'80%. Al contrario, il *Recall* per la classe 0 è inferiore, con valori particolarmente bassi nel *Voting Classifier* (42%).

Infine, una metrica che non è presente nei grafici è l'*AUC ROC*, ovvero l'area sotto la curva ROC, e varia tra 0.664 e 0.711, con i modelli *Gradient Boosting* e *Random Forest* che ottengono i punteggi migliori, pari a circa 0.71. Un *AUC* più alto indica una migliore capacità di separazione tra le classi, con valori prossimi a 1 che riflettono una separazione perfetta. Modelli come *SVM* (0.682) e *Logistic Regression* (0.664) presentano una separazione leggermente più debole.

Algoritmo	Accuracy	F1 Score	Recall	Precision	AUC ROC
Gradient Boosting	0.660430	0.701726	0.747811	0.660991	0.711215
Ada Boosting	0.654350	0.696758	0.743433	0.655598	0.697616
Random Forest	0.648269	0.693061	0.743433	0.649083	0.711796
Voting Classifier	0.657156	0.699847	0.732925	0.658019	0.711212
Support Vector Machine	0.633302	0.699154	0.800350	0.621769	0.682839
Logistic Regression	0.620674	0.636160	0.620841	0.652254	0.664694
MLP	0.650608	0.693455	0.760070	0.647278	0.694458

Tabella 31: Risultati delle metriche dei modelli, in grassetto i risultati migliori

Algoritmo	F1 Score Class 0	F1 Score Class 1	Recall Class 0	Recall Class 1	Precision Class 0	Precision Class 1
Gradient Boosting	0.605863	0.701726	0.560241	0.747811	0.659574	0.660991
Ada Boosting	0.598151	0.696758	0.552209	0.743433	0.652432	0.655598
Random Forest	0.588171	0.693061	0.539157	0.743433	0.646988	0.649083
Voting Classifier	0.528846	0.699847	0.441767	0.800350	0.658683	0.621769
Support Vector Machine	0.583380	0.699154	0.525100	0.760070	0.588011	0.652254
Logistic Regression	0.603810	0.636160	0.620482	0.620841	0.656211	0.647278
MLP	0.602578	0.693455	0.563253	0.732925	0.647806	0.658019

Tabella 32: Risultati delle metriche per le classi 0 e 1 dei modelli, in grassetto i risultati migliori

Prestazioni del Miglior Modello:

- *Accuracy: 0.6604, Gradient Boosting.*
- *F1 Score: 0.7017, Gradient Boosting,*
 - *F1 Score Class 0: 0.6059, Gradient Boosting,*
 - *F1 Score Class 1: 0.7017, Gradient Boosting.*
- *Recall: 0.8004, Support Vector Machine,*
 - *Recall Class 0: 0.6205, Logistic Regression,*
 - *Recall Class 1: 0.8004, Voting Classifier.*

- *Precision* : 0.6610, *Gradient Boosting*,
- *Precision Class 0*: 0.6596, *Gradient Boosting*.
- *Precision Class 1*: 0.6610, *Gradient Boosting*.

In conclusione, il modello nel quale è stato usato l'algoritmo *Gradient Boosting* emerge come il migliore per le prestazioni complessive, grazie alla sua capacità di ottimizzare sia l'accuratezza che le altre metriche di performance, generando una predizione leggermente più equilibrata delle classi e una buona capacità di separazione tra di esse rispetto agli altri modelli.

7.3.2 LE FEATURE MIGLIORI

Una volta individuato il modello migliore, ci si è concentrati sull'identificazione delle migliori feature, ovvero le variabili, più importanti, con l'obiettivo di inserire solo quelle significative nel miglior modello. A tale scopo, sono state utilizzate due tecniche: *Feature Importances*³⁹ e *Shap*⁴⁰. La prima, *feature_importance*, è una metrica presente in molti algoritmi di Scikit Learn e quindi non è stato necessario importare altre librerie; la seconda, *Shap*, è un metodo più elaborato basato sulla teoria dei valori di *Shapley*, che a sua volta deriva dalla teoria dei giochi. Poiché questa tecnica non era incorporata negli algoritmi utilizzati, è stato necessario importare la libreria *Shap*.

Per entrambe le tecniche ci si è basati sull'algoritmo *Gradient Boosting*, ovvero l'algoritmo migliore precedentemente individuato. Per la tecnica *feature_importance*, l'obiettivo è individuare quanto ciascuna variabile contribuisce alla qualità del modello, ovvero alla capacità di generare previsioni accurate. Il *Gradient Boosting* si basa su alberi di decisioni che correggono gli errori degli alberi precedenti e ogni albero cerca di ridurre l'errore complessivo. Per trovare le variabili più importanti, la tecnica si basa su due caratteristiche: guadagno e frequenza. Il guadagno rappresenta quanto ogni caratteristica contribuisce alla riduzione dell'errore in ogni nodo dell'albero (se una variabile viene frequentemente utilizzata nella divisione degli alberi e nella riduzione dell'errore, essa avrà un guadagno elevato e sarà quindi considerata importante). L'importanza basata sulla frequenza, invece, si concentra sul numero di volte in cui una variabile è stata utilizzata per dividere i nodi, indipendentemente dal contributo alla riduzione dell'errore. Se una variabile è frequentemente utilizzata, verrà considerata importante anche se non riduce significativamente l'errore.

Le variabili analizzate con questa tecnica avranno un valore che varia da 0 a 1 e la somma di tutte le variabili sarà uguale a 1. Quindi, quanto più una caratteristica si avvicina al valore massimo, tanto maggiore sarà la sua importanza. Come si può vedere dal grafico sottostante (Figura. 123), le feature sono ordinate in modo decrescente, dalle più importanti alle meno importanti. Si possono notare

39 *feature_importances_*, *GradientBoostingClassifier*. sklearn.ensemble Scikit Learn. <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.GradientBoostingClassifier>

40 SHAP (SHapley Additive exPlanations). <https://shap.readthedocs.io/en/latest/>

variabili come il numero di viaggi lunghi più di 200 miglia e VMT, che contribuiscono molto al modello, mentre variabili come il possesso di una casa di proprietà o il veicolo precedentemente posseduto a metano influenzano poco le predizioni finali. Per trovare le variabili ottimali da inserire nel nuovo modello, sono state prese in considerazione le variabili dalla più importante alla meno importante, la cui somma arriva a 0.9. Ovvero, sono state considerate le variabili in base al loro valore di importanza cumulativo, e sono state inserite le prime k variabili che coprono il 90% dell'importanza totale.

Le feature con importanza maggiore che portano a un'importanza cumulativa del 90% sono:

1. N. viaggi lunghi: 0.1808.
2. VMT: 0.1783.
3. Reddito: 0.1179.
4. Viaggio più lungo: 0.1095.
5. Distanza Casa-Lav.: 0.0858.
6. Sensibilità Ambiente: 0.0796.
7. BEV precedente: 0.0668.
8. N. auto in fam.: 0.0455.
9. Classe Età: 0.0343.




Figura 123. Confronto dell'importanza delle variabili con `feature_importance`

In questo caso, la somma di queste caratteristiche porta a un valore di 0.8984, circa il 90%. Inoltre, analizzando le feature considerate non importanti, si può vedere che un'altra soglia di selezione delle variabili è il 3%. Vengono considerate importanti tutte le variabili che hanno un valore di importanza maggiore del 3%.

Uno dei limiti di questa tecnica è che non offre una visione globale di tutte le caratteristiche, ovvero non tiene conto delle interazioni tra le varie caratteristiche e può risultare meno accurata nel determinare come ogni singola caratteristica influenza la previsione. Per ovviare a questi limiti, è stata utilizzata la tecnica *Shap*, che calcola il contributo marginale di ogni singola caratteristica per ogni previsione, basandosi sul concetto di valore di *Shapley*, e non solo su una media globale.

Per l'analisi delle caratteristiche più rilevanti con *Shap*, è possibile usare diverse tipologie di explainer, come *TreeExplainer* per modelli Decision Tree, *Random Forest*, *Gradient Boosting*; *KernelExplainer* per qualsiasi modello; *DeepExplainer* per modelli basati su reti neurali; *LinearExplainer* per modelli lineari⁴¹. In questa analisi è stato usato *TreeExplainer*, in quanto il modello utilizzato è *Gradient Boosting*. Come si può vedere dalla Figura 124, l'importanza delle varie caratteristiche è ordinata in ordine decrescente. Le prime tre caratteristiche sono le stesse di quelle trovate con la tecnica precedente, ma il peso della loro importanza varia. Anche in questo caso, sono state considerate le caratteristiche dalle più importanti alle meno importanti, contribuendo a raggiungere una soglia del 90% dell'importanza totale. Tuttavia, la somma non è uguale a 1 come nella tecnica precedente, ma può variare. In questo caso, la somma di tutte le caratteristiche porta a un valore di 2.0476, mentre per le sole caratteristiche che arrivano a spiegare il 90% dell'importanza hanno una somma di circa 1.8428.




Figura 124. Confronto dell'importanza delle variabili con Shap

Feature con importanza maggiore che portano a un'importanza cumulativa del 90% sono:

1. N. viaggi lunghi: 0.4180.
2. VMT: 0.2840.
3. Reddito: 0.2187.
4. BEV precedente: 0.1744.
5. Sensibilità Ambiente: 0.1433.
6. Classe Età: 0.1396.
7. Viaggio più lungo: 0.1189.
8. Distanza Casa-Lav.: 0.0764.
9. N. auto in fam.: 0.0753.
10. Genere: 0.0743.
11. ICE precedente: 0.0723.
12. HEV precedente: 0.0712.

Le tecniche presentano delle somiglianze, in quanto le prime tre caratteristiche più importanti per entrambe sono: il numero dei viaggi lunghi compiuti nell'ultimo anno, VMT e la classe di reddito, anche se hanno un diverso grado di importanza. Una differenza tra queste due tecniche è che, per raggiungere il 90% di importanza totale, la tecnica *Shap* richiede più variabili rispetto a *feature_importance*; queste nuove tre variabili corrispondono a genere, vettura precedente posseduta (ICE) e vettura precedentemente posseduta (HEV). Un'altra differenza è l'importanza delle caratteristiche successive alla terza; per esempio, nella tecnica *Shap*, la quarta caratteristica più importante è aver posseduto in passato una vettura elettrica, mentre nella tecnica *feature_importance*, la quarta caratteristica più importante è la distanza casa-lavoro.

Tramite il grafico *beeswarm* (Figura. 125) ottenuto con la tecnica *Shap*, è possibile analizzare l'importanza delle variabili basata sui valori di *Shap*. Questi valori indicano quanto ciascun punto contribuisce alla predizione. Sull'asse orizzontale sono rappresentati i valori di *Shap* di ogni variabile, indicando quanto quella determinata caratteristica influenza il risultato della predizione. Sull'asse verticale, le variabili sono ordinate in maniera decrescente secondo la loro importanza. Sul grafico, i punti rappresentano i valori di *Shap* di ogni predizione individuale, cioè per ogni caso presente nel modello. I punti sono distribuiti lungo l'asse orizzontale in base al loro valore di *Shap*. Il grafico prende il nome dalla disposizione di questi punti, a sciame (in inglese *beeswarm*), creando distribuzioni di punti che non si sovrappongono. Quando ci sono molti punti, significa che la variabile ha avuto una variazione significativa. Se i punti sono concentrati su un lato dell'asse orizzontale, significa che la variabile ha un forte effetto sul risultato del modello in una delle due direzioni; se i punti fossero distribuiti uniformemente, la variabile potrebbe avere un impatto meno definito sul risultato.

Un'ultima caratteristica di questo grafico è il colore dei punti, che varia in base al valore della variabile stessa. Se il valore della variabile è basso, i punti saranno rappresentati con un colore tendente al blu; se




Figura 125. Grafico Beeswarm di SHAP

il valore è alto, saranno rappresentati con colori tendenti al rosso.

Per esempio, la seconda variabile più importante nel modello, VMT, che misura quante miglia vengono percorse in un anno, mostra che a bassi livelli della variabile (bassi valori di VMT), i valori di *Shap* aumentano, aumentando la probabilità di possedere un veicolo elettrico. Al contrario, a livelli alti della variabile, i valori di *Shap* diminuiscono, riducendo la probabilità. Per la variabile che misura il numero di viaggi lunghi più di 200 miglia, c'è una concentrazione di punti a valori bassi della variabile (pochi o nessun viaggio lungo) verso valori positivi di *Shap*, indicando un forte impatto sul risultato del modello, soprattutto a livelli bassi.

Infine, si nota che a redditi più bassi la probabilità diminuisce, così come il fatto di non avere posseduto un veicolo in precedenza riduce la probabilità. Avere un'attitudine positiva verso la sostenibilità ambientale aumenta la probabilità di possedere un veicolo elettrico. Per quanto riguarda l'età, a classi di età più basse, la probabilità di possedere un veicolo elettrico aumenta, indicando che una persona più giovane ha maggiori probabilità di acquistare un veicolo elettrico. Un caso particolare riguarda i veicoli posseduti in precedenza di tipologia ICE e HEV: chi ha posseduto un veicolo a combustione interna avrà più probabilità di acquistare un veicolo elettrico rispetto a chi ha posseduto un veicolo ibrido, che avrà meno probabilità di acquistare un veicolo elettrico.

In conclusione, la tecnica *Shap* non ha stravolto le caratteristiche individuate con la tecnica *feature_importance*, ma ha distribuito i pesi in termini di importanza e aggiunto tre nuove caratteristiche. Questo può essere dovuto al fatto che *Shap* è più sensibile alla variabilità dei dati e può rilevare comportamenti non lineari tra le variabili, cosa che non è possibile con la tecnica *feature_importance*. Verranno quindi prese in considerazione le variabili trovate con la tecnica *Shap*.

7.3.3 IL MIGLIORE MODELLO CON LE MIGLIORI FEATURE

Una volta individuato il migliore modello e le migliori variabili, si è voluto testare il modello utilizzando soltanto le variabili più importanti, per verificare se ci fosse un miglioramento o un peggioramento in termini di accuratezza. Le variabili testate sono: la classe d'età, il genere, la classe di reddito familiare, l'importanza di ridurre le emissioni di gas serra, la tipologia di auto precedente (ICE), la tipologia di auto precedente (BEV), la tipologia di auto precedente (HEV), il numero di auto presenti in famiglia, il numero dei viaggi superiori a 200 miglia compiuti nell'ultimo anno, il viaggio più lungo effettuato nell'ultimo anno, la distanza casa-lavoro e, infine, la variabile VMT. Queste variabili, prima di essere analizzate con il modello *Gradient Boosting Classifier*, sono state standardizzate.

Come per i modelli precedenti, è stata condotta la tecnica della *Grid Search CV* con gli stessi parametri analizzati precedentemente.




Figura 126. Curve di apprendimento del modello *Gradient Boosting* con le variabili ridotte

Una volta trovato il modello con i migliori parametri, è stata condotta una *K-Fold Cross Validation* di 15 fold. Questo processo ha portato a un'accuratezza finale sul set di *test* di 0.6740, con un leggero aumento rispetto al modello con tutte le variabili, pari a circa un punto e mezzo percentuale. Per validare il modello è stata utilizzata anche la libreria *Learning Curves*⁴² di Scikit Learn per analizzare la performance del modello, calcolando la curva di apprendimento per vedere come varia l'accuratezza sui set di train e test. Dalla Figura 126 è possibile osservare le curve di apprendimento; per generare queste curve sono stati calcolati 25 valori di accuratezza sia sul train che sul *test set*. Come si può vedere, è presente un leggero *overfitting*, in quanto la performance ottenuta durante la fase di training è più alta rispetto a quella ottenuta durante il test. Il valore massimo dell'accuratezza sul *test* è di circa 0.674. La differenza non è comunque eccessiva, con una differenza tra *train* e *test accuracy* di circa 0.03, ovvero un 3%, e il modello mostra una buona capacità di generalizzazione, senza un *overfitting* significativo.

Le ulteriori metriche mostrano un *F1 Score* complessivo di 0.7184, una *Recall* di 0.7730 e una *Precision* di 0.6709. L'area sotto la curva *ROC* è di 0.7384. Come si può notare dalla confusion matrix (Figura 119), il modello ha una buona capacità nel rilevare i valori positivi, con una *Recall* del 77.3%, ma presenta una precisione del 67%, indicando che il modello identifica correttamente i casi positivi, ma tende anche a generare un numero relativamente elevato di falsi positivi. Per quanto riguarda la classe 0, il modello ha un valore di *Recall* molto basso, del 55.9%, indicando che sono stati identificati correttamente solo il 56% dei valori appartenenti a questa classe, mentre il restante 44% è stato classificato come classe 1. La precisione per la classe 0 è del 68%, ovvero, di tutti i valori predetti appartenenti alla classe 0, il 68% appartiene veramente a tale classe.




Figura 127. Modello Gradient Boosting ridotto. Istogramma dei punteggi predetti

42 [Learning Curve, sklearn.model_selection. Scikit Learn. https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.learning_curve](https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.learning_curve)




Figure 128-130. Modello Gradient Boosting ridotto. TPR e FPR per ogni threshold, ROC Curve, PR Curve

In conclusione, il numero ridotto delle variabili non ha portato a un aumento significativo dell'efficienza del modello. Le performance complessive rimangono non ottimali, con percentuali non elevate e difficoltà nell'individuare i valori appartenenti alla classe 0. Queste difficoltà possono essere attribuite soprattutto alla struttura dei dati, che non permettono una facile comprensione da parte del modello per effettuare previsioni corrette. Poiché le classi sono abbastanza bilanciate, il problema potrebbe risiedere nella qualità dei dati, con possibile rumore e caratteristiche irrilevanti o poco informative per il problema di classificazione, che non permettono una corretta rappresentazione del problema.

Nel Paragrafo seguente verrà affrontato il tema delle reti neurali artificiali, per vedere se un modello basato su tale struttura sia in grado di comprendere meglio i dati e restituire performance migliori, o se soffra degli stessi problemi.




Figura 131. Confronto delle Confusion Matrix dei tre modelli Gradient Boosting ridotto: Base, con Grid Search e in fine con Cross-Validation

Modello: *Gradient Boosting ridotto*

Classe	Precision	Recall	F1-Score	Support
0.0	0.68	0.56	0.61	996
1.0	0.67	0.77	0.72	1142
Accuracy			0.67	2138
Macro Avg	0.67	0.67	0.67	2138
Weighted Avg	0.67	0.67	0.67	2138

Tabella 33: Report di classificazione: Modello Gradient Boosting ridotto

7.4 DEEP LEARNING: ANALISI DEL MODELLO DI RETE NEURALE ARTIFICIALE (ANN)

7.4.1 INTRODUZIONE ALLE RETI NURALI ARTIFICIALI

Introducendo il *Deep Learning* come una branca avanzata dell'apprendimento automatico all'inizio del Capitolo, in questo Paragrafo si concentrerà sulla costruzione del modello neurale, e la sua analisi. Va notato che, nel contesto di dati tabulari con una quantità limitata di informazioni, le reti neurali profonde potrebbero non garantire prestazioni superiori rispetto agli algoritmi tradizionali di *Machine Learning*. Verrà analizzato un modello specifico di rete neurale, l'*Artificial Neural Network (ANN)* creato con le librerie TensorFlow⁴³ e Keras⁴⁴. Questo modello, pur appartenendo alla famiglia del *Deep Learning*, offre un approccio più semplice e facilmente interpretabile. Verrà esaminato il comportamento dell'*ANN* con dati tabulari, confrontando la sua efficacia con le tecniche classiche di *Machine Learning* e valutando la sua capacità di apprendimento e generalizzazione.

Come anticipato precedentemente, i modelli neurali sono caratterizzati da un livello di *input*, la cui dimensione dipende dal numero di feature presente nei dati, da uno o più livelli nascosti, i quali sono connessi fra di loro attraverso i neuroni, e un livello finale di *output* che restituisce una predizione. Ogni neurone della rete neurale riceve degli *input* (x_i), ciascuno associato a un peso (w_i), per determinarne l'importanza. Gli *input* vengono moltiplicati per i rispettivi pesi e sommati insieme a un bias (b) per spostare la funzione di attivazione. La somma totale passa attraverso una funzione di attivazione $f()$, che

43 Libreria Tensorflow: <https://www.tensorflow.org/>

44 Libreria Keras: <https://keras.io>

decide la rilevanza delle informazioni per il neurone. Se l'informazione non è rilevante, il neurone non si attiva e l'informazione si arresta.

$$y = f \left(\sum_{i=1}^n x_i w_i + b \right)$$

Dove:

- x_i sono gli *input*,
- w_i sono i pesi associati a ciascun *input*,
- b è il bias, che consente di adattarsi meglio ai dati,
- $f()$ è la funzione di attivazione, che introduce non linearità e determina se il neurone deve “attivarsi” (ossia, produrre un *output* rilevante).

La funzione di attivazione svolge un ruolo cruciale nelle reti neurali, poiché introduce non linearità nel modello, permettendo alla rete di apprendere rappresentazioni più complesse dei dati. Senza questa non linearità, la rete sarebbe limitata a una combinazione lineare dei suoi *input*, che non sarebbe sufficiente per risolvere compiti complessi. Tra le funzioni di attivazione più comuni troviamo la *ReLU* (Rectified Linear Unit), che trasforma tutti i valori negativi in zero mentre mantiene invariati i valori positivi. La *ReLU* è molto popolare perché riduce il problema del vanishing gradient e accelera l'addestramento, ma tuttavia, può incorrere nel fenomeno del *dying ReLU*, in cui alcuni neuroni smettono di attivarsi. Per ovviare a questo problema esistono varianti come:

- *Leaky ReLU*: la applica una leggera pendenza ai valori negativi invece di essere bloccati a 0, quindi permette ai neuroni che ricevono in *input* negativi di apprendere comunque.
- *Parametric ReLU (PReLU)*: è una variante della *Leaky ReLU*, che è in grado di apprendere durante addestramento l'pendenza priva valori negativi.
- *Exponential Linear Unit (ELU)*: questa variante applica ai valori negativi una funzione esponenziale.

Altre funzioni di attivazione includono la sigmoide, che mappa i valori nell'intervallo $[0, 1]$ e viene comunemente utilizzata per la classificazione binaria, e la tangente iperbolica (*Tanh*), che mappa i valori nell'intervallo $[-1, +1]$. Entrambe soffrono del problema del vanishing gradient, ma la *Tanh* è utile per catturare informazioni sia positive che negative.

Durante il processo di addestramento, la rete neurale cerca di ottimizzare i pesi e il bias in modo da ridurre l'errore tra il risultato previsto e quello atteso, usando il processo di retropropagazione, chiamata anche backpropagation. Questo processo aggiusta i pesi in base all'errore calcolato, migliorando gradualmente la precisione del modello. Si verifica alla fine della *Forward propagation*, ovvero è il

processo che consiste nel calcolare la funzione di attivazione e capire se un determinato neurone è utile o è utile, il cui segnale viene propagato in avanti, attraverso la rete passando da ogni livello dall'*input* fino all'*output* per ottenere una previsione, senza mai tornare indietro. Una volta che si è raggiunta la previsione, è possibile calcolare l'errore della rete confrontando l'*output* previsto con l'*output* ottenuto e per ottimizzare e ridurre questo errore entra in gioco il processo della *Backpropagation*, che cerca di minimizzare l'errore, calcolandolo per ogni neurone, e infine aggiustando i pesi.

7.4.2 ANALISI DEI MODELLI ANN: MODELLO BASE

In questa fase sono stati creati tre modelli per confrontarne le performance. I modelli creati sono di tipo sequential, ovvero la rete neurale è organizzata in modo lineare, con l'*output* di ogni livello che diventa l'*input* per il livello successivo. Sono state considerate tutte le 18 feature presenti nel dataset, determinando così la dimensione del livello di *input*: 18 *input* per ogni esempio di addestramento. Successivamente, il modello prevede quattro livelli nascosti (*hidden layers*) di tipo denso, dove ogni neurone è collegato a tutti i neuroni del livello precedente. Per ciascun livello nascosto, è stata utilizzata la funzione di attivazione *ReLU* (*Rectified Linear Unit*), che trasforma i valori negativi in zero, assumendo che non contribuiscano all'apprendimento. Inoltre, la funzione è non lineare ma comporta una crescita lineare per i valori positivi, accelerando l'addestramento e risolvendo il problema del vanishing gradient, che impedisce a una rete neurale di apprendere in modo efficiente.

Nel caso specifico di questo modello, la funzione di attivazione *ReLU* è stata utilizzata per i quattro livelli nascosti, mentre l'ultimo livello (*output*) prevede un singolo neurone, dato che il modello affronta un problema di classificazione binaria. Per questo livello finale, è stata utilizzata la funzione di attivazione sigmoide, che restituisce un valore compreso tra 0 e 1, utile per interpretare la previsione come una probabilità di appartenenza alla classe positiva.

La struttura degli hidden layer è composta da quattro livelli: il primo con 16 neuroni, il secondo con 64, il terzo con 128 e il quarto con 64 neuroni. A ogni livello è associato un Dropout con un valore di 0.2, ossia il 20% dei neuroni viene "spento" in modo casuale durante l'addestramento per prevenire l'*overfitting*. Il modello è stato compilato con l'ottimizzatore *Adam*, uno degli ottimizzatori più popolari e una variante avanzata del gradient descent. *Adam* è stato scelto per la sua efficienza nell'aggiornamento dei pesi, ma esistono anche altri ottimizzatori, come lo *Stochastic Gradient Descent* (*SGD*), che aggiorna i pesi dopo ogni campione di dati, il *Momentum*, che riduce il rumore nel processo di aggiornamento e accelera la convergenza, e *RMSprop*, che adatta il tasso di apprendimento per ogni parametro usando una media mobile esponenziale del quadrato dei gradienti.

Il modello creato a 18,033 parametri, ovvero neuroni, i quali sono stati utilizzati nell'apprendimento del modello. La fase di apprendimento è avvenuta con 300 epoche, ovvero il modello è stato colato e ripensato per 300 volte, con una batch size di 64. La batch size è la dimensione del numero di esempi che

vengono utilizzati simultaneamente per calcolare il gradiente aggiornare i pesi, ovvero ad ogni iterazione dell'addestramento il modello esaminerà 64 campioni di dati, calcolando il gradiente e aggiornando i pesi. Essendo che i casi presenti nel dataset sono 10688 e la batch size di 64, vorrà dire che serviranno 167 batch ($10,688/64$), o passaggi, per completare un'epoca.

Avere delle batch size piccole rende l'apprendimento più dinamico, ma l'aggiornamento più frequente dei pesi può portare sia ad avere più rumore ma anche un apprendimento più lento. Mentre *batch size* più grandi che portano più esempi ad ogni interazione rendono l'aggiornamento dei pesi meno rumorosi e più stabile, oltre che più veloce, ma potrebbero perdere la capacità di esplorare dei dettagli che si sarebbero potute cogliere soltanto con batch size più piccole.

Infine, sono stati predisposti dei dati per il set di validazione, i quali corrispondono a un 20% del *train set*.



Figure 132 e 133. Andamento della Loss e Accuracy

Il modello ha prodotto un'accuratezza di 0.6268 e una *loss* di 0.6696, una accuratezza inferiore rispetto ai modelli di *Machine Learning*. Come mostrano i grafici, Figure 132 e 133, l'accuratezza non migliora dopo le prime epoche, e inoltre la accuratezza sul *test* e quella sul *validation* rimangono stabili ed equidistanti, così come la *loss*. Essendo che dopo diverse epoche la performance della rete non migliora è stato introdotto un *Early Stopping* per prevenire l'*overfitting*, interrompendo l'addestramento quando le prestazioni sui dati di validazione non migliorano più. Questo parametro monitora la *loss* sul *validation set*, e quando non c'è un miglioramento di 0.00001 dopo 10 volte il modello si arresta. Con l'*Early*

Stopping, l'accuratezza è migliorata a 0.6324 e la *loss* è scesa a 0.6627. Sebbene non abbia raggiunto le prestazioni degli algoritmi di *Gradient Boosting*, per aumentare l'efficienza si è cercato creare modelli più complessi.

7.4.3 ANALISI DEI MODELLI ANN: MODELLI AVANZATI

Per realizzare dei modelli più complessi del precedente è stata applicata una trasformazione polinomiale di secondo grado dopo aver standardizzato tutte le feature, una tecnica facente parte delle tecniche feature engineering, per cercare di catturare relazioni non lineari. Questa tecnica fa parte del feature engineering ed è stata utilizzata per catturare potenziali relazioni non lineari tra le variabili. Ad esempio, nel caso di due caratteristiche X_1 e X_2 , la trasformazione polinomiale di grado 2 genera tre nuove variabili: X_1^2 , X_2^2 e X_1X_2 , oltre alle caratteristiche originali X_1 e X_2 . Per implementare questa trasformazione, è stata utilizzata la funzione *PolynomialFeatures*⁴⁵ della libreria scikit learn. In questo caso, considerando che il dataset conteneva 18 caratteristiche, la trasformazione ha prodotto 171 nuove *feature*, portando il totale a 189 variabili disponibili per i nuovi modelli ANN più complessi.

Entrambi i modelli successivi sono caratterizzati da una regolarizzazione *ElasticNet*, che combina i metodi *Lasso (L1)* e *Ridge (L2)*. La regolarizzazione *ElasticNet* è utile per prevenire il rischio di *overfitting*, ossia l'adattamento eccessivo del modello ai dati di addestramento. Inoltre, è stata modificata la funzione di attivazione negli strati nascosti, passando da *ReLU* a *LeakyReLU*, con un valore di *negative_slope* pari a 0.3, per mitigare il problema del *dying ReLU*. Per entrambi i modelli, sono state adottate tecniche per adattare dinamicamente il learning rate durante l'addestramento: per il primo modello, è stato inoltre cambiato l'ottimizzatore da *Adam* a *AdamW*, in quanto quest'ultimo incorpora la regolarizzazione L2 in modo più efficace. Entrambi gli ottimizzatori sono stati configurati con un learning rate iniziale di 0.001, parametro che determina la velocità con cui il modello aggiorna i pesi durante l'addestramento. Un valore di learning rate elevato può accelerare la convergenza, ma rischia di causare oscillazioni o sovrallungazioni nella soluzione ottimale. Al contrario, un valore basso rallenta la convergenza, rischiando di far rimanere il modello bloccato in soluzioni non ottimali.

Infine, per entrambi i modelli è stato aggiunto un ulteriore strato nascosto nella rete rispetto al modello trattato nel Paragrafo precedente, modificando di conseguenza la sua struttura interna. La rete risultante è composta da 5 strati densi: il primo con 64 unità, il secondo con 128, il terzo con 256, il quarto con 128 e l'ultimo con 64 unità. Prima dello strato di *output*, è stata applicata la tecnica di *BatchNormalization* per ridurre il *covariate shift* interno, normalizzando gli *input* di ciascun strato su ogni batch di dati. Inoltre, è stato utilizzato il dropout al 30% in ogni strato per prevenire l'*overfitting*. Entrambi i modelli presentano un totale di 94.977 parametri, di cui 94.849 sono neuroni addestrabili, mentre 128 parametri sono non addestrabili.

⁴⁵ *PolynomialFeatures*, sklearn.preprocessing. Sklearn. <https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.PolynomialFeatures>

Modello con riduzione del Learning Rate

Il primo modello “avanzato” è stato addestrato per 400 epoche, con l’ausilio di due *callback*. La prima riguarda l’early stopping, che interrompe l’addestramento quando il miglioramento sulla *loss* del *validation set* è inferiore a 0.00001 per 20 epoche consecutive (*patience* = 20). Quando non si osservano miglioramenti, la *callback* ripristina i pesi del modello allo stato della miglior epoca. La seconda *callback* riguarda la tecnica *ReduceLROnPlateau*⁴⁶, che riduce il learning rate del 50% ogni volta che la *loss* del *validation set* non migliora per 5 epoche consecutive (*patience* = 5, *Factor* = 0.5). Queste due tecniche hanno scopi differenti: la prima interrompe l’addestramento in caso di mancanza di miglioramenti, mentre la seconda riduce il tasso di apprendimento quando non si registrano progressi. Definite le *callback* il modello, quindi, è stato addestrato su 400 epoche, con una batch size più piccola, di 32. Essendo che la batch size è più piccola serviranno più passaggi per completare un’epoca rispetto al modello precedentemente, per l’esattezza verranno compiuti 334 passaggi per ogni epoca. L’addestramento si è fermato alla 90^a epoca, poiché a partire dalla 70^a epoca non si sono più registrati miglioramenti, e i pesi sono stati ripristinati alla 70^a epoca. Durante l’addestramento, sono avvenute 8 riduzioni successive del learning rate, la prima alla 29^a epoca e l’ultima alla 90^a (per la precisione alle epoche: 29, 51, 66, 75, 80, 85 e 90).

Per il calcolo delle metriche, sono stati considerati *accuracy*, *loss*, *AUC*, *Precision* e *Recall*, con i seguenti risultati:

- *Accuracy*: 0.6534,
- *Loss*: 0.6559,
- *AUC*: 0.7023,
- *Precision*: 0.6589,
- *Recall*: 0.7374.

L’analisi dei grafici, Figure 134 e 135, mostra che la *loss* (sia quella di addestramento che di validazione) diminuisce rapidamente nelle prime epoche, stabilizzandosi successivamente. La *loss* scende da valori elevati, di 6.42, fino a valori più bassi di circa 0.65, come la *Val_Loss* che segue un andamento simile, scendendo da 4.91 a circa 0.66. L’*accuracy* mostra un incremento più lento all’inizio, salendo da circa 0.54 a 0.66, per poi raggiungere un massimo di 0.67. Al contrario, la *Val_Accuracy* presenta fluttuazioni più marcate: dopo aver toccato il suo valore massimo di circa 0.66, scende nuovamente in alcune epoche, indicando possibili oscillazioni durante il processo di validazione. Nelle fasi finali dell’addestramento, la *Val_Accuracy* mostra una leggera diminuzione, passando dal picco di 0.66 al valore finale di 0.64. Se nell’early stopping fosse stata utilizzata come metrica di riferimento la *Val_Accuracy*, l’addestramento si sarebbe probabilmente interrotto prima. In generale, il modello sembra soffrire di un lieve *overfitting*, in cui la performance sui dati di addestramento migliora leggermente, mentre

quella sui dati di validazione non mostra un miglioramento altrettanto evidente, con un peggioramento in alcuni casi, come suggerito dalla discrepanza tra *Accuracy* e *Val_Accuracy* nelle fasi finali.



Figure 134 e 135. Andamento della Loss e Accuracy del modello con riduzione del Learning Rate

Matrice di confusione: modello con riduzione del Learning Rate




Figura 136. Confusion Matrix del modello con riduzione del Learning Rate

La matrice di confusione mostra che il modello ha classificato correttamente 549 esempi come negativi (TN) e 848 come positivi (TP). Tuttavia, ha commesso 439 errori di tipo falso positivo (FP) e 302 errori di tipo falso negativo (FN). Da questi valori, è stato calcolato un *F1 Score* di circa 69.6%. La precisione del modello sui casi positivi è pari al 66%, mentre il richiamo è del 74%, suggerendo che il modello è più preciso nel classificare i positivi, ma meno accurato nei negativi.




Figura 137. ROC Curve del modello con riduzione del Learning Rate

Modello con Rescheduler del Learning Rate.

Nel secondo modello è stato impiegato l'ottimizzatore *AdamW*⁴⁷, come nel modello precedente, l'addestramento è stato effettuato su 400 epoche con una batch size di 32 e due *callback*. La prima *callback* è relativa all'early stopping, ma in questo caso l'addestramento viene interrotto se il miglioramento della *loss* sul *validation set* è inferiore a 0.0001 ($1e-4$) per cinque epoche consecutive (*patience* = 5). Un'altra differenza importante riguarda l'uso di un *LearningRateScheduler*⁴⁸, che, analogamente al modello precedente, regola dinamicamente il tasso di apprendimento durante l'addestramento. Tuttavia, a partire dalla decima epoca, il tasso di apprendimento viene ridotto moltiplicandolo per un fattore di $\exp(-0.1)$, circa 0.9048, diminuendo progressivamente con ogni epoca successiva. Di conseguenza, il tasso di apprendimento si abbassa continuamente fino a raggiungere il valore di $1e-5$ nell'ultima epoca. Il modello è stato interrotto alla 56^a epoca, grazie all'early stopping, poiché dalla 51^a epoca non si sono più osservati miglioramenti significativi, determinando il ripristino dei pesi del modello a tale epoca. Il secondo modello ha mostrato prestazioni leggermente inferiori rispetto al precedente, con un'accuratezza di 0.6511 (inferiore di circa 0.2 punti percentuali rispetto al primo modello).

Le altre metriche sono risultate simili, tranne la precisione, che è aumentata a 0.6608. I risultati sono i seguenti:

⁴⁷ AdamW, Optimizer API, Keras. <https://keras.io/api/optimizers/adamw/>

⁴⁸ LearningRateScheduler. Callbacks API, Keras. https://keras.io/api/callbacks/learning_rate_scheduler/

- *Accuracy*: 0.6511,
- *Loss*: 0.6594,
- *AUC*: 0.6952,
- *Precision*: 0.6608,
- *Recall*: 0.7217.




Figure 138 e 139. Andamento della Loss e Accuracy del modello con Rescheduler del Learning Rate

Analizzando le Figure 138 e 139 si può notare che, anche in questo caso, sia la *loss* che la *Val_loss* partono da un valore iniziale piuttosto alto, rispettivamente di 6.44 e 4.94, per poi diminuire con l'avanzamento delle epoche, indicando un miglioramento progressivo del modello durante l'allenamento, per poi stabilizzarsi. Per quanto riguarda l'accuratezza, anch'essa subisce un miglioramento graduale, passando da 53.04% a 66.02% verso la fine. Questo miglioramento si osserva anche nell'accuratezza dei dati di validazione, che passa da 54.58% a 65.58%, pur caratterizzandosi per alcuni piccoli aumenti e cali durante le epoche centrali, per poi stabilizzarsi verso le epoche finali. Questo modello sembra essere meno affetto dal problema dell'*overfitting* rispetto al modello precedente, dato che i due valori di accuratezza si discostano di circa mezzo punto percentuale. Analizzando questi dati, soprattutto quelli relativi alla *loss*, si potrebbe imporre un early stopping più marcato, con un *min_delta* più alto, per evitare che il modello continui ad allenarsi riducendo di pochissimo la perdita sulla validazione.

Confrontando questo grafico con quello del modello precedente, entrambi i modelli in termini di *loss* e accuratezza convergono abbastanza bene, ma il primo modello sembra performare leggermente meglio in termini di accuratezza, sebbene presenti una maggiore fluttuazione nelle epoche finali.

Matrice di confusione: modello con Rescheduler del Learning Rate




Figura 136. Confusion Matrix del modello con Rescheduler del Learning Rate

Analizzando la matrice di confusione di questo modello (Figura 136), si vede che il modello classifica correttamente come veri positivi 830 casi e 562 casi come veri negativi, mentre sbaglia la classificazione di 320 casi predetti come negativi ma che sono in realtà positivi, e 426 casi predetti come positivi ma che in realtà sono negativi. Rispetto al modello precedente, questo modello predice più casi nella classe negativa. Prima venivano predetti 851 casi come negativi, di cui 549 erano veri negativi (*precision class 0: 0.6451*), mentre in questo modello vengono predetti 882 casi come negativi, di cui 562 sono veri negativi (*precision class 0: 0.6372*).

ROC Curve: modello con Rescheduler del Learning Rate




Figura 137. ROC Curve del modello con Rescheduler del Learning Rate

Quindi, apparentemente il secondo modello predice più casi nella classe negativa, portando a un numero maggiore di veri negativi, ma con una precisione leggermente inferiore sulla classe zero. Per

quanto riguarda la classe positiva, il secondo modello, identificando più casi come negativi, predice un numero minore di casi positivi rispetto al modello precedente: 1256 contro i 1287 del modello precedente. Questo modello predice correttamente 830 casi appartenenti alla classe positiva rispetto ai 848 casi del modello precedente, ma con una precisione leggermente superiore (*precision class 1.model1*: 0.6589; *precision class 1.model2*: 0.6608). Quindi, il secondo modello è più preciso nell'identificare i valori positivi, anche se classifica più casi come negativi.

Per quanto riguarda la *Recall* per i casi positivi, ovvero la percentuale dei casi positivi correttamente identificati sul totale dei valori positivi, le prestazioni sono invertite rispetto alla precisione: per il primo modello, la precisione è 0.7374 (sul totale di 1150 casi, 848 sono stati identificati correttamente), mentre per il secondo modello, il valore della *Recall* è 0.7217 (su 1150 casi, 830 sono stati identificati correttamente). Per quanto riguarda la *Recall* sui valori negativi, le prestazioni si invertono: il primo modello ha un valore di 0.5557 contro un valore di 0.5688 del secondo modello (il primo modello identifica correttamente 549 valori veri negativi, mentre il secondo modello identifica correttamente 562 casi come veri negativi su un totale di 988). Combinando le metriche della *Recall* e della precisione, il F1-Score del secondo modello risulta più basso, con un valore del 69% rispetto al 69.6% del primo modello.

Infine, analizzando le metriche relative agli errori, ovvero i *False Positive Rate (FPR)* e *False Negative Rate (FNR)*, si nota che il primo modello commette più errori nell'identificazione dei positivi rispetto al secondo, mentre nell'identificazione dei negativi il primo modello sbaglia meno del secondo.

Primo modello:

- FPR: 0.444 (44.4%)
- FNR: 0.263(26.3%)

Secondo modello:

- FPR: 0.431(43.1%)
- FNR: 0.278(27.8%)

Nel complesso, pur con differenze minime nelle metriche, il secondo modello mostra una maggiore stabilità nell'identificare i positivi, ma è meno preciso nella classificazione dei negativi. Pertanto, se l'obiettivo è ridurre i falsi negativi, il primo modello potrebbe essere preferibile, mentre il secondo modello potrebbe essere più adatto per ridurre i falsi positivi, con un *F1 Score* complessivamente più bilanciato.

7.5 CONCLUSIONI SUI MODELLI DI APPRENDIMENTO

In conclusione, questo Capitolo si è focalizzato sull'individuazione del miglior modello di *Machine* o *Deep Learning* per predire se una persona possieda o meno un veicolo elettrico, con l'obiettivo di prevedere il futuro possesso in base alle caratteristiche del soggetto analizzato. Per determinare il miglior modello, è stato seguito un iter preciso per i modelli di machine learning: inizialmente è stato analizzato il modello base, poi è stata applicata la tecnica della *Grid Search CV* per ottimizzare i parametri, seguita da una *Cross Validation* con 15 *K-Fold* per ottenere un modello più robusto e meno suscettibile all'*overfitting*.

L'analisi dei vari modelli di *Machine* o *Deep Learning* ha evidenziato risultati non particolarmente efficienti, con una precisione che variava tra circa 0.65 e 0.66. Solo alcuni modelli, come la regressione logistica (0.62) e *SVC* (0.63), hanno mostrato performance inferiori. Tra gli algoritmi di *Machine Learning*, quelli basati su tecniche di *ensemble learning*, come il *Gradient Boosting* e il *Voting Classifier*, hanno offerto le migliori performance in termini di accuratezza e capacità predittiva.

L'accuratezza dei modelli di *Machine Learning* si aggira attorno al 65%. Tuttavia, si è osservato un leggero miglioramento, arrivando al 67% con il modello *Gradient Boosting* e al 66% con il modello basato su reti neurali, quando sono state selezionate solo le variabili che spiegano il 90% dell'importanza secondo l'analisi *Shap*. Nonostante ciò, l'accuratezza rimane relativamente bassa. In generale, tutti i modelli tendono a concentrarsi sull'identificazione dei valori positivi, risultando in una maggiore predizione della classe 1 rispetto alla classe 0, nonostante il dataset fosse bilanciato. In teoria, entrambe le classi dovrebbero avere lo stesso numero di predizioni, ma la *Recall* della classe 1 è tipicamente più alta di quella della classe 0, con differenze anche di 20 punti percentuali.

Ad esempio, il modello di *Gradient Boosting* tende a classificare un numero relativamente elevato di casi come appartenenti alla classe 1, ottenendo una *Recall* della classe 1 pari al 74.8%, mentre la *Recall* per la classe 0 è del 56%. Questo suggerisce che il modello è più efficace nell'identificare correttamente le istanze della classe 1, ma con un compromesso sulla precisione. Infatti, il punteggio di precisione per entrambe le classi è pari al 66%, indicando che circa il 34% delle previsioni di classe 1 e 0 sono errate (falsi positivi). In sostanza, il modello tende a prediligere la classe 1, classificando un numero maggiore di casi appartenenti a essa, ma senza un alto livello di accuratezza nelle previsioni.

Questo comportamento è comune a tutti i modelli di *Machine Learning*, ad eccezione del modello di regressione logistica, che bilancia meglio le predizioni tra le due classi. Infatti, come riportato nel Paragrafo 7.3, il modello logistico mostra valori identici di precisione e *Recall* per entrambe le classi, indicando una classificazione più equilibrata.

Inoltre, è stato analizzato un modello di rete neurale di base, il *Multi-Layer Perceptron (MLP)* di Sklearn, confrontandolo con modelli più complessi basati su *TensorFlow* e *Keras*, che utilizzano una struttura più articolata con più neuroni e livelli. Il modello *MLP* aveva solo un livello nascosto per un totale

di 620 neuroni, mentre il modello più complesso sviluppato con TensorFlow contava 94.849 neuroni trainabili distribuiti su più livelli nascosti. Tuttavia, l'aumento della complessità non ha portato a un miglioramento delle performance: l'accuratezza del modello *MLP* è stata di 0.651, mentre quella dei modelli più complessi oscillava tra 0.651 e 0.653, con prestazioni simili. I modelli complessi, rispetto al *MLP*, hanno mostrato precisioni leggermente superiori ma *Recall* leggermente inferiori.

In generale, i modelli di *Machine Learning* hanno performato meglio rispetto ai modelli basati su reti neurali artificiali. Il maggior costo computazionale associato ai modelli di *Deep Learning* non giustifica un miglioramento significativo delle performance, soprattutto considerando che alcuni algoritmi di *Machine Learning* hanno ottenuto risultati leggermente superiori. Questo può essere attribuito alla tipologia e alla quantità dei dati utilizzati: il dataset conta circa 10,000 esempi di tipo tabulare, mentre le tecniche di *Deep Learning* sono più adatte per l'elaborazione di dati complessi, come immagini, testi e audio, e per set di dati di dimensioni maggiori.

7.6 LIBRERIE PYTHON PER L'ANALISI PREDITTIVE DELL'APPRENDIMENTO AUTOMATICO

In questo Capitolo, oltre alle librerie fondamentali come pandas, numpy e plotly, già trattate nei capitoli precedenti, sono state impiegate altre librerie specializzate per l'elaborazione dei dati, la selezione delle caratteristiche, la costruzione dei modelli e la valutazione delle prestazioni.

Tra le librerie di scikit-learn (sklearn) usate:

- sklearn.preprocessing per la normalizzazione dei dati e la trasformazione delle caratteristiche tramite: StandardScaler, LabelEncoder e PolynomialFeatures.
- sklearn.feature_selection per selezionare le migliori caratteristiche tramite SelectKBest e il test `f_classif`.
- sklearn.model_selection per suddividere il dataset in set di addestramento e *test* con `train_test_split`, eseguire la ricerca ottimale dei parametri con *GridSearch CV*, validare i modelli con `cross_val_score` e `cross_val_predict`, e ottimizzare l'accuratezza del modello tramite tecniche di validazione incrociata come StratifiedKFold e KFold.
- sklearn.metrics per valutare la performance dei modelli tramite metriche come *accuracy_score*, *classification_report*, *confusion_matrix*, *roc_auc_score*, *roc_curve*, *f1_score*, *precision_score*, e *recall_score*.

Inoltre, sono state usate librerie avanzate come *Shap* per l'interpretabilità delle feature dei modelli, e tensorflow, un potente framework per il *Deep Learning*. Nello specifico, sono stati utilizzati i seguenti componenti di tensorflow:

- keras.models per costruire modelli sequenziali con Sequential e caricare modelli pre-addestrati tramite load_model.

- `keras.layers` per creare reti neurali avanzate con strati come Dense, Dropout, BatchNormalization, e funzioni di attivazione come LeakyReLU.
- `keras.utils` per visualizzare uno schema riassuntivo del modello con `plot_model`
- `keras.callbacks` per implementare meccanismi di early stopping, riduzione del learning rate e schedulazione del learning rate durante l'addestramento.
- `keras.optimizers` per ottimizzare i modelli usando algoritmi avanzati come Adam e AdamW.
- `keras.regularizers` per applicare la regolarizzazione `l1_l2`.
- `scikeras.wrappers` per combinare Keras e scikit-learn attraverso `KerasClassifier`, permettendo l'uso delle tecniche di validazione e ottimizzazione di scikit-learn sui modelli Keras.
- Infine, le metriche avanzate di `tensorflow.keras.metrics` come AUC, Precision, e Recall sono state impiegate per una valutazione approfondita dei modelli.

Il notebook Python completo, che descrive i passi pratici e le implementazioni dettagliate, è disponibile nella repository GitHub al seguente link:

[https://github.com/FedeGambe/Master_s_thesis_Data_science/blob/130fcd101bc663d0ee1730347088c6fb0b4db5d5/Apprendimento_Automatico_analisi_predittive/Apprendimento_Automatico\(ML_e_DL\).ipynb](https://github.com/FedeGambe/Master_s_thesis_Data_science/blob/130fcd101bc663d0ee1730347088c6fb0b4db5d5/Apprendimento_Automatico_analisi_predittive/Apprendimento_Automatico(ML_e_DL).ipynb)

I concetti trattati in questo capitolo si ricollegano a quelli esposti nei seguenti capitoli del notebook:

- Sottoparagrafo 7.2.1 - Preparazione (Cap. 1 del Notebook Analisi Predittive: Python. Preparazione).
- Sottoparagrafo 7.2.2 - Scelta dei modelli (Cap. 2 del Notebook Analisi Predittive: Python. Analisi Predittiva: ML).
- Sottoparagrafi 7.2.3 - Ensemble Learning, 7.2.4 - *Support Vector Machine*, 7.2.5 - Linear Model, 7.2.6 - Neural Network. (Cap. 3 del Notebook Analisi Predittive: Python. Analisi Modelli: ML).
- Paragrafo 7.3 - I migliori modelli e le migliori features negli algoritmi di ML (Cap. 4 del Notebook Analisi Predittive: Python. Migliore modello e migliori features: ML).
- Paragrafo 7.4 - Deep Learning: analisi del modello di rete neurale artificiale (ANN) (Cap. 5 del Notebook Analisi Predittive: Python. Reti Neurali: DL).

CAPITOLO 8

CONCLUSIONI FINALI

8.1 INTRODUZIONE ALLE CONCLUSIONI

La presente tesi nasce dall'interesse di indagare le caratteristiche che motivano l'acquisto di veicoli elettrici. Negli ultimi anni, infatti, stiamo assistendo a un cambiamento epocale nel settore della mobilità e delle industrie automotive, un cambiamento che rappresenta una vera e propria transizione di paradigma, simile a quelli che si sono verificati nel corso dei secoli. Il lavoro si è inizialmente concentrato sull'analisi del contesto attuale dei veicoli elettrici, passando poi a confrontare l'efficienza dei motori elettrici con quella dei tradizionali motori a combustione interna. Infine, è stato esaminato il motore a idrogeno, mettendone in luce i punti di forza e le problematiche, concludendo che, al livello attuale delle tecnologie disponibili, il veicolo elettrico risulta essere la soluzione più efficiente, in particolare in contesti urbani.

Una volta fornita una panoramica del contesto attuale, la ricerca si è concentrata sull'analisi dei dati. Le metodologie adottate sono state principalmente due: analisi statistiche e apprendimento automatico, usando modelli di machine learning e di deep learning. Per condurre queste analisi, è stato utilizzato un dataset proveniente dall'Università di California, Davis, basato su dati raccolti da un campione di rispondenti californiani. Questo rappresenta un primo limite della ricerca, in quanto i dati si riferiscono a un contesto socio-economico e culturale diverso da quello italiano. In particolare, il contesto californiano presenta, ad esempio, valori di reddito familiare significativamente più alti rispetto a quelli italiani, e una diversa configurazione abitativa, con una maggiore prevalenza di abitazioni indipendenti, tipiche delle aree suburbane, rispetto alle tipologie abitative presenti in Italia. Un'altra differenza rilevante risiede nell'uso delle automobili: negli Stati Uniti, e in particolare in California, la distanza percorsa in auto è generalmente maggiore rispetto ai paesi europei, come l'Italia, il che implica un maggiore utilizzo del veicolo. Inoltre, il territorio californiano è noto per essere un polo di innovazione, come dimostra la presenza della Silicon Valley, una delle aree più dinamiche e fertili al mondo per la nascita di start-up

tecnologiche. Un esempio significativo è rappresentato da Tesla, nel settore automobilistico. Questo ambiente potrebbe agevolare l'adozione di nuove tecnologie, come i veicoli elettrici.

8.2 CONCLUSIONI SULLE ANALISI STATISTICHE

Dopo aver descritto i primi limiti incontrati del dataset, ovvero, che potrebbe non essere completamente rappresentativo del contesto europeo e italiano, si è proceduto con le analisi statistiche. In primo luogo, sono state esaminate le distribuzioni di tutte le variabili presenti nel dataset, per poi concentrarsi sulla distribuzione rispetto alla variabile dipendente. Questa fase ha consentito la formulazione delle quattro ipotesi, enunciate all'inizio della tesi, che hanno orientato l'intera analisi. Successivamente, è stata condotta un'analisi VIF per verificare la presenza di multicollinearità tra le variabili, che ha costituito il primo passo verso l'applicazione del modello di regressione logistica, che rappresenta il fulcro di questa parte dell'analisi statistica. La regressione logistica ha permesso di verificare e validare le quattro ipotesi formulate, riguardanti i fattori che influenzano l'adozione dei veicoli elettrici a batteria (BEV).

1. La prima ipotesi riguardava l'influenza del reddito sull'acquisto di veicoli elettrici. I risultati dell'analisi confermano che il reddito è un fattore determinante per l'acquisto di un veicolo elettrico: le persone con redditi più elevati hanno una probabilità maggiore di possedere un veicolo BEV, probabilmente a causa dei costi superiori rispetto ai veicoli a combustione interna. È importante sottolineare, tuttavia, che il reddito non rappresenta l'unico fattore cruciale nell'acquisto di un veicolo elettrico, ma anche altri fattori, come gli incentivi governativi, potrebbero giocare un ruolo significativo.
2. La seconda ipotesi analizzava se la proprietà di un veicolo precedente fosse correlata con l'acquisto successivo di un veicolo elettrico. Questa ipotesi è stata suddivisa in tre sottopunti e, sebbene solo parzialmente confermata, ha rivelato alcuni risultati interessanti. I dati mostrano che chi ha posseduto in passato un veicolo ibrido ha una probabilità maggiore di acquistare un veicolo elettrico, suggerendo che la tecnologia ibrida possa rappresentare una fase di transizione verso l'elettrico. Tuttavia, l'effetto di questa relazione è stato meno marcato rispetto alle aspettative iniziali. Inoltre, la proprietà di un veicolo a combustione interna non sembra ridurre la propensione ad acquistare un veicolo elettrico. Infine, l'analisi ha evidenziato che chi ha già acquistato un veicolo elettrico tende a farlo nuovamente, indicando una forte fedeltà verso la tecnologia elettrica.
3. La terza ipotesi riguardava l'influenza delle lunghe distanze percorse sull'acquisto di un veicolo elettrico. Questa ipotesi non è stata confermata, poiché non è emersa una relazione significativa tra la percorrenza di lunghe distanze e la probabilità di acquistare un veicolo elettrico. Sebbene sia diffusa la percezione che i BEV siano meno adatti a viaggi lunghi a causa della limitata autonomia e delle infrastrutture di ricarica, i dati non supportano questa

ipotesi in modo significativo. Questo potrebbe essere spiegato dai progressi nelle tecnologie delle batterie e dalla crescente disponibilità di stazioni di ricarica, che contribuiscono a ridurre l'impatto della cosiddetta “*range anxiety*”⁴⁹.

4. L'ultima ipotesi analizzava l'influenza della sensibilità ambientale sulla scelta di un veicolo elettrico. I dati confermano che un maggior interesse verso le problematiche ambientali è associato a una probabilità più alta di acquistare un veicolo elettrico. Le persone che attribuiscono grande importanza alla riduzione delle emissioni di gas serra risultano significativamente più propense a scegliere un veicolo elettrico rispetto a coloro che prestano minore attenzione alle tematiche ambientali.

Infine, per quanto riguarda le analisi statistiche, sono state condotte analisi esplorative per comprendere le relazioni tra le variabili nel dataset e per verificare se fosse possibile ridurre il numero tramite tecniche di analisi fattoriale dei dati misti, analisi delle corrispondenze multiple e analisi delle componenti principali. Tuttavia, queste tecniche non hanno prodotto risultati soddisfacenti in termini di riduzione delle variabili a un numero più contenuto di caratteristiche esplicative della maggior parte della varianza. Sebbene non abbiano portato alla riduzione delle variabili, queste analisi hanno comunque offerto importanti spunti per comprendere meglio le relazioni tra le variabili stesse. Inoltre, è stata effettuata un'analisi di clustering, utilizzando diversi algoritmi, per identificare gruppi di consumatori e determinare possibili target di mercato. Da questa analisi sono emersi quattro gruppi distinti di utilizzatori di veicoli elettrici.

8.3 CONCLUSIONI SULL'APPRENDIMENTO AUTOMATICO

La terza e ultima parte della ricerca è stata dedicata all'analisi predittiva tramite l'applicazione di tecniche di apprendimento automatico, in cui sono stati testati diversi algoritmi di *machine learning*, nonché modelli basati su reti neurali. Inizialmente, sono stati provati 13 algoritmi, dei quali sette sono stati successivamente sottoposti a un'analisi più approfondita. Il processo seguito è stato il seguente: a partire dal modello base, sono stati ottimizzati i parametri per ciascun algoritmo con la tecnica *Grid Search CV*, dopodiché è stata confrontata l'accuratezza del modello base con quella del modello ottimizzato. Infine, è stata effettuata una valutazione incrociata con 15 fold del modello con i migliori parametri per ottenere una stima più robusta e affidabile. Per quanto riguarda i modelli a base di reti neurali, sono stati testati tre approcci, di cui due avanzati. Questi modelli hanno previsto un'ottimizzazione più approfondita dei parametri, con particolare attenzione al tasso di apprendimento, al fine di migliorare

⁴⁹ Range anxiety: la paura che un veicolo elettrico non abbia abbastanza carica della batteria per raggiungere la destinazione desiderata. Definizione di “range anxiety” tratta dal Cambridge Advanced Learner's Dictionary & Thesaurus © Cambridge University Press.

ulteriormente le performance predittive.

I codici utilizzati sia per l'apprendimento automatico che per le analisi statistiche, sviluppati in Python e R, sono disponibili open source. È possibile accedere alla repository su GitHub⁵⁰, i cui dettagli sono riportati a fine dei capitoli 4, 5, 6 e 7. Inoltre, i riferimenti alla repository sono inclusi anche nella bibliografia.

Dashboard di Predizione: modello GB

Genere
Maschio

Reddito familiare
<50,000

Numero di auto in famiglia
1

Casa di proprietà
No

Classe d'età
<25

Livello di istruzione
Licenza Media

Numero di persone in famiglia
1

Casa Indipendente
No

Importanza di ridurre le emissioni di gas serra
-3 -2 -1 0 1 2 3

Tipologia di auto precedente: ICE
No

Tipologia di auto precedente: PHEV
No

Numero di viaggi superiori a 200 miglia negli ultimi 12 mesi
0

Distanza casa-lavoro
0

Tipologia di auto precedente: BEV
No

Tipologia di auto precedente: GNC
No

Viaggio più lungo negli ultimi 12 mesi
0

VMT annuo
0

Tipologia di auto precedente: HEV
No

Genera Predizione

Inserisci i valori delle variabili e premi il pulsante per generare la predizione.

Figura 138. Dashboard predittiva iniziale con il modello di predizione Gradient Boosting Classifier Completo (con tutte le variabili)

Dashboard predittiva

L'analisi predittiva consente di effettuare previsioni sulla probabilità che un individuo scelga o meno un veicolo elettrico, sulla base delle caratteristiche presenti nel dataset. Per questo scopo, è stata sviluppata una dashboard interattiva⁵¹, nella quale è possibile inserire i valori relativi alle caratteristiche sociodemografiche di un potenziale acquirente per ottenere una stima della probabilità che il caso analizzato possieda un veicolo elettrico. Questo strumento può rivelarsi particolarmente utile per le aziende nel settore automobilistico, che potrebbero impiegarlo per elaborare strategie di marketing più mirate e

50 Link alla Repository di GitHub: https://github.com/FedeGambe/Master_s_thesis_Data_science

51 Dashboard Predittiva disponibile al link: <https://colab.research.google.com/drive/1o16naCS0C706khjFKP6L75mbwCVxMVrg?usp=sharing>. Codice presente su GitHub al link: https://github.com/FedeGambe/Master_s_thesis_Data_science/blob/130fcd101bc663d0ee1730347088c6fb0b4db5d5/Apprendimento_Automatico_analisi_predittive/Dashboard_di_Predizione.ipynb

dirette, consentendo di identificare rapidamente i potenziali acquirenti di veicoli elettrici.

Sono state sviluppate due tipologie di dashboard predittive: la prima si basa sul miglior algoritmo individuato in termini di efficienza, ovvero il modello di *Gradient Boosting*, il quale utilizza tutte le variabili presenti nel dataset. Per ottimizzare la sua capacità predittiva, è stata creata una funzione che, una volta inseriti i valori delle variabili, trasforma questi in una forma polinomiale di secondo grado, al fine di catturare meglio le relazioni non lineari tra le variabili. La seconda dashboard utilizza un modello ridotto basato su reti neurali, nel quale vengono selezionate solo le variabili che spiegano il 90% dell'importanza complessiva, identificate attraverso la tecnica *Shap*.

Ad esempio, utilizzando il modello di *Gradient Boosting* completo, è stato possibile predire la probabilità di possesso di un veicolo elettrico per un individuo di sesso maschile, di età compresa tra i 25 e i 34 anni, con un reddito familiare basso, un livello di istruzione pari alla licenza media, residente




Figura 139. Dashboard predittiva con i valori dell'esempio inseriti, con il modello di predizione *Gradient Boosting Classifier Completo* (con tutte le variabili)

in un appartamento in affitto con un'altra persona, e possessore di un'unica auto. Questo individuo ha una discreta sensibilità verso la sostenibilità e ha precedentemente posseduto un veicolo ibrido plug-in. Inoltre, compie circa quattro viaggi lunghi all'anno (intesi come andata semplice), con una distanza massima di 450 miglia per il viaggio più lungo, percorre 45 miglia giornaliere per il tragitto casa-lavoro, e compie annualmente 56,000 miglia. I valori inseriti non generano una previsione positiva riguardo alla possibilità di possedere un veicolo elettrico, poiché viene predetta la classe 0 (ovvero non BEV), sebbene la probabilità di appartenere a questa classe non sia schiacciante, indicando comunque un certo grado di incertezza (Figura 139). Va sottolineato che l'accuratezza di questa previsione è del 67%.

Inoltre, analizzando le previsioni relative alle modalità delle variabili che caratterizzano i quattro cluster identificati nel Capitolo 6, si osservano i seguenti risultati:

1. Primo cluster: Il soggetto esaminato è di sesso maschile, di età compresa tra i 45 e i 64 anni, con un reddito familiare molto alto, un livello di istruzione pari a laurea magistrale o dottorato, e vive con la sua famiglia in una casa indipendente di proprietà. La famiglia è composta da quattro persone e due auto, e il soggetto manifesta una forte sensibilità ambientale. Il veicolo attuale è a combustione interna, e il soggetto compie un solo viaggio lungo all'anno (di circa 350 miglia). La distanza percorsa giornalmente per il tragitto casa-lavoro è di 8 miglia, mentre annualmente percorre circa 5.000 miglia. Questo profilo ha una probabilità del 77% di acquistare un veicolo elettrico (classe 1).
2. Secondo cluster: Le caratteristiche del soggetto sono simili a quelle del primo cluster, con una probabilità del 77% di appartenere alla classe 1.
3. Terzo cluster: Il soggetto esaminato è di sesso maschile, di età superiore ai 65 anni, con un reddito familiare elevato e un livello di istruzione di laurea triennale. Il nucleo familiare è composta da una coppia con due auto, e vive in una casa di proprietà indipendente. Il soggetto manifesta un alto livello di sensibilità ambientale, ha posseduto in passato un veicolo ICE, e compie viaggi brevi, con un massimo di 200 miglia per il viaggio più lungo, e percorre una distanza giornaliera casa-lavoro di 12 miglia. Il mileage⁵² annuo è di circa 8.000 km (circa 5.000 miglia). Questo profilo ha una probabilità di appartenenza alla classe 1 pari all'85%.
4. Quarto cluster: Questo gruppo presenta una probabilità di appartenere alla classe 1 pari all'86% nel caso di sesso maschile, e dell'82% nel caso di sesso femminile. I soggetti di questo cluster sono di età compresa tra i 45 e i 64 anni, con un reddito familiare alto, una laurea magistrale o un dottorato, e una famiglia composta da quattro persone con due auto.

⁵² Mileage: il numero di miglia percorse da un veicolo dal momento in cui è stato immesso in circolazione. Definizione di "Mileage" tratta dal Cambridge Advanced Learner's Dictionary & Thesaurus © Cambridge University Press. In questo caso, si intende con "annual mileage" la distanza annuale percorsa, ovvero la quantità di miglia percorse da un veicolo in un anno.

Risiedono in una casa indipendente di proprietà e mostrano una forte sensibilità ambientale. In precedenza, hanno posseduto un veicolo a combustione interna e, generalmente, percorrono un solo viaggio lungo all'anno, di circa 400 miglia. La distanza casa-lavoro è di 25 miglia giornaliere, con un chilometraggio annuo di circa 15.000 miglia.

8.4 I LIMITI DELLA RICERCA

Oltre ai limiti inizialmente identificati nel contesto geografico del dataset, che potrebbe non essere del tutto rappresentativo per il contesto europeo e italiano, durante le fasi successive di analisi sono emersi ulteriori vincoli. Il primo di questi limiti è stato evidente sin dall'analisi della regressione logistica, in cui è stato riscontrato un valore molto basso del R^2 di McFadden, pari a 0,06. Ciò significa che il modello logistico, con le variabili indipendenti selezionate, spiega solo il 6% della variabilità della variabile dipendente, il che è estremamente basso. Questo indicatore suggerisce che il modello non sia adeguato per predire o spiegare adeguatamente la variabilità osservata nella variabile dipendente, limitando l'affidabilità delle previsioni.

Un altro limite significativo risiede nel fatto che le caratteristiche del dataset — cioè le variabili utilizzate — potrebbero non essere sufficientemente descrittive della variabile dipendente. Questo ha influenzato negativamente l'efficacia dei modelli basati sull'apprendimento automatico, i quali non sono riusciti a superare il 70% di accuratezza. Tale scarsa performance potrebbe essere dovuta al fatto che le variabili presenti nel dataset non sono in grado di discriminare adeguatamente tra coloro che possiedono o meno un veicolo elettrico. Di conseguenza, le dashboard predittive sviluppate con questi modelli risultano poco precise e, quindi, di limitato valore pratico. In aggiunta a questi limiti, è importante sottolineare la questione relativa al contesto geografico dei rispondenti, che potrebbe distorcere i risultati. Un ulteriore fattore limitante riguarda le variabili utilizzate nella raccolta dei dati. L'analisi si è principalmente concentrata su variabili sociodemografiche, senza considerare elementi psicologici o culturali che potrebbero giocare un ruolo cruciale nell'adozione di un veicolo elettrico. Fattori come le attitudini personali verso la sostenibilità o la predisposizione ad abbracciare nuove tecnologie potrebbero essere determinanti nella decisione di acquistare un veicolo elettrico, ma non sono stati adeguatamente esplorati.

Un altro aspetto rilevante riguarda la mancanza di dati relativi ai possessori di veicoli a combustione interna. Il dataset si è limitato a raccogliere informazioni esclusivamente su coloro che possiedono veicoli elettrici, escludendo veicoli a combustione interna, ibridi, ibridi plug-in e a idrogeno. Questa limitazione restringe il quadro delle preferenze degli acquirenti, poiché non consente di fare confronti tra utenti di veicoli elettrici e quelli di veicoli a combustione interna. Sebbene i veicoli a combustione interna siano destinati a diminuire notevolmente, i dati più recenti indicano che, tra gennaio e novembre 2024, il 46% dei nuovi veicoli immatricolati in Europa erano a combustione interna, a fronte di un 54%

nel 2022⁵³. Avere accesso anche a questi dati avrebbe permesso di esplorare maggiormente il problema.

Per superare queste limitazioni e per lavori futuri, sarebbe necessario costruire un dataset ad hoc, progettato in base alle specifiche esigenze della ricerca. Ciò, tuttavia, comporterebbe un notevole impegno di tempo e risorse. In particolare, per ottenere uno studio rappresentativo, sarebbe indispensabile raccogliere un campione a livello nazionale o regionale che garantisca una corretta rappresentazione del territorio e delle diverse caratteristiche socio-culturali, al fine di catturare tutte le sfumature del fenomeno legato all'adozione dei veicoli elettrici. La creazione di un dataset personalizzato richiederebbe l'accesso a dati ufficiali, come quelli utilizzati in altri studi simili, come ad esempio quello di Westin et al. (2021) in Svezia, dove i ricercatori hanno utilizzato registri geo-riferiti dei proprietari di veicoli. Analogamente, lo studio di Hardman (2020), relativo agli early adopters dei veicoli a celle a combustibile, ha basato la raccolta dei dati su partecipanti registrati al *California Clean Vehicle Rebate Project*, un programma che offre incentivi agli acquirenti di veicoli elettrici, ibridi *plug-in* e a idrogeno. La costruzione di un proprio dataset consentirebbe la selezione delle variabili più appropriate per il modello, rendendo così più precisa l'analisi e la previsione.

Ad esempio, potrebbe essere utile includere una variabile sull'indice di adozione tecnologica, che misuri la predisposizione di una persona ad abbracciare innovazioni tecnologiche. Inoltre, una variabile che misuri la disponibilità al cambiamento potrebbe rivelarsi utile, considerando che un veicolo elettrico è percepito non solo come un mezzo di trasporto, ma anche come una nuova tecnologia. Avrebbe inoltre valore includere una variabile che identifichi i motivi che spingono una persona ad acquistare un veicolo elettrico piuttosto che uno a combustione interna, come l'interesse per la sostenibilità ambientale, gli incentivi economici o i vantaggi in termini di risparmio. Infine, sarebbe interessante esplorare variabili aggiuntive relative all'abitazione, come la presenza di pannelli solari, accumulatori di energia nelle abitazioni o la sottoscrizione di pacchetti tariffari per la ricarica sia domestica che pubblica, pensati per chi possiede un'auto elettrica, poiché questi fattori potrebbero aumentare significativamente la propensione all'acquisto di un veicolo elettrico.

8.5 RELATED WORKS

L'articolo di Hardman (2020) si è concentrato su analisi statistiche, tra cui l'applicazione della regressione logistica, analisi simile a quella condotta in questo lavoro di tesi. I risultati ottenuti da entrambi gli studi sono comparabili, in quanto entrambi i modelli presentano valori di R^2 molto bassi. Come già menzionato, il R^2 del modello logistico di questo lavoro di tesi è pari a 0.06, mentre quello del modello di Hardman et al. è di 0.056. Questi valori simili indicano che le variabili inserite nel modello non riescono a spiegare adeguatamente la variabilità della variabile dipendente, suggerendo una scarsa capacità predittiva del modello.

Una differenza sostanziale tra i due studi riguarda la significatività delle variabili indipendenti. Nel presente lavoro di tesi, risultano significative variabili come la classe di reddito familiare, alcuni livelli di istruzione, il numero di persone in famiglia, il genere, il numero di veicoli in famiglia, il numero di viaggi superiori ai 200 miglia e la distanza casa-lavoro, tutte caratterizzate da bassi p-value. Al contrario, nel lavoro di Hardman, queste stesse variabili non risultano significative, in quanto dotate di p-value elevati. Tale discrepanza potrebbe essere attribuita a tre fattori principali: in primo luogo, alcune variabili di natura qualitativa, come il livello di istruzione e la classe di reddito familiare, sono state trattate come variabili quantitative nel modello di Hardman; in secondo luogo, come sono state dicotomizzate le variabili per l'analisi logistica; e in terzo luogo, potrebbero esserci differenze nella selezione del campione. Il dataset utilizzato in questa tesi include circa 10,000 osservazioni, mentre quello di Hardman et al. si compone di meno di 5,000 casi.

Inoltre, i dati utilizzati in questo studio sono stati impiegati anche in un altro lavoro di ricerca condotto da Ma e Pinsky (2020) in "Using machine learning to identify primary features in choosing electric vehicles based on income levels". A differenza dello studio di Hardman et al., questo articolo si concentra sull'analisi predittiva tramite modelli di *machine learning*. Una differenza sostanziale tra lo studio di Ma e Pinsky e questo lavoro di tesi è che gli autori hanno suddiviso il dataset in base alle classi di reddito e hanno applicato modelli predittivi separati per ciascun gruppo, confrontandone le performance. Gli algoritmi utilizzati in entrambi gli studi sono simili e includono *Random Forest*, *Logistic Regression* e *SVC*. Tendenzialmente, anche i modelli di Ma e Pinsky presentano valori di accuratezza non elevati, sebbene con alcune differenze. In particolare, l'algoritmo *Random Forest* mostra una performance più bassa nel *training set*, ma migliora nel *validation set*. Al contrario, l'algoritmo *Naive Bayes*, che ha ottenuto performance soddisfacenti sia sui dati di train che su quelli di test, ha raggiunto valori di accuratezza variabili tra 82% e 88%. Poiché questo algoritmo ha garantito buone performance, è stato testato anche in questa tesi. Inizialmente, il *Naive Bayes* si era classificato come il sesto algoritmo migliore in termini di accuratezza, motivo per cui non era stato preso in considerazione, ma per fine comparativo sono stati effettuati tutti i passaggi necessari, inclusi la *Grid Search CV* e la validazione incrociata con 15 fold. Tuttavia, questo non ha portato ai risultati eccellenti riscontrati nello studio di Ma e Pinsky, in quanto i valori di accuratezza ottenuti per i tre modelli (base, *Grid Search CV* e *Cross Validation*) sono rimasti intorno al 63%. Questi risultati possono essere spiegati dal fatto che nel lavoro di Ma e Pinsky sono state utilizzate solo sette variabili, ovvero numero di veicoli in famiglia, età, numero di persone in famiglia, distanza casa-lavoro, abitazione indipendente, sensibilità ambientale e auto precedente, limitandosi esclusivamente a considerare i possessori di veicoli elettrici. La scelta di queste variabili, unita a un processo di pulizia del dataset differente, potrebbe aver influito sulla performance predittiva.

In sintesi, alla luce dei risultati ottenuti in studi precedenti, si può concludere che in generale queste variabili fatichino a spiegare adeguatamente il fenomeno in esame, in particolare nel contesto californiano, e a discriminare la decisione di acquistare o meno un veicolo elettrico.

8.6. CONSIDERAZIONI FINALI

In sintesi, questa ricerca ha evidenziato come l'adozione di veicoli elettrici sia influenzata da una combinazione di fattori, tra cui il reddito, la distanza percorsa annualmente e il numero di viaggi lunghi effettuati. La transizione verso la mobilità elettrica non deve essere vista solo come una questione tecnologica o economica, ma come un cambiamento culturale che richiede tempo e politiche mirate per favorire questa evoluzione. In particolare, come discusso nel Capitolo 2, la mobilità elettrica si configura, al momento, come la soluzione migliore per i contesti urbani, ma è fondamentale considerare anche altre variabili.

Un aspetto che non è stato trattato in questa tesi, ma che costituisce una sfida altrettanto rilevante, riguarda la quantità di energia necessaria per ricaricare i veicoli elettrici. Se la transizione verso la mobilità elettrica dovesse proseguire con la stessa intensità, sarà essenziale sviluppare strategie per gestire i consumi energetici e produrre energia elettrica pulita in grado di soddisfare il fabbisogno delle flotte di veicoli elettrici, evitando così un potenziale sovraccarico delle reti esistenti.

Le evidenze emerse da questa ricerca offrono spunti significativi sia per le aziende che per i policy makers, suggerendo la necessità di campagne informative più efficaci e di incentivi mirati in base alle diverse tipologie di consumatori. La dashboard predittiva sviluppata rappresenta un primo passo verso l'applicazione pratica di questi risultati, con l'obiettivo di migliorare la comprensione del mercato e supportare le decisioni strategiche basate su analisi data-driven.

In un contesto di crescente attenzione alla sostenibilità e alla mobilità sostenibile, comprendere le dinamiche di adozione dei veicoli elettrici diventa fondamentale per accelerare la transizione verso una mobilità più pulita e accessibile a tutti.

BIBLIOGRAFIA

A2A. (2024). Range anxiety nell'era della mobilità elettrica. Disponibile al seguente indirizzo: <https://www.a2a.it/magazine/mobilita-elettrica/range-anxiety-nellera-della-mobilita-elettrica>

ACEA. (2024). European auto industry calls for urgent action as demand for EVs declines. Disponibile al seguente indirizzo: <https://www.acea.auto/press-release/european-auto-industry-calls-for-urgent-action-as-demand-for-evs-declines/>

ACEA. (2024). New car registrations: +0.8% in 2024; battery-electric 13.6% market share. ACEA. Disponibile al seguente indirizzo: <https://www.acea.auto/pc-registrations/new-car-registrations-0-8-in-2024-battery-electric-13-6-market-share/>

Andrew, L. (2024). Net Worth for Californians: How Much To Be Poor, Middle Class or Rich. *GoBanking Rates*. Disponibile al seguente indirizzo: <https://finance.yahoo.com/news/net-worth-californians-much-poor-190020094.html?guccounter=1>

Angi, N. (2022). Auto ibride plug-in: cariche o non cariche, questo è il dilemma. *Al Volante*. Disponibile al seguente indirizzo: <https://www.alvolante.it/news/ibride-plug-in-costi-ed-emissioni-reali-superiori-a-amologati-381085>

Bartolozzi, I., Rizzi, F., & Frey, M. (2013). Comparison between hydrogen and electric vehicles by life cycle assessment: A case study in Tuscany, Italy. *Applied Energy*, 10, pp. 103-111.

Canale, G. (s.d.). Machine learning lifecycle with Python & Mastering hyperparameter tuning in machine learning with Python. Risorse online. Disponibile al seguente indirizzo: <https://xbe.at>.

Casari, M. Dottoranda presso Università degli studi di Modena e Reggio-Emilia. (2025). *Corso Artificial Intelligence e Machine Learning, Big Data Lab*.

Commissione Europea. Il Green Deal europeo. Disponibile al seguente indirizzo: https://commission.europa.eu/strategy-and-policy/priorities-2019-2024/european-green-deal_it

Commissione Europea. (2024). European Alternative Fuels Observatory: Italy. Disponibile al seguente indirizzo: <https://alternative-fuels-observatory.ec.europa.eu/transport-mode/road/italy>

Confcommercio. (2024). Incentivi e agevolazione per veicoli elettrici. Disponibile al seguente indirizzo: <https://www.confcommercio.it/-/incentivi-auto-elettriche>

Chen, C.-F., Zarazua de Rubens, G., Noel, L., Kester, J., & Sovacool, B. K. (2020). Assessing the socio-demographic, technical, economic and behavioral factors of Nordic electric vehicle adoption and the influence of vehicle-to-grid preferences. *Renewable and Sustainable Energy Reviews*, 121.

Corbetta, P. (2014). Metodologia e tecniche della ricerca sociale. *Il Mulino*.

De Lillo, A., Argentin, G., Lucchini, M., Sarti, S., & Terraneo, M. (2007). Analisi multivariata per le scienze sociali. *Pearson Education*.

Encyclopedia of Mathematics. Hamming distance. Disponibile al seguente indirizzo: http://encyclopediaofmath.org/index.php?title=Hamming_distance&oldid=54614

Gemelli, F. (2024). Mercedes Classe E diesel mild hybrid (2024), la prova dei consumi reali. *Motor1*. Disponibile al seguente indirizzo: <https://it.motor1.com/reviews/731128/mercedes-classe-e-diesel-mild-hybrid-2024-consumi/>

Géron, A. (2019). Hands-on machine learning with Scikit-Learn, Keras & TensorFlow: Concepts, tools, and techniques to build intelligent systems. *O'Reilly*.

Goldman Sachs. (2024). Why are EV sales slowing?. Disponibile al seguente indirizzo: <https://www.goldmansachs.com/insights/articles/why-are-ev-sales-slowng>

Grotti, D. (2024). *Corso Applicazioni di Deep Learning, Big Data Lab*. Risorse disponibili al seguente indirizzo: <https://github.com/Frenz86/DeepLearning>.

Hanumanthappa, M., Sarakutty, T. K., (2011). Predicting the Future of Car Manufacturing Industry using Data Mining Techniques. *International Journal on Information Technology*, 01, pp. 27-29.

Hardman, S. (2019). Understanding the Early Adopters of Fuel Cell Vehicles. *UC Davis: National Center for Sustainable Transportation*.

Hardman, S. (2019). Sociodemographic data for battery electric vehicle owning households in California (From NCST Project “Understanding the Early Adopters of Fuel Cell Vehicles”) [Dataset]. *Dryad*. Disponibile al seguente indirizzo: <https://doi.org/10.25338/B8P313>.

IEA. (2024). Global EV Outlook 2024, Moving towards increased affordability. International Energy Agency. Disponibile al seguente indirizzo: <https://www.iea.org/reports/global-ev-outlook-2024/trends-in-electric-cars>

International Council on Clean Transportation. (2024). European Vehicles Market Statistics 2023/24

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). An introduction to statistical learning with applications in R. *Springer*.

Jolliffe, I. T. (2002). Principal component analysis, Second Edition. *Springer Science & Business Media*.

Kabacoff, R. (2024). Modern data visualization with R. *CRC Press*.

Kassambara, A. (2017). Practical guide to principal component methods in R: PCA, (M)CA, FAMD, MFA, HCPC, factoextra. *STHDA*.

Kassambara, A. (2017). Practical guide to cluster analysis in R: Unsupervised machine learning. *STHDA*.

Lantz, B. (2015). Machine learning with R: Community experience distilled. *PACKT Publishing*.

MISE - Ministero delle imprese e del made in Italy. (2024). Ecobonus. Disponibile al seguente indirizzo: <https://ecobonus.mise.gov.it/>

Ma, M., & Pinsky, E. (2024). Using machine learning to identify primary features in choosing electric vehicles based on income levels. *Data Science and Management*, 7, pp. 1-6.

Molnar, C. (2022). Interpretable Machine Learning, A Guide for Making Black Box Models Explainable. *Pubblicazione Indipendente*. Disponibile al seguente indirizzo: <https://christophmolnar.com>.

Motus-E. Quanta autonomia hanno le auto elettriche?. Disponibile al seguente indirizzo: <https://www.motus-e.org/faq-items/quanta-autonomia-hanno-le-auto-elettriche/>

Pan, M., Uddin, M., Lim, H. (2024). Understanding Electric Vehicle Ownership Using Data Fusion and Spatial Modeling. *Transportation Research Part D: Transport and Environment*, 127, pp. 1-25.

Pellacani, M. (2024). *Corso Machine e Deep Learning*. Lezioni universitarie, Università degli Studi di Modena e Reggio-Emilia.

Ratner, B. (2009). The correlation coefficient: Its values range between +1/-1, or do they?. *Journal of Targeting, Measurement and Analysis for Marketing*, pp. 139–142.

Rollo, F. (2025). Ricercatrice presso Università degli studi di Modena e Reggio-Emilia. *Corso Artificial Intelligence e Machine Learning, Big Data Lab*.

Soltani-Sobh, A., Heaslip, K., Bosworth, R., Barnes, R., & Yook, D. (2015). Investigating factors affecting electric vehicles adoption: an aggregated panel data analysis over U.S. states. *World Electric Vehicle Journal*, 7, pp. 1-11.

Veras, T. S., Mozer, T. S., Messeder dos Santos, D. C. R., & Cesar, A. S. (2017). Hydrogen: Trends, production and characterization of the main process worldwide. *International Journal of Hydrogen Energy*, 42, pp. 2018-2033.

Veza, I., Zacky Asy'ari, M., Idris, M., Epin, V., Fattah, I. M. R., Spraggon, M., (2023). Electric vehicle (EV) and driving towards sustainability: Comparison between EV, HEV, PHEV, and ICE vehicles to achieve net zero emissions by 2050 from EV. *Alexandria Engineering Journal*, 82, pp. 459-467

Vrkljan, B. H., & Anaby, D. (2010). What vehicle features are considered important when buying an automobile? An examination of driver preferences by age and gender. *Journal of Safety Research*, 42, pp. 61-65.

Westin, K., Jansson, J., & Nordlund, A. (2018). The importance of socio-demographic characteristics, geographic setting, and attitudes for adoption of electric vehicles in Sweden. *Travel Behaviour and Society*, 13, pp. 118-127.

Zhang, W., Fang, X., & Sun, C. (2023). The alternative path for fossil oil: Electric vehicles or hydrogen fuel cell vehicles?. *Journal of Environmental Management*, 341, pp. 1-11.

Codici:

Repository di GitHub contenente codici usati, disponibile al link: https://github.com/FedeGambes/Master_s_thesis_Data_science